

ΠΑΝΕΠΙΣΤΗΜΙΟ ΠΕΙΡΑΙΩΣ  
ΣΧΟΛΗ ΤΕΧΝΟΛΟΓΙΩΝ ΠΛΗΡΟΦΟΡΙΚΗΣ ΚΑΙ ΕΠΙΚΟΙΝΩΝΙΩΝ  
ΤΜΗΜΑ ΠΛΗΡΟΦΟΡΙΚΗΣ



## **Πρόβλεψη Κυκλοφοριακού Φόρτου σε Οδικά Δίκτυα**

ΠΤΥΧΙΑΚΗ ΕΡΓΑΣΙΑ

ΚΑΡΚΑΝΗΣ Ε. ΕΥΣΤΡΑΤΙΟΣ

Α.Μ.: Π19064

ΕΠΙΒΛΕΠΩΝ ΚΑΘΗΓΗΤΗΣ: ΘΕΟΔΩΡΙΔΗΣ ΙΩΑΝΝΗΣ

ΠΕΙΡΑΙΑΣ 2023

## **Ευχαριστίες**

Κατά τη διάρκεια των φοιτητικών μου χρόνων στο Τμήμα Πληροφορικής του Πανεπιστημίου Πειραιώς, ανακάλυψα το βαθύ ενδιαφέρον μου με τον χώρο της μηχανικής μάθησης και της ανάλυσης των δεδομένων. Αυτή η ανακάλυψη ήταν αυτό που με ενέπνευσε να επιλέξω να αφιερώσω την πτυχιακή μου εργασία σε ένα θέμα που ανήκει σε αυτόν τον ευρύτερο τομέα. Επομένως, νιώθω ιδιαίτερα χαρούμενος και ευγνώμων που έχω αναλάβει να ασχοληθώ εκτενέστερα με ένα κλάδο που μου αρέσει πολύ. Ωστόσο, αυτή μου η προσπάθεια δεν θα ήταν δυνατόν να πραγματοποιηθεί χωρίς την συμβολή ορισμένων ατόμων.

Πρώτα και κύρια, θέλω να εκφράσω τις θερμές μου ευχαριστίες στους κο. Θεοδωρίδη Ιωάννη, Καθηγητή του Τμήματος Πληροφορικής του Πανεπιστημίου Πειραιώς, κο. Πελέκη Νικόλαο, Αναπληρωτή Καθηγητή του Τμήματος Στατιστικής και Ασφαλιστικής Επιστήμης του Πανεπιστημίου Πειραιώς και Δρα. Χονδροδήμα Εύα, μέλος του Data Science Lab του Πανεπιστημίου Πειραιώς, για την ανεκτίμητη υποστήριξη, καθοδήγηση και εμπιστοσύνη που μου παρέιχαν σε όλη τη διάρκεια εκπόνησης αυτής της μελέτης. Η συνεισφορά τους σε οργανωτικό και τεχνικό επίπεδο ήταν κρίσιμη για την πραγματοποίηση του έργου αυτού.

Δεν μπορώ να παραλείψω να ευχαριστήσω το εκπαιδευτικό προσωπικό του τμήματος πληροφορικής για την υψηλή ποιότητα γνώσεων που έλαβα κατά τη διάρκεια των σπουδών μου. Η γνώση που αποκόμισα αποτέλεσε το θεμέλιο για την επιτυχημένη και ομαλότερη ολοκλήρωση αυτής της έρευνας.

Τέλος, θα ήθελα να εκφράσω την ευγνωμοσύνη μου προς όλους όσους με στήριξαν και με ενθάρρυναν σε όλη τη διάρκεια αυτής της πορείας, ιδίως προς την οικογένειά μου, που είναι πάντα στο πλευρό μου και με υποστηρίζει στις προσπάθειές μου.

## Περίληψη

Η παρούσα πτυχιακή έρευνα επικεντρώνεται στον τομέα της μηχανικής μάθησης και συγκεκριμένα εξετάζει την πρόβλεψη της κυκλοφοριακής ροής των κινούμενων αντικειμένων εντός ενός συγκεκριμένου οδικού δικτύου μίας περιοχής. Εδώ ακολουθείται μία διαφορετική προσέγγιση για την διαδικασία των προβλέψεων, αφού η τελευταία γίνεται σε επίπεδο μονοπατιών. Ένα μονοπάτι είναι μία συνεχόμενη ακολουθία από τμήματα μεταξύ διασταυρώσεων εντός του ίδιου οδικού δικτύου. Αρχικά, προτείνεται μία γενική μεθοδολογία επίλυσης του ζητήματος, η οποία ενθαρρύνει την χρήση προηγμένων τεχνικών μηχανικής και βαθιάς μάθησης εξετάζοντας και αξιολογώντας τέσσερα μοντέλα που βασίζονται σε δέντρα απόφασης ή σε νευρωνικά δίκτυα. Έπειτα, γίνεται εφαρμογή της μεθοδολογίας αυτής με την χρήση δεδομένων τροχιών των κίτρινων ταξί που κινούνται εντός της πόλης του Σαν Φρανσίσκο στην Καλιφόρνια. Με βάση το χαμηλότερο RMSE score, το XGBoost επιλέγεται ως το ιδανικό μοντέλο για την εφαρμογή των βραχυπρόθεσμων προβλέψεων. Δεδομένης της πολυπλοκότητας και της πολυδιάστατης φύσης της κυκλοφοριακής ροής, επιλέγονται να γίνουν μόνο βραχυπρόθεσμες προβλέψεις για το μέγεθος αυτό σε κάθε μονοπάτι.

Λέξεις Κλειδιά: πρόβλεψη κυκλοφοριακής ροής, μηχανική μάθηση, XGBoost, χρονοσειρές.

## Abstract

This thesis research focuses on the field of machine learning and specifically examines the prediction of the traffic flow of moving objects within a specific road network of a region. A different approach is taken for the prediction process since the latter is done at the path level. A path is a continuous sequence of segments between intersections within the same road network. Initially, a general methodology to solve the issue is proposed, which encourages the use of advanced machine and deep learning techniques by considering and evaluating four models based in decision trees or neural networks. Then, this methodology is applied using trajectory data of yellow taxis moving within the city of San Francisco, California. Based on the lowest RMSE score, XGBoost is the ideal model for applying short-term predictions. Given the complexity and multi-dimensional nature of traffic flow, only short-term forecasts of this magnitude are selected for each pathway.

Keywords: traffic flow forecasting, machine learning, XGBoost, time series.

## Κατάλογος Εικόνων και Διαγραμμάτων

### Εικόνες

Εικόνα 1.1: Το γράφημα G1.....	8
Εικόνα 1.2: Το μονοπάτι 32-21-15-54.....	9
Εικόνα 4.1: Τροχιά ενός ΚΑ.....	25
Εικόνα 4.2: Πριν και μετά το Map Matching.....	26
Εικόνα 4.3: Παράδειγμα εφαρμογής του κυλιόμενου παραθύρου.....	29
Εικόνα 5.1: Το οδικό δίκτυο της πόλης του San Francisco, California.....	32
Εικόνα 5.2: Το τελικό σύνολο δεδομένων.....	35

### Διαγράμματα

Διάγραμμα 5.1: Κατανομή μονοπατιών ως προς το μήκος των ακμών τους.....	35
Διάγραμμα 5.2: Συνολική ροή κυκλοφορίας κάθε ημέρα.....	36
Διάγραμμα 5.3 Η κυκλοφοριακή ροή κατά την ημέρα 2008-05-18.....	37
Διάγραμμα 5.4: Μήτρα συσχέτισης του συνόλου δεδομένων.....	38
Διάγραμμα 5.5: Σφάλματα για διάφορα μήκη παραθύρου.....	39
Διάγραμμα 5.6: Επίδοση των μοντέλων στο σύνολο ελέγχου που αντιστοιχεί στο μονοπάτι 0.....	40
Διάγραμμα 5.7: Γνωστές και προβλεπόμενες τιμές του μεγέθους της κυκλοφοριακής ροής στο μονοπάτι 0.....	42
Διάγραμμα 5.8: Γνωστές και προβλεπόμενες τιμές του μεγέθους της κυκλοφοριακής ροής στο μονοπάτι 4.....	42
Διάγραμμα 5.9: Γνωστές και προβλεπόμενες τιμές του μεγέθους της κυκλοφοριακής ροής στο μονοπάτι 36.....	42
Διάγραμμα 5.10: Γνωστές και προβλεπόμενες τιμές του μεγέθους της κυκλοφοριακής ροής στο μονοπάτι 83.....	43
Διάγραμμα 5.11: Πληροφορία που συλλέγεται με και χωρίς την συνάρτηση SPQ.....	44
Διάγραμμα 5.12: Απόδοση του αλγορίθμου XGBoost σε δεδομένα που έχουν δημιουργηθεί χωρίς την χρήση των ΑΕΜ.....	44

### Πίνακες

Πίνακας 5.1: RMSE και MAE scores για κάθε μοντέλο.....	41
Πίνακας 5.2: Απόδοση του μοντέλου XGBoost.....	44

## Πίνακας Περιεχομένων

Ευχαριστίες.....	1
Περίληψη .....	2
Abstract .....	2
Κατάλογος Εικόνων και Διαγραμμάτων .....	3
Εικόνες .....	3
Διαγράμματα.....	3
Πίνακες .....	3
Πίνακας Περιεχομένων .....	4
Εισαγωγή.....	6
Ο Κλάδος της Τεχνητής Νοημοσύνης .....	6
Δομή Τόμου Εργασίας.....	7
1. Θεωρητικό Υπόβαθρο της Εφαρμογής .....	8
1.1 Ορισμοί.....	8
1.2 Προσδιορισμός του προβλήματος.....	9
1.3 Μοντέλα Μηχανικής Μάθησης .....	10
1.3.1 Ο Αλγόριθμος XGBoost.....	10
1.3.2 Το μοντέλο Long Short Term Memory .....	11
1.3.3 Το Μοντέλο Encoder - Decoder .....	12
1.3.4 Το Μοντέλο Random Forest .....	12
2. Σχετικές Εργασίες.....	14
2.1 Επίλυση του Προβλήματος με ένα Μοντέλο Long Short-Term Memory .....	14
2.2 Πρόβλεψη με Απλά Νευρωνικά Δίκτυα .....	15
2.3 Μοντέλο Αποτελούμενο από Κωδικοποιητές και Αποκωδικοποιητές .....	15
2.4 Πρόβλεψη Κυκλοφοριακής Ροής με το Μοντέλο Deep Crowd.....	16
2.5 Χρήση Γραφημάτων και Νευρωνικών Δικτύων .....	16
2.6 Έρευνα Βασισμένη στον Αλγόριθμο XGBoost.....	18
3. Τεχνολογίες.....	19
3.1 Η Γλώσσα Python.....	19
3.1.1 Python και Επιστήμη Δεδομένων .....	19
3.2 Jupyter Notebook και Google Colab .....	20
3.2.1 Το Jupyter Notebook.....	20
3.2.2 Το Google Colab.....	20
3.3 PostgreSQL και PLpgSQL .....	21
3.3.1 Γενικά Χαρακτηριστικά για την Βάση Δεδομένων .....	21
3.3.2 Η Γλώσσα PL/pgSQL .....	21
3.4 Το Λογισμικό Docker .....	22
3.5 Το Λογισμικό Valhalla.....	22

3.5.1 Η Υπηρεσία Valhalla Meili .....	23
4. Μεθοδολογία.....	25
4.1 Συλλογή και Επεξεργασία των Δεδομένων .....	25
4.2 Αναγωγή σε Πρόβλημα Χρονοσειρών.....	26
4.3 Προσθήκη Επιπλέον Πληροφορίας στα Δεδομένα .....	27
4.4 Οργανώνοντας τα Δεδομένα Εισόδου.....	28
4.5 Εκπαίδευση και Αξιολόγηση του Μοντέλου.....	29
4.6 Παραγωγή των Προβλέψεων .....	30
5. Εφαρμογή της Μεθοδολογίας.....	31
5.1 Δεδομένα που Χρησιμοποιήσαμε .....	31
5.1.1 Δεδομένα Τροχιών .....	31
5.1.2 Δεδομένα Καιρού.....	32
5.2 Προεπεξεργασία των Δεδομένων.....	33
5.3 Αντιστοίχιση Τροχιών στο Οδικό Δίκτυο .....	34
5.4 Αναγωγή του Προβλήματος σε Χρονοσειρές .....	34
5.5 Οπτικοποίηση των δεδομένων.....	36
5.6 Χρήση Μοντέλων Μηχανικής και Βαθιάς Μάθησης .....	37
5.6.1 Διαχωρισμός σε Σύνολα Εκπαίδευσης, Ελέγχου και Επικύρωσης.....	37
5.6.2 Εκπαίδευση των μοντέλων.....	38
5.7 Αποτελέσματα .....	41
5.8 Χρησιμότητα των ΑΕΜ στη Συλλογή Δεδομένων .....	43
6. Συμπεράσματα και Προτάσεις για Βελτίωση .....	45
Πίνακας Ορολογιών .....	46
Πίνακας Συντμήσεων – Αρκτικόλεξων – Ακρωνύμιων.....	49
Βιβλιογραφικές Πηγές.....	50

## Εισαγωγή

Η κυκλοφοριακή ροή (Traffic Flow) αποτελεί ένα κρίσιμο και αναπόσπαστο μέρος της καθημερινότητας του ανθρώπου. Ανεξαρτήτως του αν βρίσκεται σε μια απομονωμένη κοινότητα ή στην καρδιά μιας πολυσύχναστης πόλης, η καθημερινή ρουτίνα εξαρτάται σε μεγάλο βαθμό από την απρόσκοπτη ροή των οχημάτων στον δρόμο. Προβλήματα όπως η κυκλοφοριακή συμφόρηση και ο χρόνος ταξιδιού, καθίστανται ολοένα και πιο συνήθη, επιβάλλοντας την ανάγκη για καινοτόμες λύσεις.

Η τεχνολογική πρόοδος των τελευταίων ετών έχει ανοίξει τον δρόμο για την συλλογή, αποθήκευση και ανάλυση μεγάλου όγκου δεδομένων, γνωστών και ως «big data». Έτσι, η αυξημένη προσβασιμότητα σε δεδομένα κυκλοφοριακής ροής και η δυνατότητα της ταχείας επεξεργασίας τους έχει επιτρέψει την ανάπτυξη μοναδικών μεθοδολογιών και προσεγγίσεων για την πρόβλεψη της κυκλοφοριακής ροής. Παράλληλα, η ανάγκη για βελτιωμένες πρακτικές μετακίνησης και για αντιμετώπιση των συνεχών προκλήσεων στον τομέα της κυκλοφοριακής ροής έχει οδηγήσει πολλούς φοιτητές, ερευνητές και επιστήμονες σε εντατική έρευνα γύρω από αυτό το ζήτημα.

Στο πλαίσιο αυτό, η παρούσα πτυχιακή εργασία αποτελεί μία ακόμα έρευνα γύρω από αυτόν τον τομέα. Συγκεκριμένα, η μελέτη αυτή επιδιώκει την ανάπτυξη μιας προηγμένης προσέγγισης για την πρόβλεψη της κυκλοφοριακής ροής με την χρήση αλγορίθμων **μηχανικής μάθησης** (Machine Learning - ML) και **βαθιάς μάθησης** (Deep Learning - DL). Το πρόβλημα προσεγγίζεται υπό ένα μοναδικό πρίσμα, μια μεθοδολογία που, από όσο γνωρίζουμε, δεν έχει χρησιμοποιηθεί στο παρελθόν για την επίλυση ενός τέτοιου προβλήματος.

## Ο Κλάδος της Τεχνητής Νοημοσύνης

Όπως αναφέρθηκε προηγουμένως, το πρόβλημα που εστιάζει η παρούσα έρευνα συγκαταλέγεται στον τομέα της μηχανικής μάθησης. Η τελευταία ανήκει σε ένα ευρύτερο πεδίο που ονομάζεται τεχνητή νοημοσύνη (Artificial Intelligence - AI). Επομένως, καθίστανται αναγκαία η εξήγηση σχετικών με τον κλάδο αυτό όρων.

Η τεχνητή νοημοσύνη αντιπροσωπεύει μια σημαντική πτυχή της πληροφορικής που αποσκοπεί στη δημιουργία συστημάτων, τα οποία είναι σε θέση να εκτελούν εργασίες που απαιτούν ανθρώπινη νοημοσύνη και λογική σκέψη. Σε αυτήν την κατηγορία περιλαμβάνονται εφαρμογές όπως η αναγνώριση φωνής, η αναγνώριση εικόνας, η αυτόνομη οδήγηση και η αυτόματη μετάφραση. Η τεχνητή νοημοσύνη στηρίζεται στην υπολογιστική ισχύ για να αναλύσει και να επεξεργαστεί δεδομένα, προκειμένου να παράγει λογικά αποτελέσματα.

Συνεχίζοντας, η μηχανική μάθηση αποτελεί ένα σημαντικό υποσύνολο της τεχνητής νοημοσύνης. Στη μηχανική μάθηση, αλγόριθμοι και μοντέλα αναπτύσσονται, ώστε να μπορούν να «μαθαίνουν» από τα δεδομένα που τους παρέχονται. Αυτό σημαίνει ότι τα συστήματα αυτά μπορούν να αναγνωρίσουν μοτίβα και να κάνουν προβλέψεις με βάση την επεξεργασία των δεδομένων. Για παράδειγμα, ένα μοντέλο μηχανικής μάθησης μπορεί να εκπαιδευτεί, για να αναγνωρίζει πρόσωπα σε φωτογραφίες ή να προβλέπει τις τιμές διαφόρων μεγεθών δοθέντος προηγούμενων ιστορικών δεδομένων.

Τέλος, η βαθιά μάθηση αποτελεί ένα υποσύνολο της μηχανικής μάθησης που βασίζεται στη χρήση νευρωνικών δικτύων (Neural Networks – NN) με πολλά, συνήθως, επίπεδα (Layers). Αυτά τα βαθιά νευρωνικά δίκτυα προσομοιάζουν τον τρόπο με τον οποίο λειτουργεί ο ανθρώπινος εγκέφαλος και έχουν την ικανότητα να εξαγάγουν υψηλού επιπέδου σχέσεις από τα δεδομένα. Αυτό επιτρέπει σε αυτά τα μοντέλα να αντιμετωπίσουν πιο πολύπλοκες εργασίες, όπως η αναγνώριση αντικειμένων σε εικόνες, η ανάλυση φυσικής γλώσσας και η παραγωγή μουσικής.

Όλοι οι αλγόριθμοι που χρησιμοποιούν δεδομένα, για να παράγουν κάποια αποτελέσματα ονομάζονται αλλιώς και μοντέλα (Models). Με άλλα λόγια, ένα μοντέλο στον χώρο της μηχανικής μάθησης αναφέρεται σε ένα συγκεκριμένο υπολογιστικό σύστημα ή αλγόριθμο που έχει εκπαιδευτεί για μια συγκεκριμένη εργασία. Επίσης, τα μοντέλα μηχανικής μάθησης μπορούν να είναι γραμμικά, όπως ο αλγόριθμος της γραμμικής παλινδρόμησης (Linear Regression) ή πιο πολύπλοκα, όπως ένα βαθύ νευρωνικό δίκτυο (Deep Neural Network – DNN). Κάθε μοντέλο, προκειμένου να λειτουργεί σωστά για κάθε σύνολο δεδομένων, περιέχει κάποιες υπερπαραμέτρους (Hyperparameters), οι οποίες ρυθμίζονται από τον χρήστη κατά την

κατασκευή του αλγορίθμου. Αυτές οι υπερπαράμετροι ρυθμίζουν ουσιαστικά το μοντέλο, βοηθώντας το να προσαρμοστεί καλύτερα στα δεδομένα που λαμβάνει ως είσοδο.

Στην παρούσα έρευνα έχουν χρησιμοποιηθεί τέσσερα μοντέλα μηχανικής και βαθιάς μάθησης που προσπαθούν να επιλύσουν το ίδιο πρόβλημα. Τα μοντέλα αυτά είναι αφενός τα XGBoost και Random Forest που βασίζονται σε αλγορίθμους δέντρων απόφασης (Decision Trees) και ανήκουν στην κατηγορία της μηχανικής μάθησης. Αφετέρου, χρησιμοποιούνται και δύο μοντέλα βαθιάς μάθησης, ένα αναδρομικό νευρωνικό δίκτυο με βραχυπρόθεσμη και μακροπρόθεσμη μνήμη (Long Short-Term Memory – LSTM) και ένα μοντέλο Κωδικοποιητή - Αποκωδικοποιητή που βασίζεται σε νευρωνικά δίκτυα LSTM (Encoder – Decoder Model). Περισσότερες πληροφορίες για τους παραπάνω αλγορίθμους δίνονται στην επόμενη ενότητα.

## **Δομή Τόμου Εργασίας**

Η παρούσα εργασία αποτελείται από έξι κεφάλαια. Στο παρόν κεφάλαιο έγινε μία εισαγωγή, χωρίς να δίνεται έμφαση στις λεπτομέρειες.

Στο πρώτο κεφάλαιο του τόμου της εργασίας αναλύεται επακριβώς το πρόβλημα προς επίλυση από θεωρητική σκοπιά. Παράλληλα, δίνεται μία περιγραφή της μεθοδολογίας και των μηχανισμών που συμβάλλουν στην αντιμετώπιση του ζητήματος.

Στο δεύτερο κεφάλαιο γίνεται αναφορά σε παρόμοιες έρευνες που ασχολούνται με το θέμα της κυκλοφοριακής ροής. Για κάθε διαφορετική μελέτη που παρατίθεται, αναφέρονται σε βάθος η προσέγγιση του προβλήματος και η μέθοδος που ακολουθείται για την επίλυσή του.

Στο τρίτο κεφάλαιο αναφέρονται οι πλατφόρμες και τα πακέτα λογισμικού που χρησιμοποιήθηκαν για την υλοποίηση της παρούσας λύσης και την εμφάνιση των αποτελεσμάτων της.

Στο τέταρτο κεφάλαιο γίνεται εκτενής περιγραφή της μεθοδολογίας που ακολουθούμε προκειμένου να επιλύσουμε το συγκεκριμένο πρόβλημα.

Στο πέμπτο κεφάλαιο γίνεται η εφαρμογή της μεθοδολογίας που προτείνουμε σε ένα συγκεκριμένο σύνολο δεδομένων. Επίσης, παρουσιάζονται τα αποτελέσματα των προβλέψεων που προκύπτουν χρησιμοποιώντας έναν βελτιστοποιημένο αλγόριθμο μηχανικής μάθησης.

Στο τελευταίο κεφάλαιο αυτής της έρευνας παρουσιάζονται τα συμπεράσματα από την υλοποίηση της λύσης με παράλληλη παράθεση προτάσεων για βελτίωσή της.



## 1. Θεωρητικό Υπόβαθρο της Εφαρμογής


Υπάρχουν πολλά πρίσματα, υπό τα οποία μπορεί να εξετάσει κάποιος την κυκλοφοριακή ροή στους δρόμους. Για παράδειγμα, η τελευταία εξετάζεται σε μία ολόκληρη πόλη; σε ένα χωριό; σε μία περίοδο εορτής; ή κατά τη διάρκεια μίας καταιγίδας;

Στο παρόν κεφάλαιο παρατίθεται η θεωρία στην οποία βασιστήκαμε, ώστε να επιτύχουμε την επίτευξη αυτού του στόχου. Συγκεκριμένα, ορίζεται ρητά το πρόβλημα προς επίλυση και η οπτική γωνία, υπό την οποία εξετάζεται. Δηλώνονται, επίσης, και οι ερμηνείες σημαντικών εννοιών, η κατανόηση των οποίων καθίσταται αναγκαία για την παρακολούθηση του κειμένου.

### 1.1 Ορισμοί

Σε αυτό το υποκεφάλαιο αναλύονται σημαντικές έννοιες, η κατανόηση των οποίων κρίνεται σημαντική για την παρακολούθηση ολόκληρου του κειμένου. Στην παρούσα έρευνα γίνεται συχνά αναφορά στην έννοια του **οδικού δικτύου** (Road Network), το οποίο ταυτίζεται με το σύστημα οδών, δρόμων και διασταυρώσεων μίας περιοχής. Το οδικό δίκτυο μπορεί να αναπαρασταθεί ως ένα γράφημα  $G=(V,E)$ , δηλαδή ως ένα διατεταγμένο ζεύγος  $G=<V(G),E(G)>$ , όπου το  $V(G)=\{v_1,v_2,...,v_n\}$  είναι το σύνολο των κορυφών του γραφήματος  $G$  και το  $E(G)=\{e_1,e_2,...,e_m\}$  το σύνολο των ακμών του γραφήματος  $G$ .

Για παράδειγμα, στην εικόνα 1.1 δίνεται ένας μη κατευθυντός γράφος  $G_1$  που αναπαριστά ένα τυχαίο οδικό δίκτυο. Το σύνολο  $V_1$  των κόμβων του γραφήματος  $G_1$  είναι το  $V_1=\{1,2,3,4,5,6\}$ . Από την άλλη πλευρά, το σύνολο  $E_1$  των ακμών του γραφήματος  $G_1$  είναι το  $E_1=\{12,15,25,23,21,32,34,43,45,46,51,52,54,64\}$ .



Εικόνα 1.1: Το γράφημα  $G_1$ .

Γενικά, για ένα γράφημα που αναπαριστά ένα οποιοδήποτε οδικό δίκτυο, θεωρούμε ότι το σύνολο  $V$  προσδιορίζει τις διασταυρώσεις του δικτύου, ενώ το σύνολο  $E$  αναπαριστά τμήματα του οδικού δικτύου που βρίσκονται ανάμεσα σε δύο διασταυρώσεις.

Αφού έχουμε ορίσει νοητά τι είναι ένα οδικό δίκτυο, ο επόμενος ορισμός αφορά στην έννοια του **μονοπατιού** (Path). Ως μονοπάτι ορίζεται ένα σύνολο από τουλάχιστον δύο ακμές ενός γραφήματος  $G$  που είναι διαδοχικές μεταξύ τους. Κάθε μονοπάτι προσδιορίζεται μόνο από τις ακμές του γραφήματος  $G$ . Για παράδειγμα, στο γράφημα  $G_1$  της εικόνας 1.1, ένα πιθανό μονοπάτι είναι το  $15 \rightarrow 54 \rightarrow 46 \rightarrow 64$ . Η πρώτη ακμή αυτού του μονοπατιού αυτού βρίσκεται ανάμεσα στους κόμβους 1 και 5, η δεύτερη ακμή βρίσκεται ανάμεσα στους κόμβους 5 και 4 κ.ο.κ.


Μέσα σε ένα οποιοδήποτε οδικό δίκτυο, διαγράφουν πορείες διάφορα **κινούμενα αντικείμενα** ή ΚΑ (Moving Objects). Ως ΚΑ ορίζεται ένα οποιοδήποτε κινητό που διατρέχει τις ακμές ενός οδικού δικτύου. Ένα ΚΑ μπορεί να αναφέρεται σε ένα αυτοκίνητο, σε ένα λεωφορείο, σε ένα ταξί, κ.α. Οι πορείες που ακολουθεί ένα οποιοδήποτε ΚΑ μέσα στο οδικό δίκτυο αποτελεί την **τροχιά** (Trajectory) του.

Αφού έγινε η επεξήγηση των παραπάνω εννοιών, μπορούμε να αναλύσουμε τον όρο του κυκλοφοριακού φόρτου ή της κυκλοφοριακής ροής. Η τελευταία αναφέρεται στο πλήθος των ΚΑ που διέρχονται από ένα συγκεκριμένο μονοπάτι του οδικού δικτύου εντός ενός συγκεκριμένου χρονικού διαστήματος.

## 1.2 Προσδιορισμός του προβλήματος

Το θέμα της έρευνάς μας είναι η καταμέτρηση ιστορικών δεδομένων κυκλοφοριακού φόρτου από διάφορα μονοπάτια ενός οδικού δικτύου και η προσπάθεια πρόβλεψης της κυκλοφοριακής ροής σε μελλοντικό χρόνο σε κάθε μονοπάτι ξεχωριστά. Το πρίσμα, υπό το οποίο εξετάζουμε την πρόβλεψη της κυκλοφοριακής ροής είναι μοναδικό, πάντα με βάση τα όσα γνωρίζουμε. Με άλλα λόγια, δεν έχουμε καταφέρει να εντοπίσουμε έρευνες άλλων επιστημόνων που να ακολουθούν παρόμοια μεθοδολογία για την επίλυση του ίδιου προβλήματος.

Το βασικό ερώτημα που εγείρεται εδώ, είναι το πώς μπορούμε να μετρήσουμε το κυκλοφοριακό φόρτο μέσα σε ένα μονοπάτι. Ως απάντηση στο ερώτημα, παραθέτουμε την μεθοδολογία των **Αυστηρών Ερωτημάτων Μονοπατιού** (AEM) ή στα αγγλικά «Strict Path Queries - SPQs». Τα AEM αναφέρονται σε μια διαδικασία αναζήτησης που εκτελείται σε δεδομένα τροχιών ΚΑ με στόχο την ανάκτηση όλων των τροχιών που διέρχονται αυστηρά από ένα προκαθορισμένο μονοπάτι ενός οδικού δικτύου, χωρίς δηλαδή να παρεκκλίνουν καθόλου από το μονοπάτι αυτό. Μάλιστα, αυτή η συνθήκη πρέπει να ισχύει εντός ενός προεπιλεγμένου χρονικού διαστήματος [1].



Εικόνα 1.2: Το μονοπάτι 32-21-15-54.

Για παράδειγμα, εάν θέλουμε να μάθουμε πόσα ΚΑ διέσχισαν επακριβώς το μονοπάτι **32-21-15-54** του οδικού δικτύου που φαίνεται στην εικόνα 1.2 μέσα σε ένα συγκεκριμένο χρονικό διάστημα, μπορούμε να χρησιμοποιήσουμε τον αλγόριθμο των AEM.

Ειδικότερα, οι συγγραφείς, για να εξετάσουν την μέθοδό τους χρησιμοποιούν δεδομένα κίνησης ΚΑ, τα οποία καταγράφονται μέσω ενός συστήματος GPS, παρέχοντας πληροφορίες σχετικά με τη θέση τους στον τρισδιάστατο χώρο ( $x, y, t$ ). Το  $x$  αντιστοιχεί στο γεωγραφικό μήκος (longitude), το  $y$  αντιστοιχίζεται στο γεωγραφικό πλάτος (latitude) και το  $t$  αναπαριστά τον χρόνο (time). Η καταγραφή αυτών των δεδομένων κίνησης για κάθε κινούμενο όχημα ακολουθεί σταθερή περιοδικότητα. Κάθε αναφορά θέσης από το σύστημα GPS αναπαρίστανται με μια πλειάδα παραμέτρων της μορφής **loc=(moid, ts, pos)**, όπου:

- το στοιχείο «moid» (από το moving object id) αναπαριστά το αναγνωριστικό του κινούμενου αντικειμένου.
- το στοιχείο «ts» αντιστοιχεί σε συγκεκριμένη χρονική στιγμή.
- το στοιχείο «pos» (από το position) δηλώνει τη θέση του κινούμενου αντικειμένου κατά τη χρονική στιγμή «ts» με την χρήση χωρικών συντεταγμένων (latitude και longitude).

Μέσω μιας διαδικασίας αντιστοίχισης σημείων GPS σε ψηφιακούς χάρτες, τα αρχικά σημεία που παράγονται για κάθε κινούμενο όχημα αντιστοιχίζονται σε μια ακολουθία ακμών εντός του οδικού δικτύου. Με την εφαρμογή αυτής της διαδικασίας διαμορφώνεται μια τροχιά για κάθε κινούμενο όχημα. Κάθε τροχιά που συσχετίζεται με ένα συγκεκριμένο κινούμενο όχημα, αποτελείται από πολλές εγγραφές της μορφής **locmm=(tid, eid, tsenter, tsleave)**. Στην εν λόγω αναπαράσταση, το «tid» δηλώνει το αναγνωριστικό της τροχιάς, το «eid» αναφέρεται στο αναγνωριστικό της ακμής στο οδικό δίκτυο, ενώ τα «tsenter» και «tsleave» αναφέρονται στους χρόνους εισόδου και εξόδου του κινούμενου αντικειμένου από την ακμή με αναγνωριστικό «eid» αντίστοιχα. Επομένως, τα αρχικά δεδομένα που καταγράφονται από το σύστημα GPS υποβάλλονται σε μια διαδικασία μετατροπής σε εγγραφές locmm. Μια τροχιά  $tr$  προκύπτει ως ένα

σύνολο τέτοιων εγγραφών, δηλαδή η τροχιά  $tr$  ορίζεται ως εξής:  $tr = [locmm1, locmm2, \dots, locmmn]$ .

Αφού οριστεί ένα σύνολο από τροχιές, οι ερευνητές προσπαθούν να δοκιμάσουν την ικανότητα του αλγορίθμου SPQ επάνω σε αυτά τα νέα δεδομένα. Δίνοντας ως είσοδο στον αλγόριθμο δύο χρονικές στιγμές, αρχής και τέλους αντίστοιχα, καθώς και ένα μονοπάτι από συνεχόμενες ακμές που βρίσκονται στο ίδιο οδικό δίκτυο, ο αλγόριθμος επιστρέφει έναν αριθμό. Όσον αφορά την επίδοση της μεθόδου, οι συγγραφείς υποστηρίζουν ότι τα αποτελέσματα που παρέχονται από τον αλγόριθμο των AEM μπορούν να θεωρηθούν ικανοποιητικά. Ο συγκεκριμένος αλγόριθμος διακρίνεται για την υψηλή του ακρίβεια και ταχύτητα εκτέλεσής του σε σύγκριση με άλλες προσεγγίσεις που έγιναν στα πλαίσια της ίδιας έρευνας.

Είναι σημαντικό να αναφερθεί ότι τα AEM είναι απαραίτητα για πολλούς λόγους. Αφενός, παρέχουν την πληροφορία για το πόσες τροχιές διέσχισαν ένα συγκεκριμένο μονοπάτι από την αρχή του έως και το τέλος του, χωρίς να παρεκκλίνουν καθόλου από αυτό. Θέτοντάς το διαφορετικά, βοηθούν να προσδιοριστεί η ποσότητα της ροής των κινούμενων αντικειμένων εντός ενός ολοκληρού μονοπατιού με μεγάλη ακρίβεια. Αφετέρου, υπάρχει δυνατότητα να οριστεί το χρονικό διάστημα που επιλέγεται να γίνει η αναζήτηση της κυκλοφοριακής ροής. Επομένως, με την χρήση αυτής της μεθοδολογίας μπορούν να εξαχθούν σημαντικά συμπεράσματα σχετικά με τη συμπεριφορά της κυκλοφορίας και της μετακίνησης κινούμενων οχημάτων, αναγνωρίζοντας ποια μονοπάτια διασχίζονται συχνότερα κατά τη διάρκεια διαφόρων χρονικών περιόδων, όπως οι ώρες αιχμής. Τέλος, μπορούν να ανακαλυφθούν μοτίβα συμφόρησης και να εντοπιστούν ανωμαλίες στην κυκλοφορία, επιτρέποντας την αντιμετώπιση πιθανών προβλημάτων.

Τα AEM μπορούν να οργανώσουν τα δεδομένα τροχιών σε χρονοσειριακές πληροφορίες ή χρονοσειρές (Timeseries). Μία χρονοσειρά περιέχει δεδομένα, τα οποία είναι διατεταγμένα ως προς το μέγεθος του χρόνου.

Ορίζοντας τυχαία μονοπάτια σε ένα οδικό δίκτυο, είναι δυνατόν να καταμετρηθεί η κυκλοφοριακή ροή σε κάθε ένα από αυτά εντός συγκεκριμένων χρονικών διαστημάτων. Εάν τα χρονικά διαστήματα αυτά είναι διαδοχικά (το επόμενο έπεται του προηγούμενου), τότε για κάθε μονοπάτι που ορίζεται γνωρίζουμε την κυκλοφοριακή ροή σε συνεχόμενα χρονικά διαστήματα. Με άλλα λόγια, για κάθε μονοπάτι έχουμε στην κατοχή μας μία χρονοσειρά που προσδιορίζει το κυκλοφοριακό φόρτο σε αυτό.

Στο επόμενο υποκεφάλαιο, παρατίθενται κάποια μοντέλα μηχανικής και βαθιάς μάθησης που χρησιμοποιούνται για τον προσδιορισμό του μεγέθους της κυκλοφοριακής ροής στο μέλλον σε κάθε μία χρονοσειρά ξεχωριστά. Αυτή η διαδικασία πρόβλεψης είναι γνωστή και ως πρόβλεψη χρονοσειρών (Timeseries Forecasting).

### 1.3 Μοντέλα Μηχανικής Μάθησης

Σε αυτό το τμήμα του κεφαλαίου παρατίθενται περισσότερες θεωρητικές πληροφορίες σχετικά με τα μοντέλα μηχανικής μάθησης που εκμεταλλευτήκαμε στην παρούσα μελέτη, προκειμένου να ολοκληρώσουμε την διαδικασία της πρόβλεψης. Συγκεκριμένα, αναλύεται ο τρόπος λειτουργίας των ακόλουθων μοντέλων: XGBoost, Random Forest, Encoder–Decoder και LSTM.

#### 1.3.1 Ο Αλγόριθμος XGBoost

Ο αλγόριθμος XGBoost (Extreme Gradient Boosting) είναι ένας πανίσχυρος αλγόριθμος μηχανικής μάθησης που δημιουργήθηκε από τον Tianqi Chen [2]. Βασίζεται σε δέντρα απόφασης και χρησιμοποιείται ευρέως για προβλήματα παλινδρόμησης (Regression) και ταξινόμησης (Classification).

Ο μηχανισμός αυτός έχει ως θεμέλιο λίθο την τεχνική της καθόδου βαθμίδας (Gradient Boosting). Η τελευταία πρόκειται για μια αρκετά χρησιμοποιούμενη μέθοδο μηχανικής μάθησης και απαντάται συχνά σε αλγορίθμους που υιοθετούν δέντρα, για να προβαίνουν σε προβλέψεις. Η τεχνική της καθόδου βαθμίδας εμπίπτει στην κατηγορία της μάθησης συνόλου (Ensemble Learning), η οποία συνδυάζει ασθενέστερα μοντέλα δέντρων απόφασης (Weak Learners) για τη δημιουργία ενός ισχυρού δέντρου απόφασης (Strong Learner). Κάθε δέντρο κατασκευάζεται το ένα μετά το άλλο. Η ιδιαιτερότητα της μεθόδου είναι ότι κάθε επόμενο δέντρο απόφασης που

δημιουργείται προσπαθεί να μειώσει το σφάλμα του προηγούμενου. Η τελική πρόβλεψη που θα προκύψει, αποτελεί το άθροισμα όλων των προβλέψεων όλων των δέντρων.

Ο αλγόριθμος XGBoost είναι μια βελτιωμένη έκδοση αυτής της μεθόδου και έχει χρησιμοποιηθεί από πολλούς ερευνητές λόγω των εντυπωσιακών επιδόσεών του. Επιπρόσθετα, το μοντέλο συνδυάζεται με ένα πλήθος υπερπαραμέτρων που πρέπει να οριστούν από τον ερευνητή κατά την αρχικοποίησή του. Οι υπερπαραμέτροι αυτοί χρησιμοποιούνται για την βελτιστοποίηση των προβλέψεων και την αποφυγή της υπερεκπαίδευσης (Overfitting). Στην έρευνα που έχουμε κάνει, χρησιμοποιούνται πέντε υπερπαραμέτροι, οι **gamma**, **alpha**, **max\_depth**, **n\_estimators** και **learning\_rate**.

1. υπερπαραμέτρος gamma: βοηθάει το μοντέλο να αποφεύγει την υπερεκπαίδευση. Καθώς δημιουργούνται ασθενέστερα δέντρα, τα δεδομένα που αναπαρίστανται σε αυτά αποθηκεύονται σε κόμβους και κλαδιά. Το δέντρο μπορεί τελικά να φτάσει σε ένα μεγάλο βάθος (το βάθος ή τα επίπεδα που μπορεί να έχει το δέντρο επιλέγονται από τον προγραμματιστή). Όσο πιο βαθύ είναι το δέντρο, τόσο περισσότερο έχει εντρυφήσει το συγκεκριμένο δέντρο στο σύνολο εκπαίδευσης, οδηγώντας το σε υπερεκπαίδευση. Η υπερπαραμέτρος αυτή χρησιμοποιείται για να «κλαδεύει» (pruning) τα δέντρα απόφασης ώστε να μειωθεί το βάθος τους και να αποφευχθεί η υπερεκπαίδευση.
2. υπερπαραμέτρος alpha: προσθέτει έναν επιπλέον όρο στην συνάρτηση σφάλματος που χρησιμοποιείται κατά την εκπαίδευση. Ανάλογα με την τιμή του alpha, το μοντέλο γίνεται πιο αυστηρό ή ανεκτό σε σφάλματα, επηρεάζοντας ανάλογα και τις τιμές των παραμέτρων κατά την φάση της εκπαίδευσης. Τελικά, αυτός ο επιπλέον όρος ελέγχει την πολυπλοκότητα των δέντρων που δημιουργούνται και αποτρέπει την υπερεκπαίδευση.
3. υπερπαραμέτρος n\_estimators: καθορίζει τον τελικό αριθμό των δέντρων που θα δημιουργηθούν. Όσο περισσότερα δέντρα προστίθενται, τόσο πιο πολύπλοκο γίνεται το μοντέλο, ενέχοντας τον κίνδυνο της υπερεκπαίδευσης. Η εύρεση της κατάλληλης τιμής της υπερπαραμέτρου αυτής είναι σημαντική για την ισορροπία μεταξύ απόδοσης του μοντέλου και χρόνου εκπαίδευσης.
4. υπερπαραμέτρος max\_depth: ορίζει το μέγιστο βάθος που μπορεί να έχει ένα δέντρο. Ένα βαθύ δέντρο μπορεί να προσδιορίσει σύνθετες σχέσεις στα δεδομένα, αλλά συνήθως οδηγεί σε υπερεκπαίδευση. Η σωστή τιμή για το max\_depth βοηθά στο να δημιουργηθούν δέντρα που γενικεύουν καλά τα δεδομένα.
5. υπερπαραμέτρος learning\_rate: ελέγχει το βήμα, με το οποίο το μοντέλο προσαρμόζεται στα δεδομένα εκπαίδευσης.

### 1.3.2 Το μοντέλο Long Short Term Memory

Το μοντέλο Long Short-Term Memory ή LSTM ανήκει στην κατηγορία των αναδρομικών νευρωνικών δικτύων (Recurrent Neural Networks - RNN). Επομένως, πρόκειται για έναν αλγόριθμο βαθιάς μάθησης [3]. Συγκεκριμένα, αυτό το μοντέλο ειδικεύεται στην επεξεργασία και την πρόβλεψη δεδομένων, όπου ο χρόνος είναι παρών.

Το νευρωνικό αυτό δίκτυο περιλαμβάνει τις ακόλουθες βελτιστοποιήσεις, για να προβαίνει σε προβλέψεις:

- **κύτταρα μνήμης (Memory Cells):** το κύριο στοιχείο ενός LSTM είναι τα κύτταρα μνήμης, τα οποία είναι σε θέση να αποθηκεύουν πληροφορίες για μακροπρόθεσμα και βραχυπρόθεσμα χρονικά γεγονότα. Αυτά τα κύτταρα μπορούν να διατηρούν, να ενημερώνουν και να διαγράφουν πληροφορίες που επεξεργάζεται ο αλγόριθμος.
- **πύλες (Gates):** οι πύλες στα LSTM είναι υπεύθυνες για τον έλεγχο της ροής των πληροφοριών μέσα στα κύτταρα μνήμης. Υπάρχουν τρεις κύριες πύλες στο μοντέλο LSTM:
  - **πύλη εισόδου (Input Gate):** αποφασίζει ποιες πληροφορίες που έχουν δοθεί ως είσοδο θα εισαχθούν, τελικά, στα κύτταρα μνήμης.
  - **πύλη εξόδου (Output Gate):** αποφασίζει ποιες πληροφορίες από τα κύτταρα μνήμης θα δοθούν στην έξοδο του δικτύου.

- ο πύλη λησμόνησης (Forget Gate): αποφασίζει ποιες πληροφορίες στα κύτταρα μνήμης θα διαγραφούν ή θα ξεχαστούν.

Κατά την φάση της εκπαίδευσης του αλγορίθμου, το LSTM μοντέλο μαθαίνει να προσαρμόζει διάφορες εσωτερικές παραμέτρους που διαθέτει προκειμένου να επεξεργάζεται αποτελεσματικά τα χρονοσειριακά δεδομένα.

Άξιο παρατήρησης είναι ότι οι εφαρμογές των LSTM είναι πολλές σήμερα. Αυτές συμπεριλαμβάνουν προβλέψεις της καθημερινότητας όπως: η πρόβλεψη των τιμών των μετοχών μίας εταιρείας, η αναγνώριση φωνής, η μετάφραση κειμένου, η πρόβλεψη του καιρού κ.α.

### 1.3.3 Το Μοντέλο Encoder - Decoder

Ένα μοντέλο κωδικοποιητή - αποκωδικοποιητή (Encoder-Decoder model) βασίζεται είτε στη χρήση LSTM μονάδων ή άλλων αντίστοιχων αρχιτεκτονικών όπως GRU (Gated Recurrent Unit) μονάδων για την επίλυση διαφόρων προβλημάτων, όπως η μετάφραση, η σύνθεση κειμένου, η αναγνώριση προτύπων, κ.α. [4]. Στην πτυχιακή έρευνα συνδυάζουμε το μοντέλο αυτό με τα νευρωνικά δίκτυα LSTM. Τα δομικά στοιχεία ενός μοντέλου κωδικοποιητή - αποκωδικοποιητή είναι τα επόμενα:

- **τμήμα Encoder:** ο κωδικοποιητής αποδέχεται μία είσοδο στη μορφή ακολουθίας (π.χ., κείμενο σε φυσική γλώσσα). Κάθε τμήμα της εισόδου εισέρχεται στο τμήμα LSTM του κωδικοποιητή ένα προς ένα. Μετά την είσοδο, και αφού κάθε τμήμα διατρέξει την μονάδα LSTM, το μοντέλο κωδικοποιητή-αποκωδικοποιητή διατηρεί μια εσωτερική κατάσταση (Internal State) που περιέχει την πληροφορία από την είσοδο σε κωδικοποιημένη μορφή.
- **τμήμα Decoder:** ο αποκωδικοποιητής δέχεται την έξοδο του κωδικοποιητή ως είσοδο και ξεκινά τη διαδικασία παραγωγής της έξοδου του μοντέλου. Στον αποκωδικοποιητή γίνονται οι τελικές προβλέψεις του μοντέλου βασιζόμενες στην είσοδο που δίνεται κάθε φορά σε αυτόν.

Κατά την φάση της εκπαίδευσης, το μοντέλο χρησιμοποιεί ένα σύνολο ζευγαριών εισόδου-εξόδου για να προσαρμόσει τα βάρη του κωδικοποιητή και του αποκωδικοποιητή. Τόσο ο κωδικοποιητής, όσο και ο αποκωδικοποιητής είναι ένα μοντέλο LSTM ή GRU. Ουσιαστικά, το μοντέλο στο σύνολό του συνδυάζει δίκτυα LSTM ή GRU και μία εσωτερική κατάσταση, για να προβλέψει σε προβλέψεις.

### 1.3.4 Το Μοντέλο Random Forest

Ο αλγόριθμος Random Forest [5] που χρησιμοποιείται στην πτυχιακή εργασία, είναι ένας αλγόριθμος μηχανικής μάθησης και ανήκει στην κατηγορία των μοντέλων συνόλου (Ensemble Model).

Το κύριο συστατικό αυτού του μοντέλου είναι το δέντρο απόφασης, δηλαδή μία δομή δεδομένων που έχει την μορφή δέντρου. Ένα δέντρο απόφασης αποτελείται από κόμβους, οι οποίοι έχουν τον ρόλο είτε της ρίζας (Root Node) του δέντρου, είτε τον ρόλο του ενδιάμεσου κόμβου (Internal Node), είτε τον ρόλο του φύλλου (Leaf Node). Ο λόγος, για τον οποίο η δομή αυτή ονομάζεται δέντρο απόφασης είναι ότι κάθε φορά που προσπαθεί το μοντέλο να κάνει προβλέψεις, διατρέπει ένα συγκεκριμένο μονοπάτι από την ρίζα του δέντρου μέχρι να φτάσει σε ένα φύλλο του δέντρου. Το μονοπάτι που ακολουθείται δεν είναι το ίδιο κάθε φορά, αλλά εξαρτάται άμεσα από τις πληροφορίες που δίνονται ως είσοδος, βάσει των οποίων θα γίνουν και οι προβλέψεις. Στα δέντρα απόφασης αποθηκεύονται δεδομένα, τα οποία είναι σχετικά με αυτά που δίνονται ως είσοδος στον αλγόριθμό.

Κατά την εκπαίδευση του αλγορίθμου αυτού, στόχος είναι να δημιουργηθεί ένας αριθμός από διαφορετικά δέντρα απόφασης, η δομή των οποίων θα είναι βέλτιστη (για παράδειγμα το βάθος του δέντρου, ο αριθμός των φύλλων, τα δεδομένα που θα περιέχει κ.α.). Τα δέντρα που δημιουργούνται στο τέλος, περιγράφουν με τον καλύτερο δυνατό τρόπο το σύνολο δεδομένων εκπαίδευσης. Ο αριθμός των δέντρων που φτιάχνεται προσδιορίζεται από τον χρήστη.

Αφού γίνει η εκπαίδευση του μοντέλου, ο αλγόριθμος προβαίνει σε προβλέψεις με βάση τα δεδομένα ελέγχου. Κάθε φορά που χρειάζεται να γίνεται μία πρόβλεψη, ο αλγόριθμος διατρέχει το μονοπάτι όλων των δέντρων που έχουν δημιουργηθεί από την ρίζα έως ένα φύλλο του εκάστοτε δέντρου. Η τιμή που βρίσκεται στο φύλλο κάθε δέντρου είναι και η απόφαση - πρόβλεψη - του συγκεκριμένου δέντρου. Η τελική πρόβλεψη του μοντέλου είναι ο μέσος όρος των τιμών των αποφάσεων όλων των δέντρων.

Γενικά, ο Random Forest χρησιμοποιείται σε πολλές εφαρμογές της καθημερινότητας, όπως η ταξινόμηση δεδομένων (π.χ. ανίχνευση ενοχλητικών email), η πρόβλεψη αριθμητικών τιμών (π.χ. πρόβλεψη τιμών ακινήτων), η ανίχνευση ανωμαλιών (π.χ. ανίχνευση απάτης σε χρεωστικές κάρτες). Μάλιστα, θεωρείται ένας ισχυρός και αξιόπιστος αλγόριθμος. Βέβαια, η ικανότητά του μοντέλου αυτού εξαρτάται σε μεγάλο βαθμό από τα δεδομένα που του δίνονται ως είσοδο.

## 2. Σχετικές Εργασίες

Σε αυτό το κεφάλαιο παρατίθενται έξι σχετικές εργασίες που έχουν υλοποιηθεί από άλλους ερευνητές χρησιμοποιώντας μοντέλα μηχανικής και βαθιάς μάθησης. Στις έρευνες αυτές, το πρόβλημα προς επίλυση είναι παρόμοιο με αυτό που επιλύουμε. Ο τρόπος με τον οποίο ορίζεται η έννοια της κυκλοφοριακής ροής στις επόμενες έρευνες είναι ανάλογος με τον τρόπο που ορίζεται το μέγεθος αυτό στην παρούσα πτυχιακή εργασία.

Στατιστικά μιλώντας, οι περισσότεροι επιστήμονες υιοθετούν LSTM, απλά νευρωνικά δίκτυα και στατιστικά μοντέλα, όπως τα ARIMA και SARIMA, προκειμένου να επιλύσουν το πρόβλημα που έχουν αναλάβει. Για κάθε σχετική έρευνα που αναφέρεται, προσδιορίζονται το μοντέλο που χρησιμοποιήθηκε και τα δεδομένα τα οποία δόθηκαν ως είσοδο σε αυτό.

### 2.1 Επίλυση του Προβλήματος με ένα Μοντέλο Long Short-Term Memory

Η πρώτη μελέτη που παραθέτουμε εξετάζει τη σημασία της βραχυπρόθεσμης πρόβλεψης της ροής της κυκλοφορίας στις ευφυείς μεταφορές (Intelligent Transport – IT) και την εφαρμογή της στη διαχείριση της κυκλοφοριακής συμφόρησης, τη μείωση της ρύπανσης και την ενίσχυση της οδικής ασφάλειας [6]. Επιπροσθέτως, επισημαίνονται και οι προκλήσεις που σχετίζονται με την ακριβή πρόβλεψη της έντονα μη γραμμικής και στοχαστικής φύσης της ροής κυκλοφορίας. Αυτό οφείλεται σε ποικίλους παράγοντες, όπως οι μεταβαλλόμενες καιρικές συνθήκες και η μορφολογία του εδάφους, οι οποίοι έχουν αντίκτυπο στη ροή κυκλοφορίας. Στόχος είναι η πρόβλεψη της κυκλοφοριακής ροής σε ένα συγκεκριμένο χρονικό διάστημα με βάση ιστορικά δεδομένα που καταγράφονται σε διαστήματα των 15 λεπτών.

Στο πλαίσιο της παρούσας εργασίας, η κυκλοφοριακή ροή αναφέρεται στον όγκο των οχημάτων που διέρχονται από ένα συγκεκριμένο σταθμό παρατήρησης, τοποθετημένος σε έναν αυτοκινητόδρομο. Η ροή αυτή μετρείται σε διαστήματα των 15 λεπτών. Η εργασία έχει ως στόχο να προβλέψει την βραχυπρόθεσμη κυκλοφοριακή ροή με ακρίβεια, ώστε να παρέχει έγκαιρες και πολύτιμες πληροφορίες για ενδιαφερόμενους, συμπεριλαμβανομένων των ταξιδιωτών, των επιχειρήσεων και των κυβερνητικών υπηρεσιών.

Στην έρευνα αυτή χρησιμοποιείται το μοντέλο Long Short-Term Memory για την βραχυπρόθεσμη πρόβλεψη της ροής της κυκλοφορίας. Το LSTM είναι ένας τύπος νευρωνικού δικτύου κατάλληλος για εργασίες πρόβλεψης χρονοσειρών. Για την εκτέλεση της πρόβλεψης, το μοντέλο LSTM λαμβάνει ως είσοδο προηγούμενα δεδομένα ροής κυκλοφορίας, τα οποία περιλαμβάνουν πληροφορίες σχετικές με προηγούμενους όγκους κίνησης (π.χ. τα τελευταία 30 λεπτά).

Έπειτα, το μοντέλο μαθαίνει τα μοτίβα και τις εξαρτήσεις που υπάρχουν στα ιστορικά δεδομένα, για να προβλέψει τη ροή κυκλοφορίας για το επόμενο διάστημα των 15 λεπτών. Η αρχιτεκτονική LSTM περιλαμβάνει μπλοκ μνήμης που επιτρέπει στο δίκτυο να συλλαμβάνει και να αποθηκεύει πληροφορίες για μεγαλύτερες χρονικές περιόδους, αντιμετωπίζοντας την πρόκληση των χρονικών εξαρτήσεων στη ροή της κυκλοφορίας. Σε αντίθεση με τα παραδοσιακά μοντέλα νευρωνικών δικτύων, το LSTM προσδιορίζει δυναμικά τις βέλτιστες χρονικές καθυστερήσεις και τις ενσωματώνει στη διαδικασία πρόβλεψης.

Όσον αφορά την διαδικασία εκπαίδευσης του μοντέλου, χρησιμοποιείται το σύνολο δεδομένων (Dataset) Caltrans Performance Measurement System (PeMS), το οποίο παρέχει στον ερευνητή έναν μεγάλο αριθμό ιστορικών δεδομένων κυκλοφοριακής ροής.

Η απόδοση του μοντέλου αξιολογείται και σε σύγκριση με άλλα μοντέλα, όπως το Random Walk (RW), τον αλγόριθμο Support Vector Machine (SVM) και τα Feed Forward Neural Networks (FFNN). Τα αποτελέσματα δείχνουν την υπεροχή του μοντέλου LSTM, όσον αφορά την ακρίβεια πρόβλεψης και τις δυνατότητες γενίκευσης σε άλλα σύνολα δεδομένων (π.χ. τα δεδομένα ελέγχου). Το LSTM υπερτερεί έναντι άλλων μοντέλων στην αποτύπωση των μη γραμμικών και στοχαστικών χαρακτηριστικών της ροής κυκλοφορίας.

## 2.2 Πρόβλεψη με Απλά Νευρωνικά Δίκτυα

Στην δεύτερη εργασία που παραθέτουμε, ως ροή κυκλοφορίας ορίζεται η κίνηση των οχημάτων εντός ενός οδικού δικτύου ή ενός συγκεκριμένου τμήματος μίας οδού σε μία δεδομένη χρονική στιγμή. Οι συγγραφείς αναφέρουν ότι η ακριβής πρόβλεψη της κυκλοφοριακής ροής είναι ζωτικής σημασίας στα Ευφυή Συστήματα Μεταφορών - ΕΣΜ (Intelligent Transport Systems - ITS) για την αποτελεσματική μείωση της κυκλοφοριακής συμφόρησης. Οι επιστήμονες έχουν σαν βασικό στόχο την εκτίμηση του όγκου και της ταχύτητας των οχημάτων στο δρόμο για τη διευκόλυνση της αποτελεσματικής διαχείρισης της κυκλοφορίας [7].

Το μοντέλο που προτείνεται στην παρούσα εργασία για την πρόβλεψη της κυκλοφοριακής ροής είναι ένα μοντέλο SDLTFP (Supervised Deep Learning Based Traffic Flow Prediction), το οποίο είναι ένας τύπος πλήρως συνδεδεμένου νευρωνικού δικτύου (Fully Connected Deep Neural Network - FCDNN). Το μοντέλο SDLTFP λαμβάνει ιστορικά δεδομένα κυκλοφορίας ως είσοδο και προσπαθεί να προβλέψει την μελλοντική κυκλοφοριακή ροή, δηλαδή τον εκτιμώμενο όγκο των οχημάτων σε μια δεδομένη χρονική στιγμή στο μέλλον.

Στην εργασία οι συγγραφείς εφαρμόζουν διάφορες τεχνικές βελτιστοποίησης, για να αναβαθμίσουν την απόδοση του μοντέλου. Αυτές οι τεχνικές περιλαμβάνουν την κανονικοποίηση δέσμης (Batch Normalization - BN) και την εισαγωγή των επιπέδων αγνόησης (Dropout Layers). Ο συνδυασμός αυτών των δύο μεθόδων συμβάλλει στην ευκολία γενίκευσης του μοντέλου και την αποφυγή της υπερεκπαίδευσης.

Όσον αφορά τα αποτελέσματα, αναφέρεται ότι το μοντέλο SDLTFP επιτυγχάνει μέσο απόλυτο ποσοστιαίο σφάλμα (Mean Absolute Percentage Error - MAPE) 5% στα δεδομένα εκπαίδευσης. Για τα δεδομένα ελέγχου, ο προτεινόμενος αλγόριθμος καταφέρνει για την ίδια μετρική ένα σφάλμα μεταξύ 15% έως 20%. Τα αποτελέσματα αυτά δείχνουν ότι το μοντέλο αποδίδει καλά στην πρόβλεψη της ροής κυκλοφορίας, παρουσιάζοντας σχετικά χαμηλά σφάλματα πρόβλεψης.

## 2.3 Μοντέλο Αποτελούμενο από Κωδικοποιητές και Αποκωδικοποιητές

Σε αυτή την τρίτη έρευνα που συμπεριλαμβάνουμε, η ροή κυκλοφορίας αναφέρεται στην κίνηση των οχημάτων σε δίκτυα μεταφορών, όπως οι δρόμοι ή οι αυτοκινητόδρομοι [4]. Συγκεκριμένα, η τελευταία ορίζεται ως την ποσότητα των οχημάτων που διέρχονται από μια συγκεκριμένη τοποθεσία σε διαφορετικά χρονικά διαστήματα. Η παρατηρούμενη ποσότητα ροής κυκλοφορίας, η οποία συμβολίζεται ως  $X_{t,i}$ , αντιπροσωπεύει τον όγκο κυκλοφορίας που μετρήθηκε στην  $i$ -οστή θέση παρατήρησης κατά τη διάρκεια του  $t$ -οστού χρονικού διαστήματος.

Η πρόβλεψη της κυκλοφοριακής ροής αποσκοπεί στην παροχή ακριβών και έγκαιρων πληροφοριών σχετικά με τις αναμενόμενες συνθήκες κυκλοφορίας, οι οποίες είναι ζωτικής σημασίας για τη διαχείριση των μεταφορών, για τα ευφυή συστήματα μεταφορών και για διάφορες εφαρμογές που στοχεύουν στον έλεγχο και τη βελτιστοποίηση της κυκλοφορίας.

Η μεθοδολογία που χρησιμοποιείται στην παρούσα εργασία περιλαμβάνει την εφαρμογή ενός μοντέλου στοιβαγμένου κωδικοποιητή - αποκωδικοποιητή (Stacked Autoencoder - SAE), ο οποίος αποτελεί μία αρχιτεκτονική βαθιάς μάθησης. Το μοντέλο SAE εκπαιδεύεται με τη χρήση του συνόλου δεδομένων PeMS της Caltrans που περιέχει πληροφορίες για την κίνηση και την κατάσταση των οδικών δικτύων σε διάφορες περιοχές της Καλιφόρνιας. Τα βήματα της μεθοδολογίας που ακολουθούνται από τους συντάκτες της έρευνας είναι τα ακόλουθα:

1. **συλλογή δεδομένων:** τα δεδομένα κυκλοφοριακής ροής συλλέγονται από τη βάση δεδομένων PeMS της Caltrans.
2. **προεπεξεργασία:** τα δεδομένα υποβάλλονται σε προεπεξεργασία για την απομάκρυνση τυχόν ακραίων τιμών ή ασυνεπειών σε αυτά. Στη συνέχεια, χωρίζονται σε σύνολα εκπαίδευσης και ελέγχου για την αξιολόγηση του μοντέλου.
3. **σχεδίαση του μοντέλου:** το μοντέλο SAE αποτελείται από πολλαπλά στρώματα autoencoder. Ο autoencoder θεωρείται τύπος νευρωνικού δικτύου βαθιάς μάθησης. Αποτελείται από έναν κωδικοποιητή και έναν αποκωδικοποιητή. Ο κωδικοποιητής συμπιέζει τα δεδομένα εισόδου σε μια αναπαράσταση χαμηλότερης διάστασης, ενώ ο αποκωδικοποιητής ανακατασκευάζει τα αρχικά δεδομένα από αυτή την αναπαράσταση.



Το μοντέλο SAE χρησιμοποιεί τους autoencoders ως δομικά στοιχεία για τη δημιουργία ενός βαθιού δικτύου.

4. **εκπαίδευση και αξιολόγηση:** το μοντέλο SAE εκπαιδεύεται στα δεδομένα εκπαίδευσης. Έπειτα, η απόδοση του μοντέλου SAE αξιολογείται με τη χρήση διαφόρων μετρικών, όπως το μέσο απόλυτο σφάλμα (Mean Absolute Error - MAE) στα δεδομένα ελέγχου.

Η απόδοση του μοντέλου συγκρίνεται και με άλλα μοντέλα που χρησιμοποιούνται για τον ίδιο σκοπό, συμπεριλαμβανομένων των αλγορίθμων Support Vector Machine, Random Walk και Radial Basis Function Neural Network (RBF NN). Τελικά, η απόδοση του προτεινόμενου μοντέλου είναι ανώτερη από αυτές των υπολοίπων. Όμως, αξίζει να σημειωθεί ότι το μοντέλο δυσκολεύεται να αποδώσει καλά όταν η κυκλοφοριακή ροή βρίσκεται σε χαμηλά επίπεδα, ενώ για υψηλότερους όγκους κυκλοφοριακής ροής το μοντέλο αποδίδει ικανοποιητικά.

## 2.4 Πρόβλεψη Κυκλοφοριακής Ροής με το Μοντέλο Deep Crowd

Το πρόβλημα που προσπαθεί να λύσει η παρούσα έρευνα είναι η πρόβλεψη της κυκλοφοριακής ροής. Συγκεκριμένα, οι επιστήμονες προσπαθούν να προβλέψουν αφενός τον αριθμό των ΚΑ που θα βρίσκονται σε κάθε θέση μίας πόλης την επόμενη χρονική στιγμή (το ονομάζουν πρόβλεψη πληθυσμιακής πυκνότητας), αφετέρου, προσπαθούν να εκτιμήσουν πόσα ΚΑ θα φύγουν από μία συγκεκριμένη θέση και θα επισκεφτούν μία άλλη στην επόμενη χρονική στιγμή (το ονομάζουν ροή εισόδου-εξόδου) [8].

Προκειμένου να παρουσιάσουν μία καινοτόμα ιδέα, οι επιστήμονες προτείνουν μια λύση που περιλαμβάνει τη διαίρεση μιας μεγάλης αστικής περιοχής σε μικρά πλέγματα. Κάθε πλέγμα αναπαριστά μία θέση.

Επιπρόσθετα, οι συγγραφείς προτείνουν ένα μοντέλο βαθιάς μάθησης που ονομάζεται «DeepCrowd». Το τελευταίο βασίζεται σε μία πυραμιδική αρχιτεκτονική αποτελούμενη από συνελκτικά νευρωνικά δίκτυα με βραχυπρόθεσμη και μακροπρόθεσμη μνήμη (Convolutional LSTM) και μηχανισμούς προσοχής υψηλής διάστασης (High-Dimensional Attention Mechanisms - HDAM). Τα Convolutional LSTM μπορούν να διαχειριστούν πολυδιάστατα δεδομένα, ενώ ο πυραμιδικός σχεδιασμός αξιοποιεί καλύτερα χαμηλής ή/και υψηλής ποιότητας χαρακτηριστικά.

Η αναπαράσταση της κυκλοφοριακής ροής σε όλη την πόλη γίνεται με την μορφή μίας τετραδιάστατης μήτρας. Οι τέσσερις διαστάσεις της είναι ο χρόνος, το ύψος, το πλάτος και το κανάλι. Το κανάλι λαμβάνει δύο τιμές, ανάλογα με το είδος της πρόβλεψης που γίνεται σε κάθε περίπτωση. Τα δύο είδη πρόβλεψης που μελετώνται στην έρευνα αυτή αναφέρθηκαν παραπάνω.

Αξιοπρόσχετο είναι το γεγονός ότι για την διεκπεραίωση της μελέτης, οι επιστήμονες κατάφεραν να δημιουργήσουν ένα δικό τους σύνολο δεδομένων. Η εργασία χρησιμοποιεί δεδομένα μεγάλης κλίμακας αποτελούμενα από καταγραφές GPS σημείων σε πραγματικό χρόνο με την βοήθεια μίας εφαρμογής κινητού. Αυτό το σύνολο δεδομένων προσφέρει πλεονεκτήματα σε σχέση με τα ήδη υπάρχοντα, επειδή καλύπτεται το εύρος μιας μεγάλης περιοχής και υπάρχουν καταγραφές από πολλούς χρήστες.

Για την αξιολόγηση των επιδόσεων του «DeepCrowd», οι συγγραφείς διεξάγουν ενδελεχή πειράματα και συγκρίνουν τα αποτελέσματά τους με άλλες σύγχρονες μεθόδους. Τέσσερις μετρικές, οι Mean Square Error (MSE), Root Mean Square Error (RMSE), Mean Absolute Error (MAE) και Mean Absolute Percentage Error (MAPE) χρησιμοποιούνται για την αξιολόγηση. Τα αποτελέσματα των πειραμάτων αποδεικνύουν την αποτελεσματικότητα και την αποδοτικότητα του προτεινόμενου μοντέλου για την πρόβλεψη της κυκλοφοριακής ροής σε δύο μεγάλες πόλεις της Ιαπωνίας, το Τόκιο και την Οσάκα.

Συμπεραίνοντας, με την χρήση ενός ισχυρού μοντέλου, όπως το προτεινόμενο, οι συγγραφείς είναι σε θέση να συλλάβουν και να αναλύσουν τις χωροχρονικές πτυχές της κινητικότητας στην πόλη και να ανακαλύψουν μοτίβα στον τομέα της κυκλοφορίας.

## 2.5 Χρήση Γραφημάτων και Νευρωνικών Δικτύων

Στην επόμενη εργασία, οι συγγραφείς ορίζουν τη κυκλοφοριακή ροή ως τον αριθμό των οχημάτων που διέρχονται από μια συγκεκριμένη τοποθεσία ή περιοχή κατά τη διάρκεια μιας χρονικής περιόδου. Το κύριο πρόβλημα προς επίλυση είναι η πρόβλεψη της κυκλοφοριακής ροής και της

ταχύτητας των οχημάτων στο μέλλον. Το πρόβλημα αυτό ανάγεται σε χρονοσειρά. Στόχος είναι η πρόβλεψη των τιμών της με βάση διάφορα ιστορικά δεδομένα. Τέλος, λαμβάνονται υπόψη οι παράγοντες που επηρεάζουν τη κυκλοφοριακή ροή και την ταχύτητα, όπως είναι ο χρόνος, ο χώρος, οι καιρικές συνθήκες και οι δραστηριότητες (π.χ. εορτές), προκειμένου να αναπτυχθεί ένα μοντέλο που θα είναι όσο το δυνατόν ακριβέστερο [9].

Το προτεινόμενο μοντέλο που αναπτύσσεται στην παρούσα μελέτη ονομάζεται Graph Hierarchical Convolutional Recurrent Neural Network (GHCRNN). Αυτό το μοντέλο έχει σχεδιαστεί για την πρόβλεψη της κυκλοφοριακής ροής και της ταχύτητας των οχημάτων σε αστικές περιοχές. Επίσης, ενσωματώνει τόσο χωρικές όσο και ιεραρχικές πληροφορίες για τη βελτίωση της ακρίβειας πρόβλεψης. Ακολουθεί μια περιγραφή του τρόπου λειτουργίας του αλγορίθμου:

1. **ακολουθίες εισόδου και εξόδου:** το μοντέλο GHCRNN λαμβάνει ως είσοδο ιστορικά δεδομένα χρονοσειρών. Αυτό περιλαμβάνει πληροφορίες σχετικά με τη ροή και την ταχύτητα των οχημάτων κατά τη διάρκεια μιας χρονικής περιόδου. Το μοντέλο προβλέπει τη κυκλοφοριακή ροή και την ταχύτητα σε μία καθορισμένη χρονική στιγμή στο μέλλον και την παραδίδει ως έξοδο.
2. **συνελικτικά επίπεδα (convolutional layers):** το νευρωνικό δίκτυο περιλαμβάνει συνελικτικές μονάδες (Conv0 και Conv1) για την εξαγωγή χωρικών πληροφοριών από το οδικό δίκτυο. Αυτά τα συνελικτικά στρώματα αναλύουν τις σχέσεις και τα μοτίβα μεταξύ διαφορετικών θέσεων στο δίκτυο.
3. **μονάδα οργάνωσης (pooling units):** οι μονάδες αυτές (Pooling0 και Pooling1) χρησιμοποιούνται για την αποτύπωση της ιεραρχικής δομής του οδικού δικτύου. Η λειτουργία αυτή βοηθά στην εξαγωγή ιεραρχικών πληροφοριών, στην εξάλειψη περιττών γνώσεων και στη μείωση της πολυπλοκότητας των δεδομένων.
4. **επίπεδο κωδικοποιητή – αποκωδικοποιητή:** η συνολική αρχιτεκτονική του GHCRNN χρησιμοποιεί ένα δίκτυο (Sequence to Sequence - Seq2Seq) που βασίζεται σε ένα μοντέλο κωδικοποιητή – αποκωδικοποιητή. Τα ιστορικά δεδομένα τροφοδοτούνται στον κωδικοποιητή, ο οποίος παράγει ενδιάμεσα κωδικοποιημένα αποτελέσματα (State0 και State1). Αυτά τα αποτελέσματα χρησιμεύουν ως είσοδος για τον αποκωδικοποιητή, ο οποίος ολοκληρώνει τη διαδικασία της πρόβλεψης.
5. **μονάδες GHCRNN:** τα επίπεδα κωδικοποιητών και αποκωδικοποιητών περιέχουν πολλαπλές μονάδες GHCRNN, επιτρέποντας στο μοντέλο να χειρίζεται τις ακολουθίες εισόδου και εξόδου. Κάθε μονάδα GHCRNN ενσωματώνει μονάδες Gated Recurrent Unit (GRU). Αυτό επιτρέπει στο μοντέλο να συλλαμβάνει τόσο μακροπρόθεσμες, όσο και βραχυπρόθεσμες πληροφορίες.
6. **συνέλιξη γράφων και διαδικασία οργάνωσης (convolution of graphs and pooling):** σε κάθε μονάδα GHCRNN ενσωματώνονται λειτουργίες συνέλιξης και pooling για την εξαγωγή χωρικών και ιεραρχικών πληροφοριών. Αυτές οι λειτουργίες βρίσκουν τις σχέσεις μεταξύ των κόμβων του οδικού δικτύου και αποτυπώνουν τις ομοιότητες ή τις διαφορές στα χαρακτηριστικά και τις δομές τους.

Το σύνολο δεδομένων που χρησιμοποιείται στην παρούσα έρευνα είναι τα δεδομένα ταχύτητας του Los Angeles και αποτελείται από μετρήσεις των μέσων ταχυτήτων για διάφορους σταθμούς ανίχνευσης, οι οποίες συλλέγονται ανά χρονικά διαστήματα των πέντε λεπτών. Συνολικά επιλέχθηκαν 207 σταθμοί ανίχνευσης. Στο σύνολό τους, τα δεδομένα καλύπτουν ένα διάστημα τεσσάρων μηνών.

Στο πείραμα που έγινε, το γράφημα που χρησιμοποιείται αναπαρίσταται ως ένας πίνακας γειτνίασης που καθορίζει τη σχέση σύνδεσης μεταξύ των σταθμών ανίχνευσης στο οδικό δίκτυο. Δύο σταθμοί ανίχνευσης γειτνιάζουν αν υπάρχει άμεση ή έμμεση σύνδεση μεταξύ τους. Το βάρος που αποδίδεται στον πίνακα γειτνίασης καθορίζεται από τη σχέση απόστασης μεταξύ των δύο συνδεδεμένων σταθμών.

Επιπροσθέτως, οι συγγραφείς της έρευνας αναφέρουν ότι το μοντέλο μπορεί να εφαρμοστεί όχι μόνο σε δεδομένα κυκλοφορίας, αλλά και σε δεδομένα που διαθέτουν χρονικά και χωρικά χαρακτηριστικά. Το μοντέλο επιδεικνύει, επίσης, υψηλότερη ικανότητα και αποδοτικότητα κατά την επεξεργασία μεγάλων γράφων.

Συνοψίζοντας, το μοντέλο GHCRNN συνδυάζει την ισχύ των γραφημάτων, των συνελικτικών και αναδρομικών νευρωνικών δικτύων και των πράξεων pooling. Έτσι, παρέχει ακριβείς

προβλέψεις της κυκλοφοριακής ροής και της ταχύτητας των οχημάτων, λαμβάνοντας υπόψη τις χρονικές, χωρικές και ιεραρχικές πτυχές του προβλήματος.

## 2.6 Έρευνα Βασισμένη στον Αλγόριθμο XGBoost

Στην τελευταία εργασία που παραθέτουμε [10], ως ροή κυκλοφορίας ορίζεται η κίνηση των οχημάτων εντός μιας συγκεκριμένης λωρίδας κυκλοφορίας στο οδικό δίκτυο σε μια δεδομένη χρονική στιγμή. Η κυκλοφοριακή ροή μετρείται με βάση παραμέτρους, όπως ο αριθμός των διερχόμενων οχημάτων, ο μέσος όρος ταχύτητας και η πληρότητα (το ποσοστό του χρόνου κατά τον οποίο η λωρίδα είναι κατειλημμένη από οχήματα). Αυτές οι παράμετροι παρέχουν πληροφορίες σχετικά με τον όγκο και τα χαρακτηριστικά της κίνησης των οχημάτων και βοηθούν στην ανάλυση και την πρόβλεψη των μοτίβων κυκλοφορίας.

Μάλιστα, η έρευνα αυτή συνδυάζει την τεχνική της **αποσύνθεσης κυματιδίων** (Wavelet Decomposition - WD) και τον αλγόριθμο XGBoost, θέτοντας ως στόχο τη βραχυπρόθεσμη πρόβλεψη της κυκλοφοριακής ροής. Η αποσύνθεση κυματιδίων χρησιμοποιείται για την εξαγωγή επιπρόσθετης πληροφορίας από το προς πρόβλεψη χαρακτηριστικό, ενώ η ανακατασκευή του συνδυάζει τις πληροφορίες χαμηλής και υψηλής συχνότητας που παρήχθησαν για τη δημιουργία του τελικού χαρακτηριστικού που θα χρησιμοποιηθεί στα δεδομένα εκπαίδευσης του αλγορίθμου.

Στη συνέχεια, αφού τα δεδομένα χωριστούν σε σύνολα εκπαίδευσης (Training Set) και ελέγχου (Testing Set), ο αλγόριθμος XGBoost μαθαίνει τα μοτίβα και τις σχέσεις στα δεδομένα εκπαίδευσης. Έπειτα, χρησιμοποιούνται δύο μετρικές για την αξιολόγηση του προτεινόμενου μοντέλου στα δεδομένα ελέγχου, το μέσο τετραγωνικό σφάλμα και το μέσο απόλυτο ποσοστιαίο σφάλμα.

Οι προβλέψεις που παράγει το προτεινόμενο μοντέλο συγκρίνονται και με άλλες μεθόδους μηχανικής μάθησης, συμπεριλαμβανομένων των αλγορίθμων Support Vector Machine και XGBoost χωρίς την μέθοδο της αποσύνθεσης κυματιδίων. Τα αποτελέσματα δείχνουν ότι η προτεινόμενη μέθοδος επιτυγχάνει χαμηλότερα RMSE και MAPE σε σύγκριση με τα υπόλοιπα μοντέλα. Χαμηλότερες τιμές των δύο παραπάνω μετρικών δηλώνουν και καλύτερη επίδοση του μοντέλου.

### 3. Τεχνολογίες

Το συγκεκριμένο κεφάλαιο έχει δημιουργηθεί για να παραθέσει περισσότερες πληροφορίες σχετικά με τις τεχνολογίες που υιοθετήθηκαν για την διεκπεραίωση της παρούσας έρευνας. Πιο συγκεκριμένα, αναλύονται πληροφορίες για την γλώσσα προγραμματισμού Python που χρησιμοποιήθηκε. Αναφέρονται, επίσης, πληροφορίες για τα περιβάλλοντα εκτέλεσης του κώδικα, δηλαδή τα Jupyter Notebook και Google Colab. Περιγράφεται, επιπλέον, ο τρόπος λειτουργίας της βάσης δεδομένων PostgreSQL και της γλώσσας PL/pgSQL που αξιοποιήθηκαν στην έρευνα μόνο για συγκριτικούς σκοπούς. Τέλος, αναλύεται ο τρόπος λειτουργίας των λογισμικών Docker και Valhalla, η σύνθεση των οποίων κατέστη εφικτή την διαδικασία αντιστοίχισης των τροχιών των κινούμενων αντικειμένων επάνω στο οδικό δίκτυο.

#### 3.1 Η Γλώσσα Python

Η Python είναι μια γλώσσα προγραμματισμού υψηλού επιπέδου που δημιουργήθηκε από τον Guido van Rossum και πρωτοκυκλοφόρησε το 1991 [11]. Έχει κερδίσει ευρεία αναγνώριση χάρη στην απλή και ευανάγνωστη σύνταξή της, καθώς και στην ευελιξία και ισχυρή κοινότητα που την υποστηρίζει. Μερικά από τα βασικά χαρακτηριστικά της Python περιλαμβάνουν:

- **κατανοητή σύνταξη:** η Python χρησιμοποιεί απλή και ευανάγνωστη σύνταξη που διευκολύνει την ανάπτυξη και τη συντήρηση του κώδικα.
- **διερμηνευμένη φύση:** η διερμηνευμένη φύση της Python αναφέρεται στο γεγονός ότι ο κώδικας δεν χρειάζεται να μεταγλωττιστεί προκαταβολικά σε γλώσσα μηχανής πριν από την εκτέλεσή του. Αντί αυτού, ο κώδικας εκτελείται απευθείας από τον διερμηνέα της Python κατά τη διάρκεια της εκτέλεσης του προγράμματος.
- **δομημένη οργάνωση:** υποστηρίζεται η οργάνωση του κώδικα σε μονάδες, όπως οι συναρτήσεις και οι κλάσεις. Επομένως, η συγκεκριμένη γλώσσα συνδυάζει τα χαρακτηριστικά του διαδικαστικού και του αντικειμενοστραφούς προγραμματισμού.
- **δυναμική δήλωση τύπων:** δεν απαιτείται να δηλώνεται εξ αρχής ο τύπος μιας μεταβλητής, καθώς ο τελευταίος αναγνωρίζεται αυτόματα κατά την εκτέλεση του προγράμματος.
- **υποστήριξη από πολυάριθμες βιβλιοθήκες:** η Python παρέχει μια πλούσια συλλογή από ενσωματωμένες βιβλιοθήκες για διάφορες εργασίες που υποστηρίζουν από ανάλυση δεδομένων μέχρι γραφικά και σχεδίαση ιστοσελίδων.

Η Python υποστηρίζει επίσης πολλούς τύπους δεδομένων, όπως ακέραιους αριθμούς, πραγματικούς αριθμούς, σύνθετους αριθμούς, συμβολοσειρές, λίστες, πλειάδες και λεξικά. Κάθε τύπος χρησιμοποιείται σε διαφορετικές περιστάσεις. Οι τύποι αυτοί συχνά συνδυάζονται, για να δημιουργήσουν πολύπλοκες δομές και λειτουργίες στα προγράμμάτα.

Συνολικά, η Python είναι μια απλή και ισχυρή γλώσσα προγραμματισμού με πολλές δυνατότητες. Για αυτό τον λόγο, αποτελεί μια εξαιρετική επιλογή τόσο για αρχάριους, όσο και για προχωρημένους προγραμματιστές. Δεν είναι λοιπόν παράλογο το γεγονός ότι η συγκεκριμένη γλώσσα χρησιμοποιείται εκτεταμένα σε πολλούς τομείς, όπως είναι η ανάπτυξη λογισμικού, οι επιστημονικοί υπολογισμοί, η ανάλυση δεδομένων, η κατασκευή ιστοσελίδων, η τεχνητή νοημοσύνη και πολλοί άλλοι.

##### 3.1.1 Python και Επιστήμη Δεδομένων

Στην παρούσα έρευνα, εκμεταλλευόμαστε τη γλώσσα προγραμματισμού Python για την ανάλυση και επίλυση ενός προβλήματος που ανήκει στο πεδίο της μηχανικής μάθησης, δηλαδή την πρόβλεψη της κυκλοφοριακής ροής σε ένα οδικό δίκτυο με αλγορίθμους που εκπαιδεύονται από δεδομένα. Στο πλαίσιο της επιστήμης των δεδομένων, η Python αποτελεί ένα ευρέως χρησιμοποιούμενο εργαλείο, υποστηρίζοντας τις δραστηριότητες ανάλυσης, εξόρυξης και ερμηνείας δεδομένων, προκειμένου να αντληθούν πληροφορίες και γνώση από αυτά. Οι πιο συνήθεις τρόποι χρήσης της Python στο πεδίο της επιστήμης των δεδομένων περιλαμβάνουν:

- **ανάλυση και εξόρυξη δεδομένων:** η Python παρέχει βιβλιοθήκες, όπως η Pandas [12] και η Numerical Python (ή NumPy) [13] για την ανάλυση και τον χειρισμό των δεδομένων,

ενώ η βιβλιοθήκη Scikit-learn [14] προσφέρει μία ποικιλία από αλγορίθμους μηχανικής μάθησης προκειμένου να εξοριστεί γνώση από αυτά.

- **μηχανική μάθηση:** η Python αποτελεί συνήθως την πρώτη επιλογή για την ανάπτυξη μοντέλων μηχανικής μάθησης με τη χρήση βιβλιοθηκών όπως η Scikit-learn, το TensorFlow [15] και το Keras [16]. Αυτές οι βιβλιοθήκες επιτρέπουν τη δημιουργία μοντέλων πρόβλεψης, ταξινόμησης, συσταδοποίησης και πολλών άλλων.
- **οπτικοποίηση δεδομένων:** η Python παρέχει βιβλιοθήκες όπως η Matplotlib [17] και η Seaborn [18] για τη δημιουργία γραφημάτων που βοηθούν στην οπτικοποίηση (Visualization) των δεδομένων, ενισχύοντας την κατανόηση τους.

Επομένως, η ευελιξία της Python, μαζί με τις πλούσιες βιβλιοθήκες που προσφέρει, καθιστούν αυτήν τη γλώσσα ένα ισχυρό εργαλείο για την ανάλυση και την εξόρυξη δεδομένων. Μάλιστα, αυτό αποτέλεσε και το βασικό κίνητρο επιλογής της συγκεκριμένης γλώσσας στην έρευνά μας.

## 3.2 Jupyter Notebook και Google Colab

Όσον αφορά το προγραμματιστικό περιβάλλον που χρησιμοποιήθηκε, η παρούσα έρευνα που έχουμε διεξάγει έχει αναπτυχθεί κυρίως στα περιβάλλοντα του Jupyter Notebook και του Google Colab (ο όρος Colab προέρχεται από τη λέξη Collaboratory). Τόσο το Jupyter Notebook, όσο και το Google Colab αποτελούν δημοφιλή περιβάλλοντα προγραμματισμού, τα οποία χρησιμοποιούνται ευρέως για την ανάπτυξη και εκτέλεση κώδικα Python, καθώς και για την οπτικοποίηση και ανάλυση των δεδομένων. Επομένως, έχουν εξαιρετική απήχηση στον χώρο της επιστήμης των δεδομένων και της μηχανικής μάθησης.

### 3.2.1 Το Jupyter Notebook

Το Jupyter Notebook [19] αντιπροσωπεύει ένα περιβάλλον προγραμματισμού που επιτρέπει τη δημιουργία κώδικα Python και τον κοινό διαμοιρασμό εγγράφων που περιλαμβάνουν εκτελέσιμο κώδικα, κείμενο, εικόνες, γραφήματα και άλλα με άλλους χρήστες.

Αναλυτικότερα, το Jupyter Notebook, όταν εγκατασταθεί τοπικά, λειτουργεί σε έναν τοπικό διακομιστή. Κατά την εκτέλεσή του, το γραφικό περιβάλλον της εφαρμογής εμφανίζεται μέσω ενός προγράμματος περιήγησης σε μια προκαθορισμένη διεύθυνση IP, συνήθως στην <http://localhost:8888>. Επιπρόσθετα, το κλείσιμο του προγράμματος περιήγησης δεν συνεπάγεται και την αποσύνδεση από τον διακομιστή που φιλοξενεί το Jupyter Notebook.

Όσον αφορά την σχεδίαση του Jupyter Notebook, αυτό είναι οργανωμένο σε σημειωματάρια (Notebooks), όπως βέβαια δηλώνει και το όνομά του. Κάθε σημειωματάριο είναι οργανωμένο σε εκτελέσιμα κελιά. Ένα κελί μπορεί να περιλαμβάνει διάφορα είδη πληροφοριών, όπως κώδικα Python ή άλλους τύπους πληροφορίας, για παράδειγμα κείμενο. Οι χρήστες έχουν τη δυνατότητα να εκτελούν κάθε ένα αυτά τα κελιά, ξεχωριστά το ένα με το άλλο, και να παρατηρούν άμεσα τα αποτελέσματα. Το Jupyter Notebook αποτέλεσε το βασικό εργαλείο συγγραφής κώδικα κατά την διάρκεια της έρευνας, λόγω της ευχρηστότητάς του.

### 3.2.2 Το Google Colab

Το Google Colab [20] αντιπροσωπεύει μια υπηρεσία που προσφέρεται από την Google και λειτουργεί παρόμοια με το Jupyter Notebook. Η μόνη διαφορά είναι ότι η εφαρμογή αυτή παρέχει ένα περιβάλλον προγραμματισμού που εκτελείται στο υπολογιστικό νέφος της Google προσφέροντας στον τελικό χρήστη δωρεάν ή προς πληρωμή πόρους, όπως επεξεργαστική ισχύ και μνήμη για την εκτέλεση κώδικα. Το Colab αποδεικνύεται ιδιαίτερα χρήσιμο για την εκπαίδευση μοντέλων μηχανικής μάθησης, αφού παρέχει πρόσβαση σε βιβλιοθήκες όπως το TensorFlow και το Keras. Τέλος, το Google Colab δίνει τη δυνατότητα της εύκολης κοινής χρήσης των σημειωματάρων με άλλους χρήστες.

Στην εν λόγω έρευνα, εκμεταλλευτήκαμε αρκετά τις κάρτες γραφικών (Graphics Processing Unit – GPU) που προσφέρει η υπηρεσία, ώστε να εκτελέσουμε τον τελικό κώδικα και να εκπαιδύσουμε τα μοντέλα μηχανικής μάθησης που αναπτύχθηκαν σε σύντομο χρόνο.

### 3.3 PostgreSQL και PLpgSQL

Το σύστημα διαχείρισης βάσεων δεδομένων της PostgreSQL είναι μία τεχνολογία, η οποία χρησιμοποιήθηκε στην έρευνα μόνο για συγκριτικούς σκοπούς. Περισσότερες πληροφορίες για την χρήση της δίνονται στο επόμενο κεφάλαιο. Λόγω του γεγονότος ότι η χρήση της είναι περιορισμένη, παρουσιάζονται τα πιο σημαντικά στοιχεία που αφορούν αυτήν την τεχνολογία.

#### 3.3.1 Γενικά Χαρακτηριστικά για την Βάση Δεδομένων

Η PostgreSQL, γνωστή και ως Postgres, αποτελεί ένα προηγμένο σχεσιακό σύστημα διαχείρισης βάσεων δεδομένων ή ΣΔΒΔ (Database Management System – DBMS) [21]. Αυτό το ΣΔΒΔ είναι εύκολα επεκτάσιμο μέσω διάφορων προσθέτων, πολλά από τα οποία είναι ανοιχτού κώδικα και διαθέσιμα δωρεάν μέσω του διαδικτύου. Επομένως, πρόκειται για μία τεχνολογία με πολλές δυνατότητες.

Σε ένα σχεσιακό ΣΔΒΔ, τα δεδομένα αποθηκεύονται σε πίνακες με στήλες και γραμμές. Κάθε στήλη αντιπροσωπεύει έναν συγκεκριμένο τύπο δεδομένων, ενώ κάθε γραμμή αντιπροσωπεύει μια εγγραφή με συγκεκριμένες τιμές για κάθε στήλη. Το σχεσιακό μοντέλο επιτρέπει τη δημιουργία συσχετίσεων μεταξύ των πινάκων, δημιουργώντας ένα περίπλοκο δίκτυο συνδέσεων για την ανάκτηση σχετικών δεδομένων. Ένα σχεσιακό ΣΔΒΔ προσφέρει πολλά πλεονεκτήματα, όπως:

- **δομημένη οργάνωση:** τα δεδομένα οργανώνονται σε πίνακες ή σχέσεις, πράγμα που καθιστά εύκολη την οργάνωση και την ανάκτησή τους.
- **ευέλικτη ανάκτηση:** οι χρήστες μπορούν να κάνουν πολύπλοκα ερωτήματα με βάση διάφορα κριτήρια και συνθήκες.
- **κοινόχρηστη πρόσβαση:** πολλοί χρήστες μπορούν να έχουν πρόσβαση στα ίδια δεδομένα ή στην ίδια βάση δεδομένων ταυτόχρονα.
- **αποκλεισμός ανωμαλιών:** το ΣΔΒΔ παρέχει μηχανισμούς αποκλεισμού ανωμαλιών και ανάκαμψης μετά από κάποιο σφάλμα.

Ένα σημαντικό χαρακτηριστικό που υποστηρίζεται από την PostgreSQL είναι τα ευρετήρια (Indexes). Τα ευρετήρια βελτιστοποιούν την απόδοση και την αναζήτηση δεδομένων στη βάση επιτρέποντας γρήγορη πρόσβαση σε συγκεκριμένες εγγραφές μίας σχέσης, μειώνοντας έτσι τον χρόνο αναζήτησης και ανάκτησης των δεδομένων. Η PostgreSQL υποστηρίζει διάφορους τύπους ευρετηρίων που εξυπηρετούν διάφορες ανάγκες. Τα πιο σημαντικά και ευρέως χρησιμοποιούμενα ευρετήρια στην PostgreSQL είναι τα ευρετήρια B+ δέντρων και τα ευρετήρια κατακερματισμού.

Τέλος, η PostgreSQL υποστηρίζει διεπαφές με πολλές γλώσσες προγραμματισμού, όπως οι Java, Python, C, C++, PHP και C#, επιτρέποντας στις εφαρμογές να αλληλεπιδρούν άμεσα με τη βάση δεδομένων.

#### 3.3.2 Η Γλώσσα PL/pgSQL

Η γλώσσα προγραμματισμού PL/pgSQL (από το Procedural Language/PostgreSQL) αποτελεί μια πολύτιμη επέκταση του ΣΔΒΔ της PostgreSQL [22]. Πιο αναλυτικά, τα κυριότερα χαρακτηριστικά της PL/pgSQL συνοψίζονται παρακάτω:

- **δημιουργία συναρτήσεων και διαδικασιών:** με την PL/pgSQL μπορούν να δημιουργηθούν συναρτήσεις που επιστρέφουν τιμές και διαδικασίες που εκτελούν ενέργειες χωρίς επιστροφή τιμών. Αυτό επιτρέπει την οργάνωση εντός της βάσης δεδομένων.
- **ενσωμάτωση με την PostgreSQL:** ένα από τα πλεονεκτήματα της PL/pgSQL είναι ότι είναι πλήρως ενσωματωμένη με το σύστημα διαχείρισης βάσεων δεδομένων της PostgreSQL. Αυτό σημαίνει ότι οι διαδικασίες και οι συναρτήσεις που γράφονται σε γλώσσα PL/pgSQL είναι άμεσα εκτελέσιμες από τον ίδιο τον εξυπηρετητή της βάσης. Με τη δυνατότητα εκτέλεσης πολύπλοκων λειτουργιών απευθείας στη βάση δεδομένων, εξοικονομούνται πόροι που βελτιώνουν την απόδοση. Η PL/pgSQL αναδεικνύεται ως ένα απαραίτητο εργαλείο για τη δημιουργία πολύπλοκότερων και αποτελεσματικότερων διαχειριστικών λειτουργιών εντός του περιβάλλοντος της PostgreSQL.

- **εύκολη ανάπτυξη κώδικα:** η σύνταξη της PL/pgSQL είναι παρόμοια με αυτή της κλασικής SQL, επιτρέποντας στους προγραμματιστές και τους διαχειριστές βάσεων δεδομένων να εξοικειωθούν γρήγορα με τη νέα γλώσσα.
- **δήλωση μεταβλητών και σταθερών:** ένα από τα σημαντικότερα χαρακτηριστικά της PL/pgSQL είναι η δυνατότητα δήλωσης μεταβλητών για την αποθήκευση δεδομένων κατά τη διάρκεια της εκτέλεσης προγραμμάτων, καθώς και η δυνατότητα αποθήκευσης σταθερών τιμών, οι τιμές των οποίων παραμένουν σταθερές κατά τη διάρκεια της εκτέλεσης του κώδικα.
- **έλεγχος ροής:** η PL/pgSQL παρέχει δομές ακολουθίας, επιλογής και επανάληψης, οι οποίες επιτρέπουν τη διαχείριση της ροής εκτέλεσης του προγράμματος βάσει συνθηκών και κριτηρίων.
- **παραμετροποίηση:** η δυνατότητα χρήσης παραμέτρων και μεταβλητών στην PL/pgSQL παρέχει ευελιξία κατά την εκτέλεση των διαδικασιών, επιτρέποντας την προσαρμογή της συμπεριφοράς του προγράμματος βάσει δυναμικών παραμέτρων.
- **αναγνώριση σφαλμάτων:** σε περίπτωση εμφάνισης σφάλματος, η PL/pgSQL παρέχει σαφή μηνύματα σφάλματος προς τον προγραμματιστή, διευκολύνοντας τον εντοπισμό και τη διόρθωσή τους.

Συνολικά, η γλώσσα PL/pgSQL αντιπροσωπεύει μια ισχυρή εργαλειοθήκη που συμβάλλει στην επέκταση των δυνατοτήτων της PostgreSQL, καθιστώντας τη ένα περιβάλλον κατάλληλο όχι μόνο για την αποθήκευση δεδομένων, αλλά και για την εκτέλεση πολύπλοκων εργασιών και λογικών σεναρίων. Ουσιαστικά, η PL/pgSQL επιτρέπει στους χρήστες να εκμεταλλεύονται την δύναμη μίας γλώσσας προγραμματισμού, για να διαμορφώσουν τη βάση δεδομένων όπως αυτοί επιθυμούν.

### 3.4 Το Λογισμικό Docker

Το λογισμικό Docker [23] αποτελεί μια εξαιρετικά σημαντική τεχνολογία, η οποία συνδέεται στενά με τον τρόπο που αναπτύσσονται, μεταφέρονται και εκτελούνται εφαρμογές και λογισμικά. Το κύριο πλεονέκτημα του Docker είναι ότι επιτρέπει τη δημιουργία ενός «κουτιού εκτέλεσης» (container), το οποίο μπορεί να εκτελεστεί σε οποιοδήποτε σύστημα και λειτουργικό, εξαλείφοντας έτσι τις ανησυχίες περί συμβατότητας. Αναλυτικότερα, κάθε κουτί εκτέλεσης περιλαμβάνει:

- **εκτελέσιμο αρχείο:** το εκτελέσιμο αρχείο της εφαρμογής.
- **βιβλιοθήκες:** οι βιβλιοθήκες και οι εξαρτήσεις που απαιτούνται για τη λειτουργία της εφαρμογής. Αυτές χρησιμοποιούνται κατά τη διάρκεια της εκτέλεσης.
- **ρυθμίσεις περιβάλλοντος:** είναι τα πρότυπα που καθορίζουν πως η εφαρμογή πρέπει να εκτελείται, όπως είναι οι μεταβλητές περιβάλλοντος και οι παράμετροι εκτέλεσης.
- **εκτελέσιμες εντολές:** οι εκτελέσιμες εντολές αναφέρονται στις ενέργειες που πρέπει να ληφθούν, για να εκκινήσει η εφαρμογή εντός του κουτιού εκτέλεσης.
- **δεδομένα εφαρμογής:** πρόκειται για οποιαδήποτε δεδομένα ή αρχεία που χρειάζεται η εφαρμογή για να λειτουργήσει σωστά.

Η αξία του Docker έγκειται στην ευκολία ανάπτυξης, στην ευελιξία και στην αξιοπιστία εκτέλεσης των εφαρμογών. Όσον αφορά την επιρροή του Docker στον παγκόσμιο χώρο, η τεχνολογία αυτή έχει υιοθετηθεί από πολυάριθμους χρήστες και επιχειρήσεις, διαμορφώνοντας έτσι νέα πρότυπα για την αποτελεσματική και αξιόπιστη διαχείριση των εφαρμογών.

### 3.5 Το Λογισμικό Valhalla

Το λογισμικό Valhalla αποτελεί ένα πρόγραμμα ανοιχτού κώδικα που αναπτύχθηκε αρχικά από την εταιρεία Mapzen. Η συγκεκριμένη εταιρία ιδρύθηκε το 2013 και ειδικευόταν στις υπηρεσίες χαρτογράφησης γεωχωρικών δεδομένων. Η εφαρμογή έχει ως κύριο στόχο να εκτελεί υπηρεσίες χαρτογράφησης GPS δεδομένων, προσφέροντας ακριβείς δρομολογήσεις για αυτοκίνητα, ποδήλατα και άλλα μέσα μεταφοράς, καθώς επίσης και τη δυνατότητα αντιστοίχισης τροχιών GPS σε ψηφιακούς χάρτες [24].

Η διαδικασία ανάπτυξης του Valhalla ξεκινάει το 2014 και ολοκληρώνεται το 2019, όταν η εταιρεία Mapzen αποσύρεται από τον επιχειρηματικό τομέα. Μετά το κλείσιμο της Mapzen, το Valhalla και τα σχετικά δεδομένα που το απαρτίζουν μεταφέρονται στον Οργανισμό Ελεύθερου Λογισμικού (Software Freedom Conservancy) για τη διαχείριση, ανάπτυξη και συντήρηση του λογισμικού Valhalla.

Στον πυρήνα του Valhalla είναι συγκεντρωμένοι αλγόριθμοι υπεύθυνοι για την επεξεργασία των γεωχωρικών δεδομένων, όπως η δρομολόγηση και η αντιστοίχιση τροχιών σε χάρτες, εξυπηρετώντας έτσι προγραμματιστές και χρήστες που ψάχνουν μία τέτοια υπηρεσία. Επιπρόσθετα, οι αλγόριθμοι είναι σχεδιασμένοι με τέτοιο τρόπο, ώστε να προσδίδουν ακρίβεια και αξιοπιστία στα αποτελέσματα που παράγουν.

Το λογισμικό Valhalla είναι συμβατό με διάφορα λειτουργικά συστήματα, όπως το Linux, το macOS και τα Windows. Επιπλέον, το τελευταίο είναι προσαρμόσιμο για εκτέλεση τόσο σε τοπικούς υπολογιστές, όσο και σε απομακρυσμένους διακομιστές (Servers). Τέλος, λόγω του γεγονότος ότι το λογισμικό είναι ανοιχτού κώδικα, σημαίνει ότι διανέμεται δωρεάν στους ενδιαφερόμενους χρήστες.

### **3.5.1 Η Υπηρεσία Valhalla Meili**

Το Valhalla Meili αποτελεί ένα υποσύνολο του ευρύτερου project Valhalla και αναλαμβάνει να εκτελέσει μία συγκεκριμένη λειτουργία χαρτογράφησης. Η κύρια διαφορά μεταξύ του Valhalla Meili και του Valhalla είναι ότι το πρώτο είναι υπεύθυνο για την αντιστοίχιση τροχιών GPS σε ένα ψηφιακό χάρτη, ενώ το δεύτερο παρέχει στο χρήστη ένα ευρύτερο φάσμα λειτουργιών χαρτογράφησης, όπως η αναζήτηση της συντομότερης διαδρομής μεταξύ δύο σημείων.

Συγκεκριμένα, το Valhalla Meili αναλαμβάνει την λήψη της πορείας μιας παρατηρηθείσας τροχιάς αποτελούμενη από διαδοχικά GPS σημεία (ζεύγη από γεωγραφικά μήκη και γεωγραφικά πλάτη) και δίνει ως αποτέλεσμα μια πιθανή αντιστοιχισμένη διαδρομή στον ψηφιακό χάρτη.

Στην μελέτη μας χρησιμοποιούμε δεδομένα χαρτογράφησης που παρέχονται από τον οργανισμό Open Street Map (OSM). Το OSM [25] είναι μια δωρεάν, δημόσια βάση γεωγραφικών δεδομένων που ενημερώνεται και συντηρείται συνεχώς από μια κοινότητα εθελοντών. Μέσα σε αυτή την βάση αποθηκεύονται πληροφορίες σχετικά με το οδικό δίκτυο μίας περιοχής (για παράδειγμα δρόμοι, διασταυρώσεις, εθνικές οδοί, πεζοδρόμια κ.α.) και την τοπολογία της (παραδείγματος χάριν βουνά, λίμνες, ποτάμια, πεδιάδες, θάλασσες κ.α.). Το OSM χρησιμοποιείται ευρέως για την εξαγωγή ηλεκτρονικών χαρτών σε μορφή αρχείων και την οπτικοποίηση γεωχωρικών δεδομένων, καθώς διατίθεται ελεύθερα υπό την άδεια της ανοιχτής βάσης δεδομένων.

Στην διερεύνηση που έχουμε διεξάγει, χρησιμοποιείται η υπηρεσία Valhalla Meili σε συνδυασμό με το λογισμικό Docker. Ουσιαστικά, έχουμε εγκαταστήσει το Valhalla Meili σε ένα κουτί εκτέλεσης στο Docker, μέσα στο οποίο το πρόγραμμα εκτελείται ανεξάρτητα από το λειτουργικό σύστημα και τους περιορισμούς του μηχανήματος που διαθέτουμε. Μετά την εγκατάσταση του Valhalla Meili, διαμορφώνεται ένας εξυπηρετητής που αναλαμβάνει να δέχεται αιτήματα αντιστοίχισης GPS σημείων και να επιστρέφει την αντιστοιχισμένη πληροφορία στον ψηφιακό χάρτη OSM που χρησιμοποιούμε.

Η απάντηση που λαμβάνουμε από τον εξυπηρετητή του Valhalla μετά από κάθε αίτημα αντιστοίχισης που στέλνουμε σε αυτόν είναι εμπλουτισμένη με χρήσιμες πληροφορίες. Οι πληροφορίες αυτές καθίστανται προσβάσιμες εξαιτίας της λειτουργίας Trace Attributes που διαθέτει το Valhalla Meili. Αυτό έχει ως αποτέλεσμα κάθε τροχιά να συνοδεύεται από επιπρόσθετα δεδομένα, όπως είναι η ταχύτητα του κινούμενου αντικειμένου, η κατάστασή του (π.χ. είναι σε κίνηση ή σε στάση), το είδος του κινούμενου οχήματος (π.χ. αυτοκίνητο, ποδήλατο, πεζός) κ.α.

Εξαιρετικά χρήσιμο χαρακτηριστικό της λειτουργίας αυτής αποτελεί, επίσης, και η δυνατότητα να γνωρίζουμε το μοναδικό αναγνωριστικό της ακμής (Edge ID), στην οποία αντιστοιχίζεται το GPS σημείο που εξετάζουμε. Αυτά τα μοναδικά Edge IDs που παρέχει το Valhalla Meili δεν είναι τυχαία, αλλά προέρχονται απευθείας από τη βάση δεδομένων του OSM. Αυτό σημαίνει ότι μπορούμε εύκολα να αναζητήσουμε την αντίστοιχη ακμή, απλά κάνοντας αναζήτηση στη βάση δεδομένων του OSM. Μία ακόμα λεπτομέρεια που αξίζει να αναφερθεί, είναι ότι κάθε Edge ID που υπάρχει στη βάση δεδομένων του OSM είναι μοναδικό.



Αντιστοιχίζοντας σημεία GPS με τα Edge IDs, ο αλγόριθμος μπορεί να ανακατασκευάσει ακριβώς τη διαδρομή που ακολούθησε το κινούμενο αντικείμενο, όπως ένα όχημα ή ένας χρήστης. Η διαδικασία αντιστοίχισης δεδομένων GPS που απαρτίζουν μία τροχιά στο οδικό δίκτυο περιλαμβάνει την εύρεση της ακολουθίας των Edge IDs με σωστή σειρά. Αυτή η ακολουθία των Edge ID αντιστοιχίζεται όσο το δυνατόν καλύτερα στο οδικό δίκτυο δίνοντας ως αποτέλεσμα μια ακριβή ή αρκετά καλή αναπαράσταση της διαδρομής που διένυσε το κινούμενο αντικείμενο πάνω στον OSM χάρτη.

## 4. Μεθοδολογία

Στο παρόν κεφάλαιο παρουσιάζεται η μεθοδολογία, την οποία προτείνουμε, για να αντιμετωπίσουμε με αποτελεσματικότητα το πρόβλημα της πρόβλεψης της κυκλοφοριακής ροής σε μονοπάτια που βρίσκονται μέσα σε ένα συγκεκριμένο οδικό δίκτυο. Η μεθοδολογία θέλει το πρόβλημα να επιλυθεί με αλγόριθμους μηχανικής μάθησης. Επομένως, η ύπαρξη ενός συνόλου δεδομένων καθίσταται αναγκαία. Αξίζει να προστεθεί ότι η σειρά των βημάτων που παρουσιάζονται εδώ είναι γενική.


### 4.1 Συλλογή και Επεξεργασία των Δεδομένων

Το πρώτο βήμα στην διεκπεραίωση του προβλήματος είναι η συγκέντρωση ενός κατάλληλου συνόλου δεδομένων. Τα δεδομένα συνίστανται να περιέχουν καταγραφές θέσεων ΚΑ εντός ενός συστήματος οδών, καθώς επίσης και την χρονική πληροφορία αυτών των καταγραφών.

Αφού γίνει η συλλογή των δεδομένων, καλό είναι να γίνει η δέουσα προεπεξεργασία επάνω σε αυτά. Για παράδειγμα, η απομάκρυνση πλεονάζουσας πληροφορίας που δεν σχετίζεται με την κυκλοφοριακή ροή, η αντιμετώπιση των κενών τιμών και η μετατροπή των κατηγορικών χαρακτηριστικών σε αριθμητικές τιμές είναι μόνο λίγες από τις ενέργειες που μπορούν να γίνουν, εφόσον χρειάζεται.

Αφού το σύνολο δεδομένων έχει οργανωθεί, το επόμενο βήμα αφορά στην οργάνωση της πληροφορίας που παρέχουν τα δεδομένα. Συγκεκριμένα, αυτό το βήμα διαιρείται στην διαδικασία του **διαχωρισμού τροχιών** (Trajectory Splitting) και της **αντιστοίχισης των σημείων GPS στον χάρτη** (Map Matching).

Όσον αφορά την πρώτη διαδικασία, μέσα στο σύνολο δεδομένων υπάρχουν τροχιές ΚΑ. Ο όρος τροχιά αναφέρεται στην συνεχόμενη καταγραφή GPS θέσεων ενός ΚΑ μέσα σε ένα χρονικό διάστημα. Λόγω του γεγονότος ότι οι καταγραφές αυτές μπορεί να τύχει να είναι καταγεγραμμένες ανά αραιά χρονικά διαστήματα, μία διαδικασία διαχωρισμού αυτών των τροχιών οργανώνει τα δεδομένα σε υποτροχιές, όπου κάθε υποτροχιά περιέχει χρονικές καταγραφές GPS θέσεων ενός μόνο ΚΑ που απέχουν ανά δύο ένα συγκεκριμένο χρονικό διάστημα. Το πόσο μικρά θα είναι τα χρονικά διαστήματα αφήνεται στην επιλογή του χρήστη. Μετά το πέρας αυτής της διαδικασίας, τα αναγνωριστικά της τροχιάς καθώς και της υποτροχιάς θεωρούμε πως οργανώνονται σε πεδία με ονόματα TrajID ή SubTrajID αντίστοιχα.



Εικόνα 4.1: Τροχιά ενός ΚΑ.

Για παράδειγμα, στην εικόνα 4.1 παρατηρούμε την τροχιά ενός τυχαίου ΚΑ. Τα σημεία καταγραφής GPS αυτής της τροχιάς είναι τα a, b, c, d, e και f. Εάν υποθέσουμε ότι τα σημεία GPS έχουν καταγραφεί στους χρόνους  $t_a=0$ ,  $t_b=5$ ,  $t_c=10$ ,  $t_d=20$ ,  $t_e=25$  και  $t_f=30$  αντίστοιχα και ότι κάθε τροχιά πρέπει να αποτελείται από σημεία GPS που απέχουν ανά δύο το πολύ πέντε (5) sec, τότε οι νέες υποτροχιές που θα δημιουργηθούν θα είναι οι  $sub_1=\{a,b,c\}$  και  $sub_2=\{d,e,f\}$ .

Μόλις γίνει ο διαχωρισμός των τροχιών σε υποτροχιές, η επόμενη κίνηση στην μεθοδολογία μας είναι η διαδικασία Map Matching. Τα δεδομένα των υποτροχιών αποτελούν GPS σημεία. Επομένως, υπάρχει μεγάλη πιθανότητα κατά την συλλογή τους να υπήρξε θόρυβος και να μην έχουν αντιστοιχηθεί σωστά στο οδικό δίκτυο που αντιπροσωπεύουν. Άρα, μία διαδικασία αντιστοίχισης των τροχιών στο οδικό δίκτυο καθίσταται αναγκαία.



**Εικόνα 4.2: Πριν και μετά το Map Matching.**

Η εικόνα 4.2 παρουσιάζει τα σημεία GPS μίας τροχιάς ενός ΚΑ μέσα στο οδικό δίκτυο μίας πόλης, όπως αυτά έχουν καταγραφεί αρχικά (με κόκκινο χρώμα). Αφού τελειώσει η διαδικασία της αντιστοίχισής τους στο οδικό δίκτυο, λαμβάνουμε ως έξοδο την αντιστοιχιζόμενη τροχιά (με μπλε χρώμα).

Μετά το πέρας αυτής της επεξεργασίας, τα νέα δεδομένα που προκύπτουν έχουν πλέον αντιστοιχηθεί επακριβώς στο οδικό δίκτυο. Η νέα πληροφορία που έχει εισαχθεί στα δεδομένα περιέχει για κάθε τροχιά τις διαδοχικές ακμές που πέρασε η τροχιά (στήλη OsmWayID), τον χρόνο που εισήλθε η τροχιά στην κάθε ακμή (στήλη TimeEnter) και τον χρόνο που εξήλθε η τροχιά από αυτή την ακμή (στήλη TimeLeave). **Σημείωση:** Τα ονόματα των στηλών που δίνονται είναι ενδεικτικά και χρησιμοποιούνται για την κατανόηση του αλγορίθμου SPQ που περιγράφεται παρακάτω.

## 4.2 Αναγωγή σε Πρόβλημα Χρονοσειρών

Ο τρόπος, με τον οποίο προσεγγίζεται το πρόβλημα στην μεθοδολογία είναι υπό το πρίσμα των χρονοσειρών. Ως χρονοσειρές ορίζουμε τα δεδομένα που έχουν διαταχθεί σε συνάρτηση με τον χρόνο. Το επόμενο βήμα στην μεθοδολογία μας είναι να οργανώσουμε τα δεδομένα που έχουμε στη διάθεσή μας σε χρονοσειρές. Προς διευκόλυνση του αναγνώστη, επαναλαμβάνεται ότι το πρόβλημα που επιλύεται είναι η πρόβλεψη της κυκλοφοριακής ροής σε ολόκληρα μονοπάτια ενός οδικού δικτύου.

Για την ολοκλήρωση του βήματος αυτού, θεωρούμε απαραίτητη την χρήση του αλγορίθμου των AEM που αναφέραμε στο πρώτο κεφάλαιο. Υπενθυμίζεται ότι ένα τέτοιο ερώτημα βρίσκει όλες τις τροχιές που ακολουθούν επακριβώς ένα συγκεκριμένο μονοπάτι οποιουδήποτε μήκους και εντός ενός συγκεκριμένου χρονικού διαστήματος. Η έναρξη αυτού του χρονικού διαστήματος υποδηλώνει τον χρόνο που η τροχιά εισέρχεται στο συγκεκριμένο μονοπάτι, ενώ η λήξη του χρονικού διαστήματος υποδηλώνει τον ανεκτό χρόνο που η εκάστοτε τροχιά θα πρέπει να έχει εξέλθει από αυτό.

Ο αλγόριθμος των AEM έχει υλοποιηθεί σε γλώσσα Python με μορφή συνάρτησης. Το όνομα της συνάρτησης είναι **SPQ** και προέρχεται από τη φράση **Street Path Queries**. Πιο συγκεκριμένα, η συνάρτηση προσπελάζει κάθε φορά τον πίνακα με τα αντιστοιχιζόμενα στο οδικό δίκτυο δεδομένα. Οι παράμετροι που λαμβάνει σαν είσοδο είναι οι ακόλουθες:

- **path:** είναι η διαδρομή που πρέπει να ακολουθήσουν οι τροχιές ακριβώς (ακμή προς ακμή), χωρίς να παρεκκλίνουν από αυτή. Αυτό το μονοπάτι μπορεί να έχει οποιοδήποτε μήκος ακμών μεγαλύτερο ή ίσο των δύο.
- **time\_enter:** ο χρόνος, κατά τον οποίο η τροχιά θα πρέπει να έχει εισέλθει στην πρώτη ακμή της διαδρομής που δίνεται ως είσοδος.
- **time\_leave:** ο χρόνος, κατά τον οποίο η τροχιά πρέπει να έχει εγκαταλείψει την τελευταία ακμή της διαδρομής που δίνεται ως είσοδος.

Ακολουθεί τώρα ο ψευδοκώδικας που περιγράφει την συνάρτηση SPQ:

#### ΕΝΑΡΞΗ ΣΥΝΑΡΤΗΣΗΣ SPQ

Είσοδοι Συνάρτησης: ένα μονοπάτι  $\pi$ , ο χρόνος  $time\_enter$ , ο χρόνος  $time\_leave$ .

Έξοδος Συνάρτησης: πλήθος τροχιών που διέσχισαν επακριβώς το μονοπάτι  $\pi$  στο χρονικό διάστημα  $[time\_enter, time\_leave]$ .

0: Υπολόγισε το μήκος του μονοπατιού και αποθήκευσέ το σε μία μεταβλητή  $path\_length$ .

1: Φτιάξε μία κενή λίστα  $trajectories$ .

2: Βρες όλες τις εγγραφές του πίνακα με τα αντιστοιχιζόμενα δεδομένα που έχουν  $TimeEnter \geq time\_enter$  και  $TimeLeave \leq time\_leave$ , αποθήκευσέ τις σε μία μεταβλητή με όνομα  $examined\_data$ .

3: Βρες όλα τα αναγνωριστικά των γραμμών που περιέχουν σαν  $OsmWayID$  την πρώτη ακμή στο μονοπάτι  $\pi$  και αποθήκευσέ τα σε μία λίστα  $needed\_indexes$ .

4: Για κάθε στοιχείο  $index$  στη λίστα  $needed\_indexes$  επανέλαβε:

4.1: Βρες το  $TrajlID$  του στοιχείου  $index$  και αποθήκευσέ το σε μία μεταβλητή  $t\_id$ .

4.2: Βρες το  $SubTrajlID$  του στοιχείου  $index$  και αποθήκευσέ το σε μία μεταβλητή  $s\_id$ .

4.3: Όρισε την τιμή μιας νέας μεταβλητής  $inter = 1$ .

4.4: Από  $i = 1$  έως  $path\_length$  επανέλαβε:

4.4.1: Έλεγχε εάν η γραμμή με αναγνωριστικό  $index+i$  περιέχει σαν  $TrajlID == t\_id$  ΚΑΙ  $SubTrajlID == s\_id$  ΚΑΙ  $OSMWayID$  την επόμενη σε σειρά ακμή στο μονοπάτι  $\pi$ .

4.4.2: Εάν ισχύει η παραπάνω συνθήκη αύξησε τον μετρητή  $inter$  κατά 1.

4.5: Τέλος εσωτερικού βρόγχου.

4.6: Εάν  $path\_length == inter$ , πρόσθεσε το ζευγάρι  $(t\_id, s\_id)$  στη λίστα  $trajectories$

4.7: Τέλος εξωτερικού βρόγχου.

5: Διέγραψε τα διπλότυπα ζευγάρια από τη λίστα  $trajectories$  και επέστρεψε το μήκος της.

#### ΤΕΛΟΣ ΣΥΝΑΡΤΗΣΗΣ SPQ

Αφού έχουμε παραθέσει την λειτουργία του αλγορίθμου SPQ, συνεχίζουμε με την οργάνωση των δεδομένων σε χρονοσειρές. Αρχικά, ορίζουμε  $m$  διαφορετικά μονοπάτια με τυχαία μήκη το κάθε ένα μέσα στο προς εξέταση οδικό δίκτυο. Ο αριθμός  $m$  προσδιορίζεται πάντα από το χρήστη και είναι θετικός αριθμός.

Δεύτερο, υπολογίζουμε το συνολικό χρονικό διάστημα καταγραφών που έχουμε στη διάθεσή μας. Για την διευκόλυνσή μας, προτείνουμε η συλλογή των δεδομένων για κάθε υποτροχιά να εμπεριέχεται στο ίδιο χρονικό διάστημα, για παράδειγμα εντός ενός χρόνου ή ενός μήνα. Στην συνέχεια, κατακερματίζουμε το συνολικό αυτό χρονικό διάστημα σε μικρότερα ίσα χρονικά υποδιαστήματα.

Τέλος, για κάθε μονοπάτι και για κάθε χρονικό υποδιάστημα, μετράμε την κυκλοφοριακή ροή μέσα σε αυτό χρησιμοποιώντας την συνάρτηση SPQ. Το αποτέλεσμα θα είναι ένα νέο σύνολο δεδομένων, το οποίο για κάθε μονοπάτι θα αναφέρει το πλήθος των ΚΑ που το διένυσαν σε κάθε χρονικό υποδιάστημα, δημιουργώντας έτσι πληροφορία που εξαρτάται πλήρως από το μέγεθος του χρόνου.

### 4.3 Προσθήκη Επιπλέον Πληροφορίας στα Δεδομένα

Μετά την εκτέλεση των παραπάνω βημάτων, τα δεδομένα μας έχουν μετατραπεί πλέον σε χρονοσειρές. Τα τελευταία μάλιστα αποτελούν την είσοδο προς το μοντέλο μηχανικής μάθησης, το οποίο θα εκπαιδευτεί πάνω σε αυτά και θα δώσει, τελικά, τις προβλέψεις για το μέγεθος της κυκλοφοριακής ροής σε κάθε μονοπάτι.

Προκειμένου να βελτιστοποιηθεί ακόμα περισσότερο η διαδικασία των προβλέψεων, η μεθοδολογία προτρέπει τον χρήστη να συμπεριλάβει επιπλέον δεδομένα που επηρεάζουν την

κυκλοφοριακή ροή, όπως δεδομένα καιρού, εορτών, τροχαίων ατυχημάτων και δεδομένα που αφορούν τον χρόνο.

Προφανώς, ένα μοντέλο μηχανικής ή βαθιάς μάθησης ίσως να μην χρειάζεται όλη την πληροφορία που συνοδεύει το σύνολο δεδομένων. Για την επιλογή των απολύτως απαραίτητων χαρακτηριστικών που θα χρησιμοποιηθούν τελικά από το μοντέλο, προτείνεται η χρήση μίας μήτρας συσχέτισης (Correlation Matrix). Ο ρόλος της είναι να παρουσιάσει τις συσχετίσεις μεταξύ των διάφορων χαρακτηριστικών στα δεδομένα και να βοηθήσει τον προγραμματιστή στην κατασκευή ενός καλύτερου μοντέλου μηχανικής μάθησης. Συγκεκριμένα, ο πίνακας συσχέτισης συμβάλλει στην:

- **βελτιστοποίηση του μοντέλου:** εάν το μοντέλο υποφέρει από υπερεκπαίδευση, δηλαδή δεν μπορεί να γενικευτεί σε άλλα σύνολα δεδομένων, μια προσέγγιση που υιοθετείται είναι να μειωθεί ο αριθμός των χαρακτηριστικών που χρησιμοποιούνται κατά την εκπαίδευση. Ο πίνακας συσχέτισης μπορεί να βοηθήσει στην επιλογή των χαρακτηριστικών που πρέπει να διατηρηθούν, για να βελτιωθεί η γενίκευση του μοντέλου.
- **ανίχνευση κοινών χαρακτηριστικών:** κοινά χαρακτηριστικά που περιγράφουν την ίδια πληροφορία μπορούν να εισαγάγουν θόρυβο στο μοντέλο μπερδεύοντάς το. Ο πίνακας συσχέτισης μπορεί να αναδείξει χαρακτηριστικά που έχουν υψηλή σχέση με άλλα χαρακτηριστικά, υποδηλώνοντας ότι μπορεί να είναι περιττά και ίσως να χρειαστεί να μην χρησιμοποιηθούν στην εκπαίδευση.

Οι νόμιμες τιμές που λαμβάνει μία μήτρα συσχέτισης κυμαίνονται μεταξύ του μείον ένα και του ενός. Αν η τιμή της συσχέτισης είναι κοντά στο μείον ένα, τότε υπάρχει **αρνητική γραμμική συσχέτιση** μεταξύ των δύο χαρακτηριστικών. Αυτό σημαίνει ότι όταν μία μεταβλητή αυξάνεται, η άλλη μειώνεται σύμφωνα με μια γραμμική σχέση.

Από την άλλη, όταν η τιμή της συσχέτισης είναι κοντά στο μηδέν, **δεν υπάρχει γραμμική συσχέτιση** ανάμεσα στις μεταβλητές. Αυτό σημαίνει ότι οι μεταβλητές δεν συσχετίζονται με τρόπο που να μπορεί να περιγραφεί με μια γραμμική σχέση. Ωστόσο, αυτό δεν σημαίνει απαραίτητως ότι δεν υπάρχει καμία άλλη συσχέτιση μεταξύ τους.

Τέλος, μία τιμή κοντά στο ένα δηλώνει ότι οι δύο μεταβλητές παρουσιάζουν **θετική γραμμική συσχέτιση**. Κάθε αλλαγή στην τιμή της μίας μεταβλητής, επηρεάζει την άλλη κατά ανάλογο τρόπο. Με άλλα λόγια, υπάρχει μία γραμμική σχέση που διέπει τις δύο μεταβλητές.

#### 4.4 Οργανώνοντας τα Δεδομένα Εισόδου

Το μοντέλο που πρόκειται να χρησιμοποιηθεί πρέπει να ανήκει στην κατηγορία της μάθησης υπό επίβλεψη (Supervised Learning). Ουσιαστικά, με αυτό τον τρόπο, το μοντέλο χρησιμοποιεί ένα μέρος του συνόλου δεδομένων για να εκπαιδευτεί. Κατά τη φάση της εκπαίδευσης, ο αλγόριθμος μηχανικής μάθησης που έχουμε επιλέξει μαθαίνει σχέσεις και μοτίβα που υπάρχουν στο σύνολο εκπαίδευσης. Για αυτό τον λόγο, συνηθίζεται το ποσοστό των δεδομένων που δίνεται για εκπαίδευση να είναι 70% και άνω των συνολικών δεδομένων. Τα υπόλοιπα δεδομένα αφορούν το σύνολο ελέγχου, στο οποίο ο αλγόριθμός θα προσπαθήσει να εφαρμόσει τα όσα έμαθε κατά την εκπαίδευσή του. Μάλιστα, πάνω στο σύνολο ελέγχου γίνεται και η τελική αξιολόγηση του μοντέλου.

Σε προβλήματα, στα οποία προσπαθούμε να διαχειριστούμε χρονοσειρές προκειμένου να κάνουμε προβλέψεις, μία δημοφιλής τεχνική που εφαρμόζεται συχνά για την υποβοήθηση αυτής της διαδικασίας είναι το κυλιόμενο παράθυρο [25]. Το κυλιόμενο παράθυρο (Sliding Window) είναι μια διαδικασία που χρησιμοποιείται στην ανάλυση χρονοσειρών εξασφαλίζοντας προβλέψεις με βάση προηγούμενες παρατηρήσεις (ιστορικά δεδομένα). Στην ουσία, χρησιμοποιείται ένα κινούμενο παράθυρο που κυλάει κατά μήκος της χρονοσειράς, επιτρέποντας τη δημιουργία πολλαπλών προβλέψεων.


Σε ένα πρόβλημα ανάλυσης ή πρόβλεψης χρονοσειρών, η τεχνική του συρόμενου παραθύρου χρησιμοποιείται για διάφορους λόγους:

- οι παρατηρήσεις από το παρελθόν μπορούν να χρησιμοποιηθούν, για να προβλέψουν το μέλλον. Με το κυλιόμενο παράθυρο δημιουργούνται διαδοχικά παράθυρα (δηλαδή τμήματα χρονοσειρών) που περιλαμβάνουν τις προηγούμενες παρατηρήσεις. Το μοντέλο

εκπαιδεύεται σε αυτά τα παράθυρα, για να παράγει τις μελλοντικές τιμές του μεγέθους προς πρόβλεψη.

- με την πρόοδο του χρόνου, το κυλιόμενο παράθυρο επιτρέπει τη συνεχή ενημέρωση του μοντέλου με νεότερες παρατηρήσεις, ενισχύοντας την ικανότητα πρόβλεψης με βάση τις τελευταίες πληροφορίες.

Στην εικόνα 4.3 γίνεται επεξήγηση του πως λειτουργεί η τεχνική του κυλιόμενου παραθύρου. Στον πίνακα αριστερά έχουμε την καταγραφή της κυκλοφοριακής ροής σε ένα μονοπάτι ανά ίσα χρονικά διαστήματα. Εάν επιλέξουμε να δίνουμε στο μοντέλο δύο (2) παρελθοντικά δεδομένα της κυκλοφοριακής ροής (χρόνοι t-1 και t-2) προκειμένου να προβλέψει την αμέσως επόμενη τιμή του ίδιου μεγέθους (χρόνος t), τότε το μήκος του παραθύρου πρέπει να είναι τρία (3). Με βάση αυτούς τους κανόνες, η χρονοσειρά μετασχηματίζεται στην μορφή που φαίνεται στον πίνακα δεξιά της εικόνας 4.3.



**Εικόνα 4.3: Παράδειγμα εφαρμογής του κυλιόμενου παραθύρου.**

Η μεθοδολογία αυτή εγγυάται ότι ο αλγόριθμος εκπαιδεύεται σε ολόκληρη την χρονοσειρά (ή τις χρονοσειρές) που συμπεριλαμβάνεται (συμπεριλαμβάνονται) στα δεδομένα εκπαίδευσης. Η ίδια ακριβώς τεχνική χρησιμοποιείται και στα δεδομένα ελέγχου. Χρησιμοποιώντας διαφορετικά μήκη παραθύρου, δηλαδή το πόσα ιστορικά δεδομένα χρησιμοποιούνται κάθε φορά στο παράθυρο για την πρόβλεψη, μπορούμε να αξιολογήσουμε πως η εφαρμογή τους επηρεάζει την απόδοση του μοντέλου. Αυτό βοηθά να ευρεθεί το βέλτιστο μέγεθος παραθύρου για τη συγκεκριμένη χρονοσειρά.

## 4.5 Εκπαίδευση και Αξιολόγηση του Μοντέλου

Η παρούσα μεθοδολογία αναφέρεται σε ένα πρόβλημα πρόβλεψης ενός σχετικά μη γραμμικού και απρόβλεπτου μεγέθους, αυτό της κυκλοφοριακής ροής. Στην διάθεσή μας υπάρχουν πολλοί αλγόριθμοι υπό επίβλεψη που χειρίζονται τέτοιου είδους δεδομένα, όπως ένα νευρωνικό δίκτυο με μνήμη (LSTM). Η επιλογή του κατάλληλου μοντέλου πρέπει να γίνει με προσοχή, έχοντας ως γνώμονα πάντα το είδος των δεδομένων που χρησιμοποιούνται και την μορφή που έχουν αυτά.

Αφού ευρεθεί ένας αλγόριθμος με ικανοποιητική αρχική απόδοση στα δεδομένα που χρησιμοποιούνται, είναι απαραίτητο να γίνουν οι όποιες βελτιστοποιήσεις χρειάζονται. Συγκεκριμένα, οι τελευταίες αναφέρονται σε μία διαδικασία ρύθμισης των υπερπαραμέτρων του μοντέλου.

Κατόπιν εκτέλεσης τούτων, σειρά έχει η διαδικασία της εκπαίδευσης του αλγορίθμου στο σύνολο δεδομένων. Αυτή η διαδικασία ενδέχεται να καθυστερήσει, ανάλογα πάντα με το πλήθος των δεδομένων εκπαίδευσης που χρησιμοποιούνται.

Το τελευταίο βήμα όλης της διαδικασίας αναφέρεται στην αξιολόγηση (Evaluation) του μοντέλου. Η επίδοσή του προσμετράται με την βοήθεια δύο μετρικών (Evaluation Metrics): το Μέσο Απόλυτο Σφάλμα και τη Ρίζα του Μέσου Τετραγωνικού Σφάλματος.

- Το RMSE μετράει την τυπική απόκλιση των προβλέψεων από τις πραγματικές τιμές. Υψηλές τιμές του RMSE υποδεικνύουν μεγάλη διακύμανση μεταξύ των προβλέψεων και των πραγματικών τιμών, κάνοντας τις προβλέψεις να απέχουν σημαντικά από τις πραγματικές τιμές. Ο τύπος για το RMSE score περιγράφεται στην εξίσωση 5.1:

$$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - k)^2} \quad (5.1)$$

Το  $n$  είναι ο αριθμός των παρατηρήσεων,  $y_i$  είναι η πραγματική τιμή και  $k$  είναι η πρόβλεψη του μοντέλου για την  $i$ -οστή παρατήρηση.

- Το MAE μετράει το μέσο απόλυτο σφάλμα μεταξύ των προβλέψεων και των πραγματικών τιμών. Ο τύπος για το MAE score δίνεται από τη σχέση 5.2:

$$\frac{1}{n} \sum_{i=1}^n |y_i - k| \quad (5.2)$$

Το  $n$  είναι ο αριθμός των παρατηρήσεων,  $y_i$  είναι η πραγματική τιμή και  $k$  είναι η πρόβλεψη του μοντέλου για την  $i$ -οστή παρατήρηση. Αυτό το μέτρο αγνοεί το πρόσημο του σφάλματος, δηλαδή αν η πρόβλεψη είναι πάνω ή κάτω από την πραγματική τιμή.

Συνολικά, και οι δύο μετρικές χρησιμοποιούνται σε μοντέλα παλινδρόμησης (Regression), για να εκτιμήσουν πόσο κοντά βρίσκονται οι προβλέψεις του μοντέλου στις πραγματικές τιμές. Όσο μικρότερες είναι αυτές οι τιμές, τόσο καλύτερες είναι και οι προβλέψεις που γίνονται. Το μοντέλο με τις χαμηλότερες τιμές για κάθε μία από τις δύο αυτές μετρικές επιλέγεται ως το πλέον κατάλληλο για την διαδικασία των προβλέψεων.

#### 4.6 Παραγωγή των Προβλέψεων

Στο τελευταίο βήμα της μεθοδολογίας, εγείρεται ένα σημαντικό ερώτημα: πρέπει να παράγουμε προβλέψεις για την κυκλοφοριακή ροή εντός ενός σύντομου χρονικού διαστήματος στο μέλλον ή εντός ενός μακρού χρονικού διαστήματος στο μέλλον; Η απόφαση αυτή εξαρτάται από τις ανάγκες του χρήστη. **Σημείωση:** ως «μέλλον» ορίζονται τα χρονικά διαστήματα, για τα οποία δεν έχουμε καμία πληροφορία για την κυκλοφοριακή ροή, αλλά προσπαθούμε να την προβλέψουμε. Υποθέτουμε ότι οι προβλέψεις επιλέγεται να γίνουν  $k$  ώρες στο μέλλον. Το  $k$  ορίζεται να είναι ένας θετικός αριθμός.

Για να δημιουργήσουμε αυτές τις προβλέψεις, χρησιμοποιούμε δεδομένα που περιλαμβάνουν τα ίδια χαρακτηριστικά (π.χ. δεδομένα καιρού, χρόνου, εορτές, κυκλοφοριακά δεδομένα) που χρησιμοποιήθηκαν κατά την εκπαίδευση και τον έλεγχο του μοντέλου μηχανικής μάθησης. Το σημαντικό είναι ότι αυτά τα νέα δεδομένα πρέπει να αντικατοπτρίζουν την πληροφορία που αφορά τις κυκλοφοριακές συνθήκες σε ένα ολόκληρο χρονικό διάστημα  $k$  ωρών στο μέλλον.

Εισάγοντας αυτά τα μελλοντικά δεδομένα στο ήδη εκπαιδευμένο μοντέλο μηχανικής μάθησης, λαμβάνουμε ως έξοδο προβλέψεις για το μέγεθος της κυκλοφοριακής ροής σε κάθε μονοπάτι κατά τις επόμενες  $k$  ώρες.

## 5. Εφαρμογή της Μεθοδολογίας

Στο κεφάλαιο αυτό παρέχεται όλη η απαραίτητη γνώση σχετικά με τον κώδικα που αναπτύχθηκε. Ταυτόχρονα, αναλύονται οι τεχνικές και οι βελτιστοποιήσεις που λήφθηκαν υπόψιν, ώστε να παραχθούν ακριβέστερα και ποιοτικότερα αποτελέσματα. Ο κώδικας έχει χωριστεί σε πέντε αρχεία, τα οποία φέρουν τους τίτλους «**Notebook1**», «**Notebook2**», «**Notebook3**», «**Notebook4**» και «**Notebook5**»:

Στο πρώτο αρχείο γίνεται όλη η προεπεξεργασία των δεδομένων: η αντιστοίχιση των σημείων GPS στο οδικό δίκτυο και η αναγωγή του προβλήματος σε χρονοσειρές. Επιπρόσθετα, στο δεύτερο αρχείο γίνεται κατανοητή η σημασία χρήσης της μεθόδου των ΑΕΜ χρησιμοποιώντας γραφήματα. Στο τρίτο αρχείο εισάγονται τα δεδομένα καιρού, γίνονται οπτικοποιήσεις πάνω στα δεδομένα και συγκρίνονται τέσσερα μοντέλα μηχανικής μάθησης, όπου κάθε ένα από αυτά αποσκοπεί στην επίλυση του βασικού προβλήματος. Στην συνέχεια, στο τέταρτο αρχείο πραγματοποιούνται οι διαδικασίες των προβλέψεων του μεγέθους της κυκλοφοριακής ροής, κάνοντας χρήση του καλύτερου αλγορίθμου μηχανικής μάθησης που εκπαιδεύτηκε. Τέλος, στο πέμπτο αρχείο του κώδικα, εφαρμόζεται ολόκληρη η μεθοδολογία που αναφέραμε πάνω σε ένα σύνολο δεδομένων που έχει δημιουργηθεί χωρίς την χρήση της αλγοριθμικής διαδικασίας των ΑΕΜ. Έτσι, καθίσταται ξεκάθαρη η αναγκαιότητα της χρήσης των ΑΕΜ.

### 5.1 Δεδομένα που Χρησιμοποιήσαμε

Η κυκλοφοριακή ροή είναι ένα μέγεθος που δεν χαρακτηρίζεται από γραμμικότητα. Αυτό σημαίνει ότι ο αριθμός των οχημάτων που διέρχονται από ένα συγκεκριμένο σημείο ενός οδικού δικτύου κατά μια δεδομένη χρονική στιγμή δεν αυξάνεται ή μειώνεται σε σταθερό ρυθμό, αλλά μπορεί να διακυμαίνεται εξαιτίας διαφόρων παραγόντων, όπως ο χρόνος, οι καιρικές συνθήκες και τα τροχαία ατυχήματα. Επομένως, η χρήση κατάλληλων δεδομένων είναι κρίσιμης σημασίας για την κατανόηση και την πρόβλεψη της κυκλοφοριακής ροής. Για τους σκοπούς της έρευνας, έχουμε εκμεταλλευτεί δύο σύνολα δεδομένων:

- τα δεδομένα τροχιών (trajectory data): αναφέρονται στις πληροφορίες που καταγράφουν τις θέσεις των κινούμενων αντικειμένων σε όλη τη διάρκεια του χρονικού διαστήματος που μας ενδιαφέρει.
- τα δεδομένα καιρού (weather data): αφορούν μετρήσεις και πληροφορίες σχετικά με τις καιρικές συνθήκες σε μια συγκεκριμένη περιοχή. Η καταγραφή και η ανάλυση των δεδομένων καιρού μπορεί να προσφέρει πληροφορίες σχετικές με τις συνθήκες που επηρεάζουν την κίνηση των οχημάτων, καθώς και την ασφάλεια και την απόδοσή τους στους δρόμους.

Και τα δύο προαναφερθέντα είδη δεδομένων συνδυάζονται με σκοπό την καλύτερη κατανόηση της κυκλοφοριακής ροής και της συμπεριφοράς των οχημάτων υπό διάφορες καιρικές συνθήκες.

#### 5.1.1 Δεδομένα Τροχιών

Για να εξασφαλιστεί η υψηλή ποιότητα της έρευνας, έχουμε προσπαθήσει να αναζητήσουμε ένα σύνολο δεδομένων θέσεων GPS εντός μίας περιοχής, το οποίο ικανοποιεί ορισμένες αυστηρές προδιαγραφές. Συγκεκριμένα, κατά την επιλογή του ιδανικού συνόλου δεδομένων, πρέπει να συμπεριληφθούν υπόψιν τα ακόλουθα:

- πρώτο, περιέχονται δεδομένα σημείων GPS που καλύπτουν ένα σχετικά ευρύ γεωγραφικό χώρο (για παράδειγμα τον χώρο μίας ολόκληρης πόλης).
- δεύτερο, στο σύνολο δεδομένων είναι σημαντικό να υπάρχουν καταγραφές θέσεων GPS πολλών διαφορετικών ΚΑ, ώστε η μελέτη να είναι όσο το δυνατόν ακριβέστερη και πληρέστερη.
- τρίτο, τα συνεχόμενα δεδομένα θέσεων GPS για κάθε ΚΑ πρέπει να καταγράφονται εντός ενός μικρού χρονικού διαστήματος το ένα με το άλλο.



- τέταρτο, ο χρόνος καταγραφής για κάθε σημείο GPS πρέπει να δίνεται ως πληροφορία στο σύνολο δεδομένων.

Ένα σύνολο δεδομένων που καλύπτει όλες αυτές τις προϋποθέσεις είναι γνωστό ως **Cab Mobility Traces** [26], [27]. Αυτό το σύνολο δεδομένων αποτελεί προϊόν της συνεργασίας μεταξύ του Exploratorium (το μουσείο επιστήμης, τέχνης και ανθρώπινης αντίληψης του San Francisco) και του καλλιτέχνη Scott Snibbe. Τα συγκεκριμένα δεδομένα προσφέρουν μια λεπτομερή εικόνα των μοτίβων κίνησης των κίτρινων ταξί στην πόλη του San Francisco. Το σύστημα δρόμων της πόλης, πάνω στο οποίο έχει γίνει η καταγραφή των δεδομένων φαίνεται στην ακόλουθη εικόνα:



**Εικόνα 5.1: Το οδικό δίκτυο της πόλης του San Francisco, California.**

Τα δεδομένα έχουν συγκεντρωθεί μέσω ενός καινοτόμου συστήματος παρακολούθησης GPS που έχει ενσωματωθεί σε κάθε κίτρινο ταξί της πόλης. Αυτό το σύστημα μεταδίδει δεδομένα πραγματικού χρόνου, περιλαμβάνοντας τον αριθμό ταυτοποίησης του ταξί, τις γεωγραφικές του συντεταγμένες (γεωγραφικό πλάτος και γεωγραφικό μήκος) εκείνη τη χρονική στιγμή, τον χρόνο που γίνεται η καταγραφή και την κατάσταση του ταξί, δηλαδή εάν εκτελεί δρομολόγιο ή όχι εκείνη τη χρονική στιγμή. Όλη αυτή η πληροφορία συγκεντρώνεται σε ένα κεντρικό διακομιστή.

Στο σύνολο δεδομένων Cab Mobility Traces καταγράφεται η κίνηση 536 ταξί κατά τον μήνα Μάιο του έτους 2008. Για κάθε ταξί, ο μέσος όρος δειγματοληψίας της θέσης του είναι περίπου 30 δευτερόλεπτα. Η πορεία κάθε ταξί ενσωματώνεται σε ένα ξεχωριστό αρχείο που φέρει ως όνομα το αναγνωριστικό του εκάστοτε ταξί. Συνολικά, όλα τα δεδομένα τροχιών των ταξί που υπάρχουν στο σύνολο δεδομένων αντιστοιχίζονται σε 11.000.000 εγγραφές περίπου, εκ των οποίων, εμείς χρησιμοποιούμε μόνο δεδομένα μίας εβδομάδας, δηλαδή περίπου 3.300.000 εγγραφές.

### **5.1.2 Δεδομένα Καιρού**

Η συμπερίληψη δεδομένων καιρού είναι απαραίτητη κατά την πρόβλεψη της κυκλοφοριακής ροής σε ένα οδικό δίκτυο, καθώς οι καιρικές συνθήκες έχουν έντονη επίδραση στη συμπεριφορά των οχημάτων και, κατά συνέπεια, στην κυκλοφοριακή κατάσταση των οδών. Ο καιρός μπορεί να

επηρεάσει την ταχύτητα, την ορατότητα, την πρόσφυση των ελαστικών, τη συμπεριφορά των οδηγών και την κυκλοφοριακή ροή. Επομένως, για να εξασφαλιστούν ακόμα καλύτερα αποτελέσματα, έχουν συμπεριληφθεί δεδομένα καιρού της πόλης του San Francisco κατά τον μήνα Μάιο του έτους 2008. Επιπλέον, τα δεδομένα καιρού που χρησιμοποιούνται έχουν καταγραφεί σε ωριαία βάση. Τα πιο σημαντικά στοιχεία που συμπεριλαμβάνονται σε αυτά είναι τα ακόλουθα:

- **θερμοκρασία:** η θερμοκρασία μπορεί να επηρεάσει την ταχύτητα των οχημάτων, καθώς και την ορατότητα.
- **υγρασία:** η υγρασία μπορεί να επηρεάσει την πρόσφυση των ελαστικών στον δρόμο και την ασφάλεια της οδήγησης.
- **ταχύτητα του ανέμου:** η ταχύτητα του ανέμου επηρεάζει την συμπεριφορά των οχημάτων και την σταθερότητα της κίνησης.
- **ατμοσφαιρική πίεση:** η ατμοσφαιρική πίεση μπορεί να προσφέρει πληροφορίες σχετικά με τις αλλαγές στις καιρικές συνθήκες και την πιθανή επίδρασή τους στην κυκλοφορία.
- **ορατότητα:** η ορατότητα είναι κρίσιμη για την ασφάλεια της οδήγησης και μπορεί να επηρεάσει την ταχύτητα και τον τρόπο κίνησης.

Αξίζει να σημειωθεί ότι η ανάλυση αυτών των δεδομένων παρέχει πολύτιμες πληροφορίες για τον τρόπο, με τον οποίο οι καιρικές συνθήκες επηρεάζουν την κυκλοφοριακή ροή. Η σύνδεση των δεδομένων καιρού με τα δεδομένα κίνησης μπορεί να αποκαλύψει ποιες συνθήκες οδήγησης έχουν τη μεγαλύτερη επίδραση στην κίνηση των οχημάτων, προσφέροντας ένα πληρέστερο και πιο περιεκτικό πλαίσιο για την κατανόηση των παραγόντων που επηρεάζουν την κυκλοφορία.

## 5.2 Προεπεξεργασία των Δεδομένων

Η αρχική φάση του κώδικα είναι αφιερωμένη στην συλλογή και την προετοιμασία του αρχικού συνόλου δεδομένων. Όσον αφορά την συλλογή των δεδομένων, λόγω του ότι αυτά βρίσκονται μοιρασμένα σε πολλά διαφορετικά αρχεία, προσπαθούμε να τα ενοποιήσουμε όλα μαζί σε ένα ενιαίο αρχείο. Το ενοποιημένο πλέον σύνολο δεδομένων είναι σχολαστικά δομημένο, ενσωματώνοντας τα εξής χαρακτηριστικά:

- **Taxi ID:** το μοναδικό αναγνωριστικό του κάθε Ταξί.
- **Latitude:** το γεωγραφικό πλάτος της θέσης του ταξί όταν έγινε η καταγραφή.
- **Longitude:** το γεωγραφικό μήκος της θέσης του ταξί όταν έγινε η καταγραφή.
- **Occupied:** δηλώνει εάν το ταξί μετέφερε επιβάτη/επιβάτες ή όχι όταν έγινε η καταγραφή της θέσης του (είναι η μόνη πληροφορία που δεν θα χρειαστεί στην έρευνά).
- **Date Time:** η ημερομηνία και η ώρα που έγινε η καταγραφή. Είναι της μορφής χρονιά-μήνας-ημέρα ώρα:λεπτό:δευτερολεπτο.

Υπενθυμίζεται ότι το σύνολο δεδομένων περιλαμβάνει περίπου έντεκα εκατομμύρια εγγραφές (Rows). Για να διευκολύνουμε την διαδικασία της έρευνάς, έχει περιοριστεί ο αριθμός των εγγραφών που χρησιμοποιούνται, απομονώνοντας αυτές που καταγράφηκαν κατά τη διάρκεια μιας εβδομάδας: από τις 18 έως τις 25 Μαΐου. Μάλιστα, θεωρήθηκε φρόνιμο το γεγονός ότι η κυκλοφοριακή ροή είναι ένα μέγεθος που για να προβλεφθεί η συμπεριφορά του δεν χρειάζεται να ανατρέξουμε πολύ πίσω στον χρόνο.

Το σύνολο δεδομένων είναι ιδανικό, καθώς περιέχει καταγραφές σημείων GPS ανά μικρά χρονικά διαστήματα. Ωστόσο, για κάθε διαφορετικό ταξί (δηλαδή για κάθε διαφορετικό «Taxi ID») υπάρχει μία συνεχόμενη ροή από καταγραφές θέσεων GPS. Επομένως, για κάθε ταξί διατίθεται μία μονοκομματική τροχιά. Όπως προτείνεται και στη μεθοδολογία, η διαδικασία διαχωρισμού της τροχιάς σε υποτροχιές καθίσταται απαραίτητη. Ουσιαστικά, θέλουμε σε κάθε υποτροχιά να περιλαμβάνονται σημεία GPS που απέχουν ανά δύο ένα συγκεκριμένο χρονικό διάστημα. Στην παρούσα έρευνα ορίζουμε ως μέγιστο χρονικό διάστημα τα ενενήντα (90) δευτερόλεπτα. Με άλλα λόγια, κάθε τροχιά ενός ταξί διαμοιράζεται σε υποτροχιές που περιέχουν διαδοχικά σημεία που απέχουν χρονικά ανά δύο έως και ενενήντα δευτερόλεπτα. Η προσέγγιση αυτή έρχεται να εισάγει μία καινούρια πληροφορία στο σύνολο δεδομένων, την στήλη «**Traj ID**» που δηλώνει το

αναγνωριστικό της υποτροχιάς. Πλέον, κάθε μοναδικό ζεύγος (Taxi ID, Traj ID) ταυτοποιεί μοναδικά μία τροχιά.

### 5.3 Αντιστοίχιση Τροχιών στο Οδικό Δίκτυο

Ένα επιπλέον πρόβλημα που προκύπτει με τα δεδομένα, είναι ότι οι τροχιές δεν έχουν αντιστοιχηθεί σε κάποιον ψηφιακό χάρτη. Εδώ η μεθοδολογία προτείνει μία διαδικασία αντιστοίχισης των σημείων GPS στο οδικό δίκτυο που διερευνείται. Ο κώδικας εκκινεί τη διαδικασία αντιστοίχισης τροχιών στον χάρτη της περιοχής του San Francisco, εκμεταλλευόμενο το Valhalla Meili API. Αυτό καθιστά δυνατή την ευθυγράμμιση των πορειών GPS του κάθε ταξί με το υποκείμενο οδικό δίκτυο. Κάθε τροχιά GPS που αναπαρίσταται από ζεύγη γεωγραφικού πλάτους και γεωγραφικού μήκους, υποβάλλεται ως αίτημα στον εξυπηρετητή του Valhalla Meili, λαμβάνοντας ως έξοδο ένα νέο σύνολο δεδομένων που φέρει το όνομα «visited\_segments» και περιέχει όλη την αντιστοιχιζόμενη πληροφορία, δηλαδή τις αντιστοιχιζόμενες τροχιές επάνω στο οδικό δίκτυο της πόλης. Συγκεκριμένα, η πληροφορία εξάγεται από το σύστημα trace attributes του Valhalla Meili και περιλαμβάνει τα ακόλουθα χαρακτηριστικά:


- **αναγνωριστικό ταξί (Taxi ID):** το μοναδικό αναγνωριστικό που αντιστοιχεί σε κάθε ταξί, επιτρέποντας τη διάκριση των μονοκόμματων τροχιών.
- **αναγνωριστικό τροχιάς (Traj ID):** το αναγνωριστικό της υποτροχιάς της μονοκόμματης-κύριας τροχιάς που διένυσε το ταξί με αναγνωριστικό Taxi ID.
- **αναγνωριστικό διαδρομής OSM (OSM Way ID):** δηλώνει το αναγνωριστικό της αντιστοιχιζόμενης στο οδικό δίκτυο ακμής.
- **ώρα έναρξης (Start Time):** χρονοσφραγίδα που υποδηλώνει τη στιγμή που η τροχιά εισέρχεται στην ακμή με αναγνωριστικό OSM Way ID.
- **ώρα λήξης (End Time):** χρονοσφραγίδα που υποδηλώνει τη στιγμή που η τροχιά εξέρχεται από την ακμή με αναγνωριστικό OSM Way ID.

Σύμφωνα με τα παραπάνω, στο καινούριο σύνολο δεδομένων που δημιουργήθηκε, για κάθε ξεχωριστή τροχιά (δηλαδή ένα μοναδικό ζεύγος Taxi ID και Traj ID) είναι γνωστές οι διαδοχικές ακμές που αυτή διένυσε, όπως και την χρονική στιγμή που αυτή εισήλθε και εξήλθε από κάθε ακμή.

### 5.4 Αναγωγή του Προβλήματος σε Χρονοσειρές

Σύμφωνα με την μεθοδολογία που προτάθηκε, το επόμενο βήμα αφορά στην κατασκευή ενός συνόλου δεδομένων που εστιάζει στην καταγραφή της ροής της κυκλοφορίας στο οδικό δίκτυο του San Francisco ανά μονοπάτι και ανά χρονικό διάστημα. Για αυτή την διαδικασία χρησιμοποιούνται όλα τα αντιστοιχισμένα στο οδικό δίκτυο δεδομένα που υπάρχουν στα δεδομένα «visited\_segments». Στην διάθεσή μας έχουμε πληροφορία μίας ολόκληρης εβδομάδας. Επομένως, χωρίζουμε αυτό το μεγάλο χρονικό διάστημα σε μικρότερα διαστήματα διάρκειας μισής ώρας έκαστο. Δηλαδή, σε κάθε ημέρα αντιστοιχούν  $(24 \text{ ώρες} * 60 \text{ λεπτά}) / 30 \text{ λεπτά} = 48$  χρονικά διαστήματα μισής ώρας.

Προχωρώντας, πρέπει να οριστούν τα μονοπάτια, πάνω στα οποία θα γίνει η ανάλυση της κυκλοφοριακής ροής. Για αυτό τον λόγο δημιουργούνται χίλια μοναδικά μονοπάτια. Το μήκος αυτών των μονοπατιών μπορεί να κυμαίνεται από δύο έως και δεκαπέντε ακμές. Η αιτία επιλογής χιλίων μόνο μονοπατιών αφορά στην επιτάχυνση της εκτέλεσης του κώδικα. Κάθε μονοπάτι αντιπροσωπεύει μια ακολουθία συνεχόμενων οδικών ακμών που έχει διανύσει ένα ταξί. Οι ακμές αυτές δεν είναι τυχαίες, αλλά πηγάζουν άμεσα από τα δεδομένα διασφαλίζοντας πάντα ότι τα μονοπάτια που δημιουργούνται ακολουθούν την ιδιότητα της συνέχειας, όπως αυτή ορίστηκε στο πρώτο κεφάλαιο. Στο παρακάτω γράφημα φαίνεται το πλήθος των μονοπατιών που δημιουργούνται (κατακόρυφος άξονας) ως προς το μήκος των ακμών τους (οριζόντιος άξονας).



**Διάγραμμα 5.1: Κατανομή μονοπατιών ως προς το μήκος των ακμών τους.**

Πλέον, η κατασκευή των χρονοσειρών είναι εύκολη υπόθεση, αφού τα δομικά συστατικά που αποτελείται είναι στην διάθεσή μας. Για την τελική δημιουργία της χρονοσειριακής πληροφορίας χρησιμοποιείται ο αλγόριθμος SPQ. Σε κάθε κλήση της συνάρτησης, της δίνουμε ως είσοδο το μονοπάτι που θέλουμε να γίνει η καταμέτρηση της κυκλοφορίας και το εκάστοτε μισάωρο χρονικό διάστημα.

Επαναλαμβάνοντας αυτή τη διαδικασία για κάθε μονοπάτι και για κάθε μισάωρο χρονικό διάστημα, λαμβάνουμε ως αποτέλεσμα ένα νέο σύνολο δεδομένων αποτελούμενο από χίλιες χρονοσειρές, μία για κάθε μονοπάτι. Οι χρονοσειρές αποθηκεύονται σε έναν πίνακα με όνομα «time\_series\_SPQ». Κάθε εγγραφή σε αυτόν τον πίνακα περιλαμβάνει το μονοπάτι (δηλαδή την λίστα από τις ακμές που αποτελείται), την τροχιά (Taxi ID, Traj ID) που βρίσκεται αυτό το μονοπάτι, το μήκος του μονοπατιού ως προς τις ακμές του και το πλήθος των ταξί που διέσχισαν το συγκεκριμένο μονοπάτι σε κάθε μισάωρο διάστημα. Συγκεκριμένα, οι στήλες που αποτελείται ο νέος πίνακας είναι οι εξής: «Path», «Length», «Taxi ID», «Traj ID» και τα ανάλογα χρονικά διαστήματα. Κάθε χρονικό διάστημα μισής ώρας είναι και μία διαφορετική στήλη στον πίνακα.

	Taxi ID	Traj ID	Path	Length	2008-05-18 00:00:00	2008-05-18 00:30:00	2008-05-18 01:00:00	2008-05-18 01:30:00	2008-05-18 02:00:00	2008-05-18 02:30:00	...
0	255	408	[38855344, 38855344]	2	1	2	4	4	1	14	...
1	111	199	[1112271467, 1112271467, 1112271468]	3	15	15	15	18	14	12	...
2	348	51	[1166095110, 1166095110, 1166095110, 397144264...]	7	26	29	30	26	27	26	...
3	388	56	[225806030, 225806030]	2	10	20	27	29	39	29	...
4	151	268	[8921980, 48101169, 48191415, 839813773, 89155...]	11	6	9	5	8	6	7	...

**Εικόνα 5.2: Το τελικό σύνολο δεδομένων.**

Όπως είναι πλέον γνωστό, οι καιρικές συνθήκες επηρεάζουν συχνά την κυκλοφορία στους δρόμους. Για αυτό τον λόγο, στα δεδομένα κίνησης προστίθενται και δεδομένα καιρού, όπως ακριβώς περιεγράφηκαν στην υποενότητα 5.1.2


Ταυτόχρονα, εξάγουμε πολλά χαρακτηριστικά που σχετίζονται με τον χρόνο. Η διαδικασία αυτή γίνεται με την βοήθεια των χρονοσφραγίδων (Timestamps) που υπάρχουν στα δεδομένα μας. Τα χαρακτηριστικά αυτά περιλαμβάνουν την ώρα, την ημέρα της εβδομάδας, την ημέρα του μήνα και τα λεπτά. Έπειτα, εφαρμόζεται κυκλική κωδικοποίηση στα χαρακτηριστικά αυτά, η οποία αποτυπώνει την κυκλική φύση τους σε όρους ημιτόνων και συνημίτονων. Για παράδειγμα, μία ημέρα έχει εικοσιτέσσερις (24) ώρες. Αυτή η ροή των εικοσιτεσσάρων ωρών επαναλαμβάνεται

κυκλικά και, επομένως, μπορεί να κωδικοποιηθεί με την βοήθεια ημιτόνων και συνημίτονων. Το ίδιο ισχύει και για τις ημέρες της εβδομάδας, για τα λεπτά της ώρας κ.ο.κ.

Επιπρόσθετα, εισάγουμε το χαρακτηριστικό «3hour\_interval», για να υποδεικνύουμε σε ποιο 3-ωρο χρονικό διάστημα της ημέρας εντοπίζεται η εκάστοτε καταγραφή. Το χαρακτηριστικό αυτό λαμβάνει τιμές από το ένα έως και το οκτώ (αφού 24 ώρες ανά ημέρα / 3 ώρες = 8 διαστήματα ανά ημέρα). Αυτή η πληροφορία μπορεί ενδεχομένως να αναδείξει τις διακυμάνσεις στη ροή της κυκλοφορίας κατά τη διάρκεια διαφορετικών τμημάτων της ημέρας.

## 5.5 Οπτικοποίηση των δεδομένων


Μία από τις βασικές αρχές στην επιστήμη των δεδομένων αποτελεί η οπτικοποίηση των δεδομένων. Με αυτόν τον τρόπο, ο ερευνητής μπορεί εύκολα να κατανοήσει σημαντικές πτυχές στα δεδομένα που δεν μπορούν να παρατηρηθούν αλλιώς. Σε αυτό το υποκεφάλαιο προσπαθούμε να ανακαλύψουμε την συμπεριφορά της κυκλοφοριακής ροής στο χρονικό διάστημα της μίας εβδομάδας που εξετάζουμε χρησιμοποιώντας διαγράμματα.



**Διάγραμμα 5.2: Συνολική ροή κυκλοφορίας κάθε ημέρα.**

Στο παραπάνω διάγραμμα (Διάγραμμα 5.2) φαίνεται η συνολική ροή της κυκλοφορίας, δηλαδή το άθροισμα της κυκλοφοριακής ροής σε όλα τα μονοπάτια του συνόλου δεδομένων, ανά μισάωρο χρονικό διάστημα. Στον οριζόντιο άξονα έχει τοποθετηθεί ο χρόνος, ο οποίο κυμαίνεται από τις δεκαοκτώ (18) έως και εικοσιτέσσερις (24) του Μαΐου. Το χρώμα της γραμμής αντιπροσωπεύει την ημέρα της εβδομάδας. Μέσα από αυτό το γράφημα μπορούμε να παρατηρήσουμε πως αλλάζει η ροή της κυκλοφορίας κατά τη διάρκεια της εβδομάδας. Συγκεκριμένα, σε κάθε ημέρα, κατά τις πρωινές και βραδινές ώρες η κυκλοφοριακή ροή είναι αυξημένη, ενώ τις μεσημεριανές και απογευματινές ώρες παρατηρείται μικρότερη κινητικότητα στα μονοπάτια. Επομένως, υπάρχει μία σταθερή περιοδικότητα στα δεδομένα.

Στην συνέχεια, γίνεται μία αναλυτικότερη απεικόνιση της κυκλοφοριακής ροής με βάση την ημέρα και το 3-ωρο χρονικό διάστημα. Για παράδειγμα, στο επόμενο γράφημα (Διάγραμμα 5.3) χωρίζεται το άθροισμα της κυκλοφοριακής ροής όλων των μονοπατιών κατά την ημέρα 2008-05-18 σε 3-ωρα χρονικά διαστήματα. Κάθε τρίωρο χρονικό διάστημα φαίνεται με διαφορετικό χρώμα. Η πληροφορία σε κάθε άξονα είναι η ίδια όπως και στο προηγούμενο διάγραμμα.



**Διάγραμμα 5.3 Η κυκλοφοριακή ροή κατά την ημέρα 2008-05-18.**

Η παραπάνω απεικόνιση μας επιτρέπει να αναφέρουμε ότι κατά το τέταρτο τρίωρο της συγκεκριμένης ημέρας παρατηρήθηκε η χαμηλότερη αθροιστική κυκλοφορία. Από την άλλη, κατά το τρίτο τρίωρο παρατηρήθηκε η υψηλότερη αθροιστική κυκλοφορία. Επιπλέον, μπορεί να εκφραστεί με σιγουριά ότι στα πρώτα τρία τρίωρα, δηλαδή τις πρώτες εννέα ώρες της ημέρας υπάρχει αυξημένη κινητικότητα, ενώ στο τέταρτο τρίωρο (δηλαδή για τις επόμενες τρεις ώρες) παρατηρείται χαμηλή κινητικότητα κ.ο.κ.

Με παρόμοια γραφήματα, εξετάζεται η κυκλοφοριακή ροή ανά τρίωρο για κάθε μία από τις υπόλοιπες ημέρες της εβδομάδας. Γενικά, μέσω αυτών των διαγραμμάτων, γίνονται κατανοητά τα παρακάτω:

- συνολική κυκλοφορία κάθε ημέρας: καθίστανται ευδιάκριτες οι τάσεις και τα μοτίβα της κυκλοφορίας κατά τη διάρκεια της εβδομάδας. Παρατηρείται εάν υπάρχει κάποια συγκεκριμένη μέρα με υψηλότερη ή χαμηλότερη κυκλοφορία.
- κορυφές και κοιλάδες: μπορούμε να εντοπίζουμε τις ώρες κατά τις οποίες η κυκλοφορία είναι στο αποκορύφωμά της κατά τη διάρκεια μιας συγκεκριμένης ημέρας. Ταυτόχρονα, εντοπίζεται εύκολα πότε η κυκλοφοριακή ροή είναι χαμηλή.
- συγκρίσεις ημερών: δίνεται δυνατότητα να συγκρίνουμε την κυκλοφορία μεταξύ διαφορετικών ημερών της εβδομάδας και να παρατηρούμε αν υπάρχουν διαφορές στα μοτίβα κυκλοφορίας μεταξύ των ημερών.

## 5.6 Χρήση Μοντέλων Μηχανικής και Βαθιάς Μάθησης

Αφού έχει κατασκευαστεί το τελικό σύνολο δεδομένων και έχουν παραχθεί γραφήματα που εξηγούν αυτά τα δεδομένα, το επόμενο βήμα στην μεθοδολογία είναι να ορίσουμε αλγορίθμους μηχανικής και βαθιάς μάθησης με στόχο την πρόβλεψη της κυκλοφοριακής ροής. Στην έρευνα έχουν χρησιμοποιηθεί τέσσερα μοντέλα - Random Forest, XGBoost, LSTM και Encoder - Decoder - που επιλύουν το ίδιο πρόβλημα στα ίδια δεδομένα. Ωστόσο, λόγω της διαφορετικής φύσης του κάθε αλγορίθμου, τα αποτελέσματα των προβλέψεων δεν είναι τα ίδια για κάθε μοντέλο.

Σε αυτό το υποκεφάλαιο δείχνουμε πως γίνεται η εκπαίδευση του καλύτερου μοντέλου που χρησιμοποιήθηκε, του XGBoost, και ποιες βελτιστοποιήσεις θεωρήσαμε υπόψιν. Ταυτόχρονα γίνεται μία εκτενής αναφορά για την επίδοση των υπολειπόμενων τριών μοντέλων που εκμεταλλευτήκαμε.


### 5.6.1 Διαχωρισμός σε Σύνολα Εκπαίδευσης, Ελέγχου και Επικύρωσης

Σε αυτό το βήμα, τα δεδομένα διαιρούνται σε δύο σύνολα: το **σύνολο εκπαίδευσης** και το **σύνολο ελέγχου**. Το πρώτο σύνολο αποτελείται από δεδομένα που θα χρησιμοποιηθούν για την εκπαίδευση κάθε αλγορίθμου μηχανικής μάθησης, ενώ τα δεδομένα ελέγχου χρησιμοποιούνται για την αξιολόγησή τους. Τελευταίο αλλά εξίσου σημαντικό είναι και το **σύνολο επικύρωσης** (Validation Set) που χρησιμοποιούμε εκτεταμένα στην έρευνά μας. Τα δεδομένα αυτά χρησιμοποιούνται για τη βελτιστοποίηση των υπερπαραμέτρων των μοντέλων κατά τη διάρκεια της εκπαίδευσης, εξασφαλίζοντας πως το μοντέλο γενικεύει καλά σε νέα δεδομένα, χωρίς να

επηρεάζεται από την επίδοσή του στα δεδομένα εκπαίδευσης. Το σύνολο επικύρωσης ταυτίζεται με το σύνολο ελέγχου στην μελέτη αυτή.

Το χρονικό διάστημα όλων των παρατηρήσεων που υπάρχουν στην διάθεσή μας κυμαίνεται μεταξύ των ημερομηνιών 2008-05-18 και 2008-05-24. Στην μελέτη αποφασίστηκε το σύνολο εκπαίδευσης να περιέχει όλα τα δεδομένα για κάθε μονοπάτι μέχρι και την 2008-05-23. Τα υπόλοιπα δεδομένα (τα πιο πρόσφατα) θα βρίσκονται στα σύνολα ελέγχου και επικύρωσης.

Αφού γίνει ο διαχωρισμός σε σύνολα εκπαίδευσης, ελέγχου και επικύρωσης, προσπαθούμε να επιλέξουμε εκείνα τα χαρακτηριστικά που θα βοηθήσουν τους αλγόριθμους να προβλέψουν τις εκάστοτε τιμές της κυκλοφοριακής ροής, γνωστά και ως **features**. Η επιλογή των τελευταίων γίνεται με την βοήθεια της μήτρας συσχέτισης που φαίνεται στην ακόλουθη εικόνα:



**Διάγραμμα 5.4: Μήτρα συσχέτισης του συνόλου δεδομένων.**

Από την μήτρα συσχέτισης προκύπτουν πολλές πληροφορίες για τις σχέσεις των χαρακτηριστικών. Για παράδειγμα, τα χαρακτηριστικά «hour» και «hour sin» φαίνεται να έχουν αρνητική γραμμική συσχέτιση (κοντά στο -1), ενώ τα «sea level pressure» και «day of week cos» έχουν θετική γραμμική συσχέτιση (κοντά στο 1). Τέλος, τα χαρακτηριστικά «Traffic Flow» και «Length» δεν έχουν γραμμική σχέση μεταξύ τους (τιμή κοντά στο 0).

Όλα τα χαρακτηριστικά που υπάρχουν στο σύνολο δεδομένων που έχουμε υιοθετήσει και εξετάζονται ως προς την συσχέτισή τους είναι τα ακόλουθα είκοσι έξι (26): «Taxi ID», «Traj ID», «Path», «Length», «Traffic Flow», «temperature», «humidity», «wind\_speed», «visibility», «conditions\_overcast», «day\_of\_week», «conditions\_partially\_cloudy», «sea\_level\_pressure», «conditions\_clear», «hour», «day», «minute», «hour\_sin», «hour\_cos», «day\_of\_week\_sin», «day\_of\_week\_cos», «day\_sin», «day\_cos», «minute\_sin», «minute\_cos», «3hour\_interval».

Από όλα αυτά τα χαρακτηριστικά, εκείνα που δεν εισάγουν θόρυβο στο μοντέλο και αναπαριστούν μία μοναδική πληροφορία που, ίσως, βοηθήσει τους αλγόριθμους μηχανικής μάθησης είναι τα ακόλουθα δεκαεννέα (19): «Taxi ID», «Traj ID», «hour\_cos», «3hour\_interval», «visibility», «Path», «Length», «minute\_sin», «temperature», «day\_sin», «sea\_level\_pressure», «humidity», «day\_cos», «day\_of\_week\_sin», «conditions\_clear», «minute\_cos», «conditions\_overcast», «wind\_speed», «conditions\_partially\_cloudy».


## 5.6.2 Εκπαίδευση των μοντέλων

Όλα μοντέλα εκπαιδεύονται στο ίδιο σύνολο δεδομένων, χρησιμοποιώντας τα ίδια σύνολα εκπαίδευσης, ελέγχου και επικύρωσης, καθώς επίσης και τα ίδια features. Σε όλες τις περιπτώσεις, το χαρακτηριστικό προς πρόβλεψη είναι η κυκλοφοριακή ροή.



Στην συνέχεια, γίνονται δύο ενέργειες: η πρώτη αφορά τον μετασχηματισμό των συνόλων εκπαίδευσης και ελέγχου σε πρόβλημα μηχανικής μάθησης, εφαρμόζοντας την τεχνική του **συρόμενου παραθύρου**. Πριν γίνει αυτό, είναι απαραίτητο να ευρεθεί το βέλτιστο μήκος αυτού του παραθύρου. Η διαδικασία αυτή γίνεται σε συνδυασμό με το μοντέλο XGBoost, επειδή ο αλγόριθμος αυτός είναι πολύ ευέλικτος.

Για το σύνολο δεδομένων που υπάρχει στην κατοχή μας, έχουμε εκπαιδεύσει τον αλγόριθμο XGBoost χρησιμοποιώντας κάθε φορά διάφορα μήκη παραθύρου. Το παρακάτω γράφημα περιγράφει πως μειώνεται ή αυξάνεται το σφάλμα RMSE των προβλέψεων του συγκεκριμένου αλγορίθμου (κατακόρυφος άξονας), όταν αλλάζει το μήκος του παραθύρου (οριζόντιος άξονας).



**Διάγραμμα 5.5: Σφάλματα για διάφορα μήκη παραθύρου.**

Στην συγκεκριμένη περίπτωση, εκπαιδεύουμε και αξιολογούμε το μοντέλο σε διάφορα μήκη παραθύρου που κυμαίνονται από δύο (2) έως έξι (6) παρελθοντικά χρονικά βήματα. Παρατηρούμε ότι για ένα μέγεθος παραθύρου έξι χρονικών βημάτων στο παρελθόν, η μετρική RMSE του μοντέλου XGBoost είναι βέλτιστη.

Τα νέα χαρακτηριστικά που δημιουργούνται με την τεχνική του κυλιόμενου παραθύρου είναι τα «Traffic\_Flow(t-6)», «Traffic\_Flow(t-5)», «Traffic\_Flow(t-4)», «Traffic\_Flow(t-3)», «Traffic\_Flow(t-2)» και «Traffic\_Flow(t-1)», τα οποία απορρέουν άμεσα από το χαρακτηριστικό «Traffic Flow». Για να γίνουμε πιο σαφείς, το  $t-b$ , όπου  $1 \leq b \leq 6$ , δηλώνει την κυκλοφοριακή ροή  $b$  χρονικά βήματα στο παρελθόν. Αφού έχουμε τροποποιήσει το σύνολο δεδομένων σε παράθυρα, εισάγουμε, επιπλέον, τα χαρακτηριστικά «rolling\_mean» και «rolling\_variance» που υπολογίζουν τον μέσο όσο και την διακύμανση των τιμών που βρίσκονται σε κάθε παράθυρο.

Στο εξής, για κάθε μοντέλο που εκπαιδεύεται, θεωρούμε ότι λαμβάνει ως είσοδο την ακόλουθη πληροφορία: έξι παρελθοντικές τιμές του μεγέθους της κυκλοφοριακής ροής, τον μέσο όρο και την διακύμανση σε κάθε παράθυρο, καθώς επίσης και δεδομένα καιρού και δεδομένα χρόνου, όπως αυτά εξηγήθηκαν στην υποενότητα 5.6.1. Όλα αυτά τα χαρακτηριστικά χρησιμοποιούνται προκειμένου τα μοντέλα να προβλέπουν την αμέσως επόμενη τιμή του μεγέθους της κυκλοφοριακής ροής που συμβολίζεται ως «Traffic Flow (t)».

Η δεύτερη ενέργεια που πρέπει να γίνει αφορά στην βελτιστοποίηση των μοντέλων. Κάθε μοντέλο που εξετάζουμε περιέχει ορισμένες υπερπαραμέτρους που ορίζονται από τον ίδιο τον χρήστη. Αυτό έχει ως αποτέλεσμα να ευρεθεί ένας τρόπος, ώστε τα μοντέλα αυτά να ορίζονται με τις βέλτιστες τιμές για κάθε μία υπερπαραμέτρο που διαθέτουν. Ο τρόπος με τον οποίο ευρίσκουμε αυτές τις υπερπαραμέτρους είναι κοινός για τα μοντέλα XGBoost και Random Forest. Επίσης, με παρόμοιο, αλλά διαφορετικό τρόπο ευρίσκονται οι υπερπαραμέτροι για το ζεύγος μοντέλων LSTM και Encoder-Decoder.




Στην περίπτωση των δύο πρώτων μοντέλων, χρησιμοποιείται η μέθοδος της **αναζήτησης πλέγματος πολλαπλής διεπικύρωσης** (Grid Search Cross Validation ή Grid Search CV). Η μέθοδος αυτή λειτουργεί εφαρμόζοντας τα παρακάτω βήματα:

1. ορίζεται μια λίστα πιθανών τιμών για κάθε υπερπαραμέτρο που χρειάζεται να βελτιστοποιηθεί.
2. η μέθοδος Grid Search CV δημιουργεί όλους τους δυνατούς συνδυασμούς των τιμών των υπερπαραμέτρων που έχουν καθοριστεί. Για παράδειγμα, εάν έχουν οριστεί δύο υπερπαραμέτροι προς βελτιστοποίηση, καθεμία με τρεις δυνατές τιμές, θα δημιουργηθούν συνολικά  $3 * 3 = 9$  διαφορετικοί συνδυασμοί υπερπαραμέτρων.
3. για κάθε συνδυασμό υπερπαραμέτρων, το μοντέλο εκπαιδεύεται με αυτές και αξιολογείται μέσω της τεχνικής της πολλαπλής διεπικύρωσης (Cross Validation). Η μέθοδος αυτή θέλει το σύνολο εκπαίδευσης να διαχωρίζεται σε μικρότερα υποσύνολα, τα τμήματα (Folds). Κάθε φορά, ένα μόνο τμήμα αντιπροσωπεύει τα δεδομένα επικύρωσης (Validation Fold), ενώ τα υπόλοιπα χρησιμοποιούνται ως σύνολο εκπαίδευσης (Training Folds). Αυτή η διαδικασία επαναλαμβάνεται πολλές φορές, ώσπου κάθε fold να έχει αναλάβει τον ρόλο των δεδομένων επικύρωσης. Σε κάθε επανάληψη υπολογίζεται το σφάλμα των προβλέψεων. Στο τέλος, η μέση τιμή των σφαλμάτων κάθε επανάληψης χρησιμοποιείται, για να αξιολογηθεί η απόδοση του μοντέλου για τον συγκεκριμένο συνδυασμό υπερπαραμέτρων.
4. μετά την αξιολόγηση όλων των συνδυασμών, η GridSearchCV επιλέγει τον συνδυασμό υπερπαραμέτρων που παρήγαγε τα καλύτερα αποτελέσματα.

Συμπεραίνοντας, είναι κατανοητό ότι η παρούσα μεθοδολογία αποτελεί μια πολύ χρήσιμη τεχνική για την αυτοματοποίηση της διαδικασίας επιλογής υπερπαραμέτρων και τη βελτιστοποίηση της απόδοσης ενός μοντέλου.

Από την άλλη πλευρά, έγιναν βελτιστοποιήσεις και στα δύο μοντέλα νευρωνικών δικτύων. Για παράδειγμα, έχουν εισαχθεί πυκνά επίπεδα (Dense Layers) και επίπεδα εγκατάλειψης (Dropout Layers). Ο ρόλος των πρώτων είναι να βοηθούν το μοντέλο να παρατηρεί μη γραμμικές σχέσεις από τα δεδομένα, ενώ ο ρόλος των επιπέδων εγκατάλειψης είναι να «απενεργοποιούν» κατά την φάση της εκπαίδευσης έναν συγκεκριμένο αριθμό νευρώνων του δικτύου, προκειμένου να αποφευχθεί το φαινόμενο της υπερεκπαίδευσης.

Μετά από όλη αυτή την διαδικασία που περιεγράφηκε παραπάνω, παρουσιάζονται στο γράφημα 5.6 οι επιδόσεις όλων των μοντέλων στα δεδομένα ελέγχου της χρονοσειράς που αντιστοιχεί στο μονοπάτι με αριθμό μηδέν (0). Στον οριζόντιο άξονα βρίσκεται ο χρόνος, δηλαδή το διάστημα όλης της ημέρας 24 Μαΐου. Στον κατακόρυφο άξονα δηλώνεται η κυκλοφοριακή ροή.



**Διάγραμμα 5.6: Επίδοση των μοντέλων στο σύνολο ελέγχου που αντιστοιχεί στο μονοπάτι 0.**

Το γράφημα αυτό απεικονίζει την πραγματική τιμή της κυκλοφοριακής ροής με μπλε χρώμα. Με **πορτοκαλί** χρώμα φαίνονται οι προβλέψεις που παρήγαγε το μοντέλο XGBoost. Με **γκρι** χρώμα φαίνονται οι προβλέψεις που παρήγαγε το μοντέλο LSTM. Ταυτόχρονα, με **πράσινο** χρώμα φαίνονται οι προβλέψεις που έδωσε σαν έξοδο ο αλγόριθμος Random Forest. Τέλος, με **ροζ** χρώμα φαίνονται οι προβλέψεις του μοντέλου Encoder-Decoder.

Σε γενικές γραμμές, όλα τα μοντέλα έχουν καταφέρει να αναπαραστήσουν ικανοποιητικά τη συμπεριφορά της χρονοσειράς που αντιστοιχεί στο μονοπάτι με κωδικό μηδέν. Με τον όρο

«συμπεριφορά», εννοούμε την εξέλιξη της χρονοσειράς, πότε δηλαδή αυτή παρουσιάζει καθόδους και ανόδους. Επίσης, εννοούμε τις επαναλαμβανόμενες συμπεριφορές (μοτίβα) που παρατηρούνται ανά συγκεκριμένα χρονικά διαστήματα.

Στον επόμενο πίνακα φαίνονται για κάθε ένα από τα τέσσερα μοντέλα που χρησιμοποιήθηκαν, οι επιδόσεις τους σε όρους RMSE και MAE. Υπενθυμίζεται ότι όσο μικρότερος είναι ο δείκτης για κάθε μία από αυτές τις δύο μετρικές, τόσο καλύτερη είναι και η απόδοση του εκάστοτε μοντέλου:

Model	RMSE Score	MAE Score
XGBoost	2.80	1.72
LSTM	3.07	1.99
Random Forest	2.87	1.78
Encoder - Decoder	3.33	2.11

**Πίνακας 5.1: RMSE και MAE scores για κάθε μοντέλο.**

Σύμφωνα με τον παραπάνω πίνακα, εξάγουμε δύο συμπεράσματα. Πρώτο, το μοντέλο XGBoost είναι το καλύτερο μοντέλο, επιλύει δηλαδή το πρόβλημα με καλύτερες αποδόσεις σε σχέση με τα υπόλοιπα μοντέλα. Δεύτερο, αν και τα νευρωνικά δίκτυα που εφαρμόστηκαν στην μελέτη αυτή μπορούν να διαχειρίζονται τις χρονοσειρές με αποδοτικό τρόπο, συμπεραίνουμε ότι έχουν χειρότερες επιδόσεις από τους δένδροειδείς αλγόριθμους. Μία τέτοια παρατήρηση είναι χρήσιμη καθώς αποδεικνύεται ότι τα νευρωνικά δίκτυα με μνήμη δεν ανταποκρίνονται τέλεια σε κάθε σύνολο δεδομένων χρονοσειρών.

## 5.7 Αποτελέσματα


Σε αυτό το υποκεφάλαιο παρουσιάζονται οι προβλέψεις που έχουν πραγματοποιηθεί για το μέγεθος της κυκλοφοριακής ροής σε κάθε ένα από τα 1000 μονοπάτια που έχουμε ορίσει στην έρευνά μας. Αξίζει να σημειωθεί ότι οι προβλέψεις παρουσιάζουν τα ακόλουθα χαρακτηριστικά:

- έχουν δημιουργηθεί χρησιμοποιώντας τον αλγόριθμο XGBoost, λόγω του χαμηλότερου RMSE score που έχει, έναντι των υπολοίπων τριών μοντέλων.
- είναι βραχυπρόθεσμες. Αυτό συμβαίνει, διότι η κυκλοφοριακή ροή είναι ένα μέγεθος μη γραμμικό και πολυδιάστατο (Multidimensional). Εξαρτάται, δηλαδή, από πολλούς παράγοντες, όπως τα τροχαία ατυχήματα, οι εορτές και ο καιρός. Επομένως, η μακροπρόθεσμη πρόβλεψη ενός τέτοιου μεγέθους, όπως το κυκλοφοριακό φόρτο, φαντάζει μία διαδικασία δύσκολη και μη έγκυρη.


Η διαδικασία των προβλέψεων έχει πραγματοποιηθεί με τον ίδιο ακριβώς τρόπο που οργανώσαμε την διαδικασία της εκπαίδευσης και αξιολόγησης του μοντέλου: χρησιμοποιώντας δεδομένα καιρού και την τεχνική του κυλιόμενου παραθύρου. Κατά τη διάρκεια των προβλέψεων, χρησιμοποιούμε έξι παρελθοντικές τιμές του μεγέθους της κυκλοφοριακής ροής, για να προβλέψουμε την επόμενη τιμή του ίδιου μεγέθους.

Ο χρονικός ορίζοντας που εξάγουμε τις προβλέψεις ανέρχεται στις πρώτες εννέα ώρες μετά από το διάστημα της μίας εβδομάδας που μελετάμε. Με άλλα λόγια, το διάστημα στο οποίο γίνεται η εκπαίδευση και η αξιολόγηση των μοντέλων είναι από 2008-05-18 00:00:00 έως και 2008-05-24 23:30:00. Οι προβλέψεις γίνονται αμέσως μετά, δηλαδή στο διάστημα από 2008-05-25 00:00:00 έως και 2008-05-25 09:00:00.


Στα παρακάτω διαγράμματα επιλέγουμε τυχαία μονοπάτια, στα οποία αναπαρίσταται οι ήδη γνωστές τιμές του μεγέθους της κυκλοφοριακής ροής (με μπλε χρώμα) και οι προβλεπόμενες τιμές του ίδιου μεγέθους εννέα ώρες στο μέλλον (με κόκκινο χρώμα). Όλες οι προβλέψεις γίνονται με την βοήθεια του μοντέλου XGBoost.




**Διάγραμμα 5.7:** Γνωστές και προβλεπόμενες τιμές του μεγέθους της κυκλοφοριακής ροής στο μονοπάτι 0.



**Διάγραμμα 5.8:** Γνωστές και προβλεπόμενες τιμές του μεγέθους της κυκλοφοριακής ροής στο μονοπάτι 4.



**Διάγραμμα 5.9:** Γνωστές και προβλεπόμενες τιμές του μεγέθους της κυκλοφοριακής ροής στο μονοπάτι 36.



**Διάγραμμα 5.10: Γνωστές και προβλεπόμενες τιμές του μεγέθους της κυκλοφοριακής ροής στο μονοπάτι 83.**


Οι προβλέψεις που παρέχουμε για τα παραπάνω μονοπάτια χρησιμοποιώντας το μοντέλο XGBoost θεωρούμε πως είναι ικανοποιητικές. Ο εκπαιδευμένος αλγόριθμος μηχανικής μάθησης φαίνεται να έχει κατανοήσει σε μεγάλο βαθμό τις σχέσεις και τα μοτίβα που υπάρχουν στα δεδομένα εκπαίδευσης, με αποτέλεσμα οι νέες προβλέψεις που παράγει να ακολουθούν παρόμοια συμπεριφορά. Η χρονοσειρά κάθε ενός μονοπατιού παρουσιάζει ανόδους, καθόδους και έχει επαναλαμβανόμενες συμπεριφορές.

## 5.8 Χρησιμότητα των AEM στη Συλλογή Δεδομένων

Σε όλο το κείμενο τονίζουμε την αναγκαιότητα χρήσης της μεθοδολογίας των AEM, προκειμένου να μετρήσουμε την κυκλοφοριακή ροή μέσα σε ολόκληρα μονοπάτια. Παρακάτω, παρουσιάζονται δύο περιπτώσεις, στις οποίες φαίνεται ότι η χρήση των AEM είναι αναγκαία. Στην πρώτη περίπτωση δείχνουμε την πληροφορία που κατέχουμε όταν χρησιμοποιούμε τα AEM, σε αντιδιαστολή με την γνώση που έχουμε όταν η χρήση τους απουσιάζει. Στην δεύτερη περίπτωση, εκπαιδεύουμε ξανά τον αλγόριθμο XGBoost στα δεδομένα που έχουν παρασκευαστεί χωρίς την χρήση των AEM και συγκρίνουμε τις επιδόσεις του με τα αποτελέσματα που καταφέραμε προηγούμενο υποκεφάλαιο.

Για να ευρεθεί η διαφορά στα δεδομένα που συλλέγουμε όταν απουσιάζει η χρήση της μεθοδολογίας των AEM, δημιουργούμε ένα καινούριο σύνολο δεδομένων χρονοσειρών. Η κύρια διαφορά τώρα είναι ότι σε κάθε μονοπάτι δεν μετράμε την κυκλοφοριακή ροή με την βοήθεια της συνάρτησης SPQ. Σε αυτή την περίπτωση, η κυκλοφοριακή ροή σε κάθε μονοπάτι ορίζεται ως το πλήθος των τροχιών που έχουν διανύσει τουλάχιστον μία φορά όλες τις ακμές που απαρτίζουν το μονοπάτι εντός ενός συγκεκριμένου χρονικού διαστήματος. Επομένως, δεν μας ενδιαφέρει εάν το κινούμενο όχημα παρέκκλινε της πορείας του ή εάν διέτρεξε τις ακμές του μονοπατιού με διαφορετική σειρά.


Το παρακάτω γράφημα δείχνει την διαφορά ανάμεσα στα δύο σύνολα δεδομένων. Με μπλε χρώμα απεικονίζεται η πληροφορία που υπάρχει στο πρώτο σύνολο δεδομένων εφαρμόζοντας την μέθοδο των AEM, ενώ με πορτοκαλί χρώμα παρουσιάζεται η καταγραφή των δεδομένων κίνησης όταν δεν γίνεται χρήση αυτής της μεθόδου. Επίσης, για κάθε χρονική στιγμή έχουμε συμπεριλάβει το άθροισμα όλων των ταξί που διένυσαν όλα τα μονοπάτια του συνόλου δεδομένων εκείνη τη χρονική στιγμή.



**Διάγραμμα 5.11:** Πληροφορία που συλλέγεται με και χωρίς την συνάρτηση SPQ.

Αξιοσημείωτο είναι το γεγονός ότι η κυκλοφοριακή ροή παρουσιάζει παρόμοια συμπεριφορά και στα δύο σύνολα δεδομένων. Ωστόσο, η παρουσία περιορισμών που διακατέχει την μέθοδο των ΑΕΜ οδηγεί σε εγκυρότερα δεδομένα. Προτιμάται, λοιπόν, η χρήση των ΑΕΜ, αφού αναφερόμαστε σε κινητικότητα μέσα σε ολόκληρο μονοπάτι.

Επιπρόσθετα, έχουμε εκπαιδεύσει τον αλγόριθμο XGBoost στο σύνολο δεδομένων που έχει δημιουργηθεί εν απουσία της μεθόδου των ΑΕΜ. Η διαδικασία εκπαίδευσης και αξιολόγησης είναι παρόμοια με αυτή που έχει εξηγηθεί σε προηγούμενη ενότητα. Μάλιστα, το μοντέλο αυτό έχει εκπαιδευτεί σε αυτά τα νέα δεδομένα ειδικά. Παρακάτω, φαίνονται οι πραγματικές τιμές της κυκλοφοριακής ροής (μπλε χρώμα) και οι αντίστοιχες προβλεπόμενες τιμές (πορτοκαλί χρώμα) για το μονοπάτι με κωδικό μηδέν.



**Διάγραμμα 5.12:** Απόδοση του αλγορίθμου XGBoost σε δεδομένα που έχουν δημιουργηθεί χωρίς την χρήση των ΑΕΜ.

Η απόδοση του μοντέλου XGBoost σε όρους RMSE και MAE παρουσιάζεται στον επόμενο πίνακα:

Model	RMSE Score	MAE Score
XGBoost	16.97	8.40

**Πίνακας 5.2:** Απόδοση του μοντέλου XGBoost

Παρατηρούμε ότι όταν χρησιμοποιούμε δεδομένα που έχουν προέλθει μέσω της εφαρμογής της μεθόδου των ΑΕΜ, το μοντέλο XGBoost ανταποκρίνεται πολύ καλύτερα, δίνοντας ως έξοδο πιο αξιόπιστες προβλέψεις. Αυτό συμβαίνει διότι τα ΑΕΜ μετράνε την κίνηση μέσα στο μονοπάτι αυτή κάθε αυτή, απαλλάσσοντας το σύνολο δεδομένων από θόρυβο. Έτσι, ο κάθε αλγόριθμος μηχανικής μάθησης που εφαρμόζεται είναι φυσιολογικό να παρουσιάζει καλύτερη απόδοση.

## 6. Συμπεράσματα και Προτάσεις για Βελτίωση

### Συμπεράσματα

Η κυκλοφοριακή ροή στους δρόμους είναι ένα μέγεθος που ασκεί άμεση και έμμεση επίδραση στις αποφάσεις και στις ενέργειες των ανθρώπων. Συγκεκριμένα, η ροή των οχημάτων επηρεάζει την ασφάλεια των οδηγών, τις χρονικές καθυστερήσεις και την ατμοσφαιρική ρύπανση. Έτσι, η πρόβλεψη της μελλοντικής κυκλοφοριακής ροής αναδύεται ως αναγκαία, διότι μπορεί να συμβάλει στην επίλυση αυτών των σημαντικών ζητημάτων.

Η παρούσα πτυχιακή εργασία αποκάλυψε ότι το προς πρόβλεψη μέγεθος είναι πολύπλοκο, αφού εξαρτάται από πολλούς παράγοντες και παρουσιάζει μη γραμμικές σχέσεις. Αυτή η πολυπλοκότητα αποτέλεσε μια σημαντική πρόκληση κατά την διαδικασία ανάλυσης και πρόβλεψης του εν λόγω μεγέθους. Παρ' όλα αυτά, καταφέραμε να αναπτύξουμε έναν αλγόριθμο μηχανικής μάθησης που ανταποκρίνεται ικανοποιητικά στις απαιτήσεις της έρευνας και μπορεί να γενικευτεί σε άγνωστα δεδομένα κίνησης της ίδιας δομής. Αυτό αποδεικνύεται τόσο στις επιδόσεις του μοντέλου στο σύνολο ελέγχου, όσο και στις προβλέψεις που αυτό έχει παράγει.

Παρά το γεγονός ότι τα δεδομένα καιρού μπορούν να συμβάλουν στην εξαγωγή ακριβέστερων αποτελεσμάτων για το μέγεθος της κυκλοφοριακής ροής, στην συγκεκριμένη έρευνα η χρήση τους δεν επέδειξε ιδιαίτερη βελτίωση στην ικανότητα εκμάθησης των μοντέλων μηχανικής μάθησης. Βέβαια, ένα τέτοιο πόρισμα δεν είναι σε καμία περίπτωση γενικά αποδεκτό, ωστόσο στην προκειμένη περίπτωση και με τα συγκεκριμένα δεδομένα τροχιών, η διαφορά δεν ήταν αισθητή.

### Προτάσεις για Βελτίωση

Στο πλαίσιο της παρούσας μελέτης, υπήρξε περιορισμός στις δυνατότητες που χρησιμοποιήθηκαν για την εκτέλεση των προβλέψεων. Αρχικά, για τον σκοπό της ανάλυσης, επικεντρωθήκαμε σε δεδομένα κίνησης ταξί εντός της πόλης του Σαν Φρανσίσκο. Παρόλο που τα εν λόγω δεδομένα εξυπηρέτησαν τον σκοπό της παρούσας πτυχιακής εργασίας, πρέπει να αποσαφηνιστεί ότι δεν αντιπροσωπεύουν εντελώς την πραγματική κυκλοφοριακή κίνηση στην εν λόγω πόλη. Με άλλα λόγια, δεν λαμβάνονται υπόψιν οι κινήσεις άλλων μεταφορικών μέσων, όπως τα λεωφορεία και τα αυτοκίνητα. Για τη βελτίωση αυτής της κατάστασης, προτείνεται η προσθήκη δεδομένων από διάφορους τύπους οχημάτων στο σύνολο δεδομένων που χρησιμοποιείται.

Παράλληλα, κατά την εξέλιξη της διαδικασίας πρόβλεψης, χρησιμοποιήθηκαν και δεδομένα καιρού. Ο καιρός αποτελεί έναν από τους βασικούς παράγοντες που επηρεάζουν την κυκλοφοριακή ροή. Επιπλέον δεδομένα, όπως οι εορτές και οι αργίες εντός της χρονικής περιόδου που εξετάζεται, αποδεικνύονται ιδιαίτερα σημαντικά και άξια εκμετάλλευσης για τη διαδικασία της πρόβλεψης.

Τέλος, όσον αφορά τα μοντέλα μηχανικής μάθησης, η ενδεχόμενη ενσωμάτωση ενός μοντέλου που θα λαμβάνει υπόψιν τη **χωρική** (Spatial) και **χρονική διάταξη** (Temporal) του προβλήματος αποτελεί μία προοπτική βελτίωσης. Υπό αυτήν την προσέγγιση, θα λαμβάνονται υπόψιν οι συνδέσεις μεταξύ μονοπατιών εντός του οδικού δικτύου, καθιστώντας εφικτή την εκμετάλλευση της πληροφορίας σε γειτονικά μονοπάτια. Η χωρική αυτή διάταξη θα δίνεται ως πληροφορία στον μοντέλο μαζί με τον χρόνο. Με τις προαναφερθείσες προσεγγίσεις, οι προβλέψεις ενδέχεται να παρουσιάζουν αυξημένη ακρίβεια.

## Πίνακας Ορολογιών

Σε αυτό το τμήμα του τόμου, παραθέτουμε την μετάφραση των ξενόγλωσσων όρων που υπάρχουν στο κείμενο στην ελληνική γλώσσα:

Ξενόγλωσσος όρος	Ελληνικός όρος
Artificial Intelligence	Τεχνητή Νοημοσύνη
Autoencoder	Αυτόματος Κωδικοποιητής
Batch	Δέσμη
Big Data	Μεγάλος Όγκος Δεδομένων
Classification	Ομαδοποίηση / Συσταδοποίηση
Convolutional	Συνελικτικός
Container	Κουτί
Correlation Matrix	Μήτρα Συσχέτισης
Dataset	Σύνολο Δεδομένων
Date	Ημερομηνία
Decision Tree	Δέντρο Απόφασης
Decoder	Αποκωδικοποιητής
Deep Learning	Βαθιά Μάθηση
Deep Neural Network	Βαθύ Νευρωνικό Δίκτυο
Dense Layer	Πυκνό Στρώμα
Dropout Layer	Στρώμα Εγκατάλειψης
Edge	Ακμή
Encoder	Κωδικοποιητής
End Time	Χρόνος Τέλους
Ensemble Learning	Μάθηση συνόλου
Evaluation	Αξιολόγηση
Evaluation Metric	Μετρική Αξιολόγησης
Features	Χαρακτηριστικά
Fold	Κομμάτι Δεδομένων
Forecast	Πρόβλεψη
Forget Gate	Πύλη Λησμόνησης
Gate	Πύλη
Gradient Boosting	Κάθοδος Βαθμίδας
Grid Search Cross Validation	Αναζήτηση πλέγματος με την μέθοδο της πολλαπλής διεπικύρωσης
Historical Data	Ιστορικά Δεδομένα
Hyperparameter	Υπερπαράμετρος
Index	Ευρετήριο
Input Gate	Πύλη Εισόδου
Internal State	Εσωτερική Κατάσταση
Intelligent Transport System	Ευφυή Συστήματα Μεταφορών
Label	Μέγεθος προς Πρόβλεψη
Latitude	Γεωγραφικό Πλάτος
Layer	Επίπεδο

Leaf Node	Φύλλο του Δέντρου
Length	Μήκος
Linear Regression	Γραμμική Παλινδρόμηση
Longitude	Γεωγραφικό Μήκος
Long-Term Prediction	Μακροπρόθεσμη Πρόβλεψη
Machine Learning	Μηχανική Μάθηση
Mean Absolute Error	Μέσο Απόλυτο Σφάλμα
Mean Absolute Percentage Error	Μέσο Απόλυτο Ποσοστιαίο Σφάλμα
Memory Cell	Κύτταρο Μνήμης
Model	Μοντέλο
Moving Object	Κινούμενο Αντικείμενο
Multidimensional	Πολυδιάστατος
Neural Network	Νευρωνικό Δίκτυο
Non-Linear	Μη Γραμμικός
Notebook	Σημειωματάριο
Occupied	Κατειλημμένος
Overfitting	Υπερεκπαίδευση
Output Gate	Πύλη Εξόδου
Path	Μονοπάτι
Pooling Unit	Μονάδα Ομαδοποίησης
Pruning	Κλάδεμα
Regression	Παλινδρόμηση
Road Network	Οδικό Δίκτυο
Root Mean Square Error	Ρίζα Μέσου Τετραγωνικού Σφάλματος
Root Node	Ριζικός Κόμβος
Row	Εγγραφή / Γραμμή
Seasonality	Περιοδικότητα
Server	Διακομιστής
Short-Term Prediction	Βραχυπρόθεσμη Πρόβλεψη
Sliding Window	Κυλιόμενο/Συρόμενο Παράθυρο
Spatial	Χωρικός
Start Time	Χρόνος Έναρξης
Strict Path Queries	Αυστηρά Ερωτήματα Μονοπατιού
Strong Learner	Ισχυρός μαθητής
Sub Trajectory	Υποτροχιά
Supervised Learning	Μάθηση υπό Επίβλεψη
Temporal	Χρονικός
Test Set	Σύνολο Ελέγχου
Time	Χρόνος
Timeseries	Χρονοσειρά
Timeseries Forecasting	Πρόβλεψη Χρονοσειρών
Timestamp	Χρονοσφραγίδα
Traffic Flow	Κυκλοφοριακή Ροή



Training	Εκπαίδευση
Training Fold	Κομμάτι Δεδομένων Εκπαίδευσης
Train Set	Σύνολο Εκπαίδευσης
Trajectory Splitting	Διαχωρισμός Τροχιάς
Trend	Τάση
Validation Fold	Κομμάτι Δεδομένων Επικύρωσης
Validation Set	Σύνολο Επικύρωσης
Visualization	Οπτικοποίηση
Weak Learner	Μη ισχυρός μαθητής
Window Length	Μέγεθος Παραθύρου

## Πίνακας Συντμήσεων – Αρκτικόλεξων – Ακρωνύμιων

Σε αυτό το κεφάλαιο, δίνεται η πλήρης αντιστοιχία για κάθε ένα ακρωνύμιο που συναντάται στο κείμενο.

Αρκτικόλεξο	Πλήρης Σημασία
AEM	Ακριβές Ερώτημα Μονοπατιού
ΚΑ	Κινούμενο Αντικείμενο
κ.α.	Και Άλλα
κ.ο.κ.	Και Ούτω Καθεξής
ΟΕΛ	Οργανισμός Ελεύθερου Λογισμικού
π.χ.	Παραδείγματος Χάρη
ΣΔΒΔ	Σύστημα Διαχείρισης Βάσεων Δεδομένων
ARIMA	Autoregressive Integrated Moving Average
DBMS	Database Management System
Edge ID	Edge Identification Number
GPS	Global Positioning System
GPU	Graphics Processing Unit
GRU	Gated Recurrent Unit
HDAM	High-Dimensional Attention Mechanism
IP	Internet Protocol
ITS	Intelligent Transport Systems
LSTM	Long Short-Term Memory
MAE	Mean Absolute Error
MAPE	Mean Absolute Percentage Error
NN	Neural Network
OSM	Open Street Map
OSM Way ID	Open Street Map Way Identification Number
PL/pgSQL	Procedural Language/PostgreSQL
RMSE	Root Mean Square Error
RNN	Recurrent Neural Network
RW	Random Walk
SAE	Stacked Autoencoder
SARIMA	Seasonal AutoRegressive Integrated Moving Average
Seq2Seq	Sequence to Sequence
SPQ	Strict Path Query
SVM	Support Vector Machine
Taxi ID	Taxi Identification Number
Traj ID	Trajectory Identification Number
WD	Wavelet Decomposition

## Βιβλιογραφικές Πηγές

- [1] B. Krogh, N. Pelekis, Y. Theodoridis, and K. Torp, "Path-based queries on trajectory data," *Proceedings of the 22nd ACM SIGSPATIAL International Conference on Advances in Geographic Information Systems*, 2014. doi:10.1145/2666310.2666413
- [2] T. Chen and C. Guestrin, "XGBoost," *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 2016. doi:10.1145/2939672.2939785
- [3] R. C. Staudemeyer and Eric Rothstein Morris, "Understanding LSTM -- a tutorial into Long Short-Term Memory Recurrent Neural Networks," arXiv (Cornell University), Sep. 2019.
- [4] Y. Lv, Y. Duan, W. Kang, Z. Li, and F.-Y. Wang, "Traffic flow prediction with Big Data: A deep learning approach," *IEEE Transactions on Intelligent Transportation Systems*, pp. 1–9, 2014. doi:10.1109/tits.2014.2345663
- [5] L. Breiman, *Random Forests*, pp. 1–2, 2001.
- [6] Y. Tian and L. Pan, "Predicting short-term traffic flow by long short-term memory recurrent neural network," *2015 IEEE International Conference on Smart City/SocialCom/SustainCom (SmartCity)*, 2015. doi:10.1109/smartcity.2015.63
- [7] H. Tampubolon and Pao-Ann Hsiung, "Supervised deep learning based for traffic flow prediction," *2018 International Conference on Smart Green Technology in Electrical and Information Systems (ICSGTEIS)*. <https://doi.org/10.1109/icsgteis.2018.8709102>
- [8] R. Jiang *et al.*, "DeepCrowd: A deep model for large-scale citywide crowd density and flow prediction (extended abstract)," *2022 IEEE 38th International Conference on Data Engineering (ICDE)*, 2022. doi:10.1109/icde53745.2022.00136
- [9] M. Lu, K. Zhang, H. Liu, and N. Xiong, "Graph Hierarchical Convolutional Recurrent Neural Network (GHCRNN) for Vehicle Condition Prediction," *arXiv (Cornell University)*, Mar. 2019, doi: <https://doi.org/10.48550/arxiv.1903.06261>.
- [10] X. Dong, T. Lei, S. Jin, and Z. Hou, "Short-term traffic flow prediction based on xgboost," *2018 IEEE 7th Data Driven Control and Learning Systems Conference (DDCLS)*, 2018. doi:10.1109/ddcls.2018.8516114
- [11] "Python history - javatpoint," [www.javatpoint.com](http://www.javatpoint.com), <https://www.javatpoint.com/python-history> (accessed Aug. 17, 2023).
- [12] "Pandas," [pandas](https://pandas.pydata.org/), <https://pandas.pydata.org/> (accessed Aug. 17, 2023).
- [13] NumPy, <https://numpy.org/> (accessed Aug. 17, 2023).
- [14] "Scikit Learn," [scikit](https://scikit-learn.org/stable/index.html), <https://scikit-learn.org/stable/index.html> (accessed Aug. 17, 2023).
- [15] "Tensorflow," TensorFlow, <https://www.tensorflow.org/> (accessed Aug. 17, 2023).

- [16] K. Team, “Simple. flexible. powerful.” Keras, <https://keras.io/> (accessed Aug. 17, 2023).
- [17] “Visualization with python,” Matplotlib, <https://matplotlib.org/> (accessed Aug. 17, 2023).
- [18] “Statistical Data Visualization” seaborn, <https://seaborn.pydata.org/> (accessed Aug. 17, 2023).
- [19] “Project jupyter,” Project Jupyter, <https://jupyter.org/> (accessed Aug 17, 2023).
- [20] “Google Colab,” Google colab, <https://colab.research.google.com/> (accessed Aug 17, 2023).
- [21] *ΕΡΩΤΗΜΑΤΑ ΑΚΡΙΒΟΥΣ ΤΡΟΧΙΑΣ ΣΕ ΒΑΣΕΙΣ ΔΕΔΟΜΕΝΩΝ ΚΙΝΟΥΜΕΝΩΝ ΑΝΤΙΚΕΙΜΕΝΩΝ*, Feb. 2015.
- [22] P. G. D. Group, PostgreSQL, <https://www.postgresql.org/> (accessed Aug. 18, 2023).
- [23] “Accelerated Container Application Development,” Docker, <https://www.docker.com/> (accessed Aug. 18, 2023).
- [24] “Vahhalla API,” Valhalla Docs, <https://valhalla.github.io/valhalla/> (accessed Aug. 18, 2023).
- [25] OpenStreetMap, <https://www.openstreetmap.org/> (accessed Aug. 18, 2023).
- [26] “Cabspotting,” Stamen, <https://stamen.com/work/cabspotting/> (accessed May 13, 2023).
- [27] M. Piorkowski, N. Sarafijanovic-Djukic, and M. Grossglauser, “A parsimonious model of mobile partitioned networks with clustering,” 2009 First International Communication Systems and Networks and Workshops, Jan. 2009. doi:10.1109/comsnets.2009.4808865